



UNIVERSIDAD NACIONAL
AUTÓNOMA DE MÉXICO

FACULTAD DE CIENCIAS

Fórmulas de Feynman-Kac para Procesos
de Itô y sus aplicaciones

T E S I S

QUE PARA OBTENER EL TÍTULO DE

MATEMÁTICO

PRESENTA:

Félix Alfonso Camacho Moya

ASESORA DE TESIS:

María Emilia Caballero Acosta

Ciudad de México, 2026

Índice general

1. Introducción	1
1.1. ¿Qué son las fórmulas de Feynman-Kac?	1
1.2. Motivación y estructura de la tesis	3
1.3. Notación frecuentemente usada	6
2. Fundamentos teóricos	9
2.1. El movimiento browniano	9
2.2. El movimiento browniano como martingala	14
2.3. El movimiento browniano como proceso de Markov	16
2.4. Generador Infinitesimal de un proceso estocástico	19
2.5. Fundamentos de Cálculo Estocástico y Ecuaciones Diferenciales Estocásticas	24
2.6. Difusiones de Itô	31
3. Fórmulas de Feynman-Kac	37
3.1. Proceso de Feynman-Kac	37
3.2. Fórmulas de Feynman-Kac para ecuaciones de difusión modificadas	42
3.3. Fórmula de Feynman-Kac para la ecuación de calor modificada	46
3.4. Fórmulas de Feynman-Kac para problemas de tipo Dirichlet-Poisson	47
3.5. Fórmulas de Feynman-Kac para problemas de tipo Cauchy	49
3.5.1. Fórmula de Feynman-Kac para la ecuación diferencial parabólica hacia atrás	49
3.5.2. Fórmula de Feynman-Kac para la ecuación diferencial parabólica no homogénea	51
4. Conexiones entre el proceso de Feynman-Kac y otras técnicas de condicionamiento y transformación de procesos estocásticos	57
4.1. Breve repaso de la teoría de las cadenas de Markov	58
4.2. Condicionamiento de una cadena de Markov por medio de la h-transformada de Doob	59
4.3. Transformada de Doob para procesos de difusión de Itô	62
4.4. Relación entre el proceso de Feynman-Kac y la difusión sesgada	64

4.5. Solución de la ecuación de difusión a través del teorema de Girsanov	66
5. Aplicaciones	69
5.1. Ley del Arcoseno para el Movimiento Browniano mediante Fórmulas de Feynman-Kac	70
5.2. Fórmulas de Feynman-Kac en el contexto de las finanzas matemáticas	74
5.2.1. Introducción a los instrumentos financieros derivados	74
5.2.2. Métodos matemáticos para la valuación de instrumentos financieros derivados	76
5.3. Valuación de una opción asiática usando Feynman-Kac	78
5.4. Análisis comparativo entre el método de Feynman-Kac y una implementación Monte Carlo directa	81
5.4.1. Reporte de resultados	81
5.4.2. Comparación entre el método con transformada de Laplace y Feynman-Kac vs Simulación Monte Carlo con Euler-Maruyama	84
5.4.3. Benchmark de rendimiento computacional	88
5.4.4. Conclusiones acerca de la aplicación de las fórmulas de Feynman-Kac en problemas numéricos	92
5.4.5. Otras aplicaciones de las Fórmulas de Feynman-Kac	93
5.5. Conclusiones y perspectivas	94
A. Código para la valuación de opciones asiáticas	95
A.1. Código para valuar opciones asiáticas con R	95
Referencias	117
Índice alfabético	121

Capítulo 1

Introducción

1.1. ¿Qué son las fórmulas de Feynman-Kac?

El objetivo de este trabajo es exponer los teoremas de tipo Feynman-Kac para una clase importante de procesos estocásticos, así como algunas de sus aplicaciones. Nos concentraremos primero en la construcción probabilística, y después daremos algunos ejemplos concretos de su uso.

Las fórmulas de Feynman-Kac aparecen como un vínculo fundamental entre la teoría de los procesos estocásticos y las ecuaciones diferenciales parciales lineales. Uno de los aspectos importantes de estas fórmulas es que toda solución acotada de ciertas clases de problemas de ecuaciones diferenciales parciales (EDP) con valores a la frontera, tiene la representación probabilística que plantean tales fórmulas.

En ese sentido, cuando decimos “representación probabilística de la solución”, a lo que nos referimos es al método en que obtenemos estas soluciones, que es básicamente promediando un proceso de difusión.

Concretamente, las fórmulas de Feynman-Kac establecen que la solución de ciertos problemas de ecuaciones diferenciales parciales con valores a la frontera está dada por la esperanza de una funcional del movimiento browniano, y más generalmente, por la esperanza de una funcional de un proceso de difusión cuyos coeficientes coinciden con los del operador diferencial del problema dado. Recíprocamente, podemos analizar las propiedades estadísticas de un proceso estocástico de difusión mediante la EDP asociada.

A la gama de técnicas y procedimientos para calcular la esperanza en estas situaciones, en el contexto de física matemática que les da nombre a las fórmulas de Feynman-Kac, se le conoce como *integración funcional*, aunque la analogía con los métodos utilizados en mecánica cuántica es tangencial y la teoría correspondiente, desarrollada por Israel Gelfand y Akiva Yaglom en 1956[17] y posteriormente por Robert Cameron en 1960[8], es muy distinto al enfoque de la teoría de procesos estocásticos que adoptamos en este trabajo, véase en ese sentido [37].

En lo que a nosotros nos concierne, en la teoría de los procesos estocásticos y sus aplicaciones en ramas como finanzas matemáticas, a estas fórmulas se les considera una aplicación del cálculo estocástico desarrollado por Kiyoshi Itô y Wolfgang Doeblin.

Además de ser de gran interés teórico al vincular la teoría de la probabilidad con las ecuaciones diferenciales parciales, dos ramas de las matemáticas que, a primera vista, parecen sumamente distantes entre sí, las fórmulas de Feynman-Kac nos proporcionan una alternativa, tanto simbólica como computacional, para encontrar soluciones numéricas concretas por medio de simulación a problemas de EDP, y recíprocamente, permite aplicar el enfoque y los métodos de solución de EDPs en problemas probabilísticos.

Esta correspondencia nos ofrece dos perspectivas complementarias para abordar un mismo problema:

1. **De lo determinista a lo estocástico:** Si nos enfrentamos a una EDP parabólica de segundo orden, podemos representar su solución como la esperanza de un funcional adecuado de un proceso estocástico. Esta representación no solo proporciona interpretaciones probabilísticas de la solución, sino que también sugiere métodos numéricos basados en simulación (como el método de Monte Carlo) para aproximar la solución en casos donde los métodos analíticos directos son inviables.
2. **De lo estocástico a lo determinista:** Si estamos interesados en calcular la esperanza de algún funcional de un proceso estocástico, podemos transformar este problema en la resolución de una EDP asociada. Esta transformación nos permite aprovechar el rico arsenal de métodos numéricos y analíticos desarrollados para EDPs.

La belleza de esta dualidad radica en su flexibilidad: dependiendo de la naturaleza del problema, podemos elegir la perspectiva que ofrezca el enfoque más tratable o revelador.

Esto es de gran importancia práctica en su aplicación más allá de las matemáticas en problemas científicos y económicos, debido a que muchos modelos matemáticos de interés se plantean a través de ecuaciones diferenciales parciales. En dimensiones bajas se pueden resolver numéricamente con algoritmos computacionales basados en diferencias finitas.

Sin embargo, en la solución de problemas reales, el problema puede llegar a depender de muchas variables, y en dimensiones más altas los métodos de diferencias finitas pueden llegar a ser de difícil aplicación y poca estabilidad. En tales casos, los métodos de simulación estocástica resultan ser más económicos, en términos tanto de dificultad de programación como de tiempo y recursos de computación necesarios.

De hecho, muchos productos de software de computación de alto desempeño, tanto comerciales como open-source, implementan algoritmos de simulación estocástica como parte de los métodos básicos de sus librerías de funciones. Algunos ejemplos contemporáneos son los recursos basados en CUDA, publicados por NVIDIA Corp, y librerías especializadas

como Vitis de AMD, las cuales están optimizadas para funcionar en el hardware fabricado por ambas compañías.

A partir de la expresión planteada de la esperanza condicional de la variable aleatoria de interés, estos paquetes de cómputo utilizan técnicas de simulación estocástica y Monte Carlo, así como los correspondientes para las EDPs asociadas, basadas en fórmulas de Feynman-Kac, para el cálculo de valores numéricos específicos.

1.2. Motivación y estructura de la tesis

La motivación de este trabajo surgió a partir de la observación de que las fórmulas de tipo Feynman-Kac aparecen bajo distintas interpretaciones y técnicas de demostración en la literatura de procesos estocásticos y finanzas matemáticas, sin que exista una presentación unificada, y de notación consistente, que vincule entre sí las maneras en que se exponen o la teoría que está detrás de ellas.

Un ejemplo importante es la colección de resultados correspondientes a la teoría de valuación de opciones. En la literatura de finanzas encontramos tanto la llamada ecuación de Black-Scholes, una EDP parabólica particular que modela el problema de valorar una opción de tipo europeo, como la *fórmula de Black-Scholes*, que es una fórmula cerrada para calcular soluciones a dicha ecuación. En los libros de finanzas matemáticas se obtiene dicha EDP con una aplicación del Lema de Itô a una función genérica que represente la solución, y asumiendo que se busca algo que se conoce como *cobertura dinámica*, que consiste en reproducir continuamente el precio teórico que debería tener el contrato de opción, usando combinaciones del activo subyacente y un activo libre de riesgo.

Dicho argumento es un artificio de razonamiento conveniente para efectos de darle sentido al problema, pero es una ficción económica porque en la práctica es imposible realizar una cobertura dinámica continua sin incurrir en costos de transacción infinitos. En ese sentido, sin embargo, es posible mostrar la relación de la EDP de Black-Scholes como un caso particular de las fórmulas de Feynman-Kac, tomando la esperanza de la función de pago descontada bajo la medida neutral al riesgo del modelo. La fórmula de representación no determina por sí sola esa medida: su interpretación como precio de no arbitraje requiere las hipótesis económicas correspondientes.

Por lo tanto, este importante resultado de la teoría financiera es un resultado matemático fundamental que debe distinguirse de las hipótesis económicas necesarias para interpretar la esperanza como un precio. Más generalmente, el hecho de que la relación entre funcionales de procesos estocásticos y EDPs sea general nos permite abordar una variedad mucho más amplia de problemas relevantes tanto para las matemáticas mismas, como para la ciencia y la tecnología en general.

Dado lo anterior, a la presentación unificada que en este texto se busca, le acompañan las herramientas usadas para deducirlas en una serie de casos particulares, explicando los

modelos probabilísticos y situaciones dinámicas que les motivan en cada caso. La pretensión es antologizar tales resultados y exponerlos junto con la teoría básica que les respalda, de manera notacionalmente consistente.

En el capítulo de fundamentos teóricos repasaremos los resultados más importantes de la teoría de los procesos estocásticos, que serán necesarios para la correcta aplicación del cálculo estocástico en la obtención de las Fórmulas de Feynman-Kac. Utilizando al movimiento browniano como nuestro modelo de proceso estocástico continuo canónico, recuperamos su conexión con la ecuación de calor y las ecuaciones de difusión en general, así como sus propiedades probabilísticas más importantes.

Después, recuperamos los resultados clásicos del cálculo estocástico de Itô, aplicado a los procesos de difusión y la solución de ecuaciones diferenciales estocásticas. Las difusiones de Itô son el artefacto probabilístico particular, a partir del cual construimos las representaciones de Feynman-Kac para las ecuaciones diferenciales parciales que nos resultan de interés particular.

La relación dual entre la función de densidad de probabilidad y la dinámica instantánea en el espacio de estados de un proceso de difusión, resulta estar codificada en las ecuaciones diferenciales parciales de Fokker-Planck-Kolmogorov. Las ecuaciones diferenciales a las que corresponden las fórmulas de representación de Feynman-Kac surgen como modificaciones de las ecuaciones de Fokker-Planck-Kolmogorov.

Estudiamos una interpretación probabilística particular, la cual es un caso de los procesos de Markov condicionados. Partiendo de la función de transición de Markov asociada a una difusión de Itô, realizamos la construcción del modelo probabilístico de un nuevo proceso de Markov en el cual las trayectorias de la difusión de Itô son “matadas” a una cierta tasa, la cual está determinada por una variable aleatoria con distribución exponencial.

A través de la modificación de la función de transición de un proceso de difusión de Markov dado, construimos el *semigrupo de transición de Feynman-Kac* y daremos la descripción general del generador infinitesimal del proceso de difusión matado correspondiente al que llamaremos **Proceso de Feynman-Kac**.

Después, utilizamos las técnicas generales del cálculo estocástico para encontrar fórmulas de Feynman-Kac para ecuaciones de difusión más generales. Así, especializamos nuestro estudio a los casos de tales fórmulas para ecuaciones de interés particular.

La intención es de presentar el bagaje de fórmulas para los casos más útiles, así como el entendimiento heurístico de las técnicas de demostración utilizadas y la manera de interpretarlas. A la exposición de los distintos casos les acompaña algunas digresiones respecto de las aplicaciones que tienen en otras áreas de las matemáticas.

Además, examinamos el vínculo que tienen el proceso de Feynman-Kac con otros procesos de difusión modificados por medio de la técnica de condicionamiento de la función de transición, y su relación con técnicas como la *h-transformada* de Doob. Dicha relación está apuntalada en la aplicación del teorema de Girsanov, e ilustramos su utilización para

la obtención de fórmulas de representación similares en las cuales subyace el concepto de cambio de medida.

1.3. Notación frecuentemente usada

A lo largo de este texto, en lo general se considera un espacio medible $(E, \mathcal{E})$, i.e. un conjunto E con su sigma-álgebra $\mathcal{E}$, que para efectos de este trabajo será $(\mathbb{R}^d, \mathcal{B}(\mathbb{R}^d))$, es decir, $\mathbb{R}^d$ y los borelianos de $\mathbb{R}^d$.

Cuando decimos que una función $f \in \mathcal{E}$, $\mathcal{E}$ es el conjunto de funciones $\mathcal{E}$ -medibles $f : E \mapsto \mathbb{R}$.

$\mathcal{E}_b$ son aquellas f acotadas en $\mathcal{E}$. (En particular, $\mathcal{B}(\mathbb{R})_b$ es la notación equivalente para las funciones borelianas acotadas en $\mathbb{R}$, y así sucesivamente)

$\mathcal{E}^+$ son aquellas f no negativas.

$C(E)$ es el conjunto de funciones continuas $f : E \mapsto \mathbb{R}$.

$C_b(E)$ el conjunto de f continuas y acotadas.

$C_0(E)$ es el conjunto de f continuas de E en $\mathbb{R}$ tales que

$$\lim_{|x| \rightarrow \infty} f(x) = 0.$$

En dicho espacio trabajamos con la norma uniforme: $\|f\|_\infty = \sup_{x \in E} |f(x)|$

$C_K(E)$ es el conjunto de aquellas f con soporte compacto.

$C^2(E)$ es el conjunto de las f que son dos veces diferenciables, con derivadas continuas de primer y segundo orden.

$C_K^2 = C^2 \cap C_K$ es el conjunto de f dos veces diferenciables y con soporte compacto.

Para denotar la diferenciación, para f en C^2 , escribiremos $\partial_i f$ para la derivada parcial respecto del i -ésimo argumento, y $\partial_{ij} f$ para las derivadas parciales de segundo orden respecto de los i y j -ésimos argumentos; la notación convencional para ello es $\partial_i = \frac{\partial}{\partial x_i}$ y $\partial_{ij} = \frac{\partial^2}{\partial x_i \partial x_j}$ respectivamente.

Cuando la dimensión $d = 1$, éstas se escriben de la manera usual: f' , f'' .

Algunos espacios funcionales importantes para la teoría de integración estocástica son los siguientes:

$L^2(\mathbb{P})$ es el espacio vectorial de variables aleatorias X que son cuadrado-integrables, es decir:

$$\|X\|_{L^2(\mathbb{P})} = (\mathbb{E}[X^2])^{1/2} < \infty.$$

Fijada una filtración $(\mathcal{F}_t)_{t \geq 0}$ y un horizonte $T > 0$, consideramos procesos progresiva-

mente medibles. Los espacios que utilizaremos son

$$\begin{aligned}\mathcal{H}^2 &= \left\{ X : \mathbb{E} \left[\int_0^T |X_t|^2 dt \right] < \infty \right\}, \\ \mathcal{L}_{\text{LOC}} &= \left\{ X : \mathbb{P} \left[\int_0^T |X_t| dt < \infty \right] = 1 \right\}, \\ \mathcal{L}_{\text{LOC}}^2 &= \left\{ X : \mathbb{P} \left[\int_0^T |X_t|^2 dt < \infty \right] = 1 \right\}.\end{aligned}$$

En particular, $\mathcal{H}^2 \subset \mathcal{L}_{\text{LOC}}^2$.

Para los procesos que empiezan en un punto $x \in \mathbb{R}^d$ al tiempo t , escribiremos $X^{t,x} = (X_s^{t,x})_{s \geq t}$, con $X_t^{t,x} = x$. Esta notación designa la solución con esa condición inicial; en general, no se obtiene sumando x a una solución que empieza en cero. En el caso particular del movimiento browniano sí podemos escribir $W_s^{t,x} = x + W_s - W_t$, para $s \geq t$.

Denotaremos por $\mathbb{P}^{t,x}$ la ley del proceso con dicha condición inicial y por $\mathbb{E}^{t,x}$ la esperanza respecto de esa ley. Así, para una función medible f para la cual exista la esperanza,

$$\mathbb{E}^{t,x} [f(X_s)] = \int f(y) P_{t,s}(x, dy), \quad s \geq t,$$

donde $P_{t,s}(x, \cdot)$ es la probabilidad de transición. Cuando el proceso es homogéneo en el tiempo y empieza en el instante cero, abreviaremos estas notaciones como X^x , $\mathbb{P}^x$ y $\mathbb{E}^x$.

Capítulo 2

Fundamentos teóricos

2.1. El movimiento browniano

“Observa lo que acontece cuando los rayos del sol son admitidos dentro de un edificio y cómo arroja la luz sobre los lugares oscuros. Puedes ver la multitud de pequeñas partículas moviéndose en un sinnúmero de caminos... su baile es un indicio de movimientos subyacentes de la materia, escondidos de nuestra vista...”

Lucrecio, *Sobre la naturaleza de las cosas*.

Como fenómeno de la naturaleza, el movimiento browniano fue observado por primera vez por el filósofo y poeta romano Lucrecio, en cuyo libro *Sobre la naturaleza de las cosas*[26] describe el movimiento de las partículas de polvo bajo el sol y usa esto como evidencia para argumentar a favor de la existencia de los átomos. Sin embargo, su nombre es debido al botánico Robert Brown, quien a principios del siglo XIX describió el errático comportamiento del polen inmerso en el agua cuando lo observaba bajo su microscopio.

Tales partículas realizaban un movimiento cuyas características eran las siguientes: en cualquier momento dado, una partícula podía moverse en cualquier dirección; el movimiento futuro parecía no depender de ningún modo del movimiento anterior; el movimiento era constante y no se detenía en ningún momento.

Brown observó que dicho comportamiento era común a toda clase de partículas que se encontraran en estado de suspensión en alguna clase de líquido. Además, comprobó que el mismo fenómeno ocurría para partículas de sustancias tanto inorgánicas como orgánicas.

La teoría física del movimiento browniano, como fue observado y documentado por Brown, fue desarrollada por diversos científicos a lo largo del siglo XIX. De ellos vale la pena destacar las observaciones de Delsaux, quien fue el primero en llegar a la conclusión correcta de que el movimiento de las partículas se debía a los impactos que sufrían por las moléculas del líquido en el que se encontraban sumergidas.

Conforme se fue desarrollando la teoría de la termodinámica a lo largo del siglo XIX, también fue evolucionando la teoría del movimiento browniano, la cual fue establecida, a partir de consideraciones de un estado de equilibrio termodinámico, en 1905, por Mileva Maric (véase [3]) y Albert Einstein. Ellos dedujeron la siguiente fórmula:

$$p(t, x, y) = \frac{1}{\sqrt{2\pi Dt}} \exp\left[-\frac{(y-x)^2}{2Dt}\right].$$

Esta fórmula establece la densidad de probabilidad p de que la partícula se desplace una cierta distancia $y - x$, durante un intervalo de tiempo t .

El coeficiente de difusión D es calculado tomando en cuenta el radio de la partícula, sus interacciones con las moléculas que le rodean, la temperatura y la constante de Boltzmann. La argumentación detallada de la maquinaria física y matemática que justifica esta teoría, como fue originalmente desarrollada por Maric y Einstein a lo largo de una serie de artículos presentados a partir de 1905, se puede consultar en [1].

Esta teoría fue verificada experimentalmente por Jean Baptiste Perrin en años subsecuentes. Tal densidad nos dice que el modelo matemático para el movimiento browniano corresponde a la clase de los procesos estocásticos gaussianos.

En la literatura clásica se han establecido distintas maneras de demostrar que un proceso estocástico que represente dicho fenómeno existe y cumple con ciertas características.

Aquí solo se citarán aquellos resultados que sean imprescindibles para exponer el tema que se presenta, basándonos principalmente en las siguientes fuentes: *Procesos de Lévy*, *Procesos de Markov y Convergencia Débil en espacios de Skorokhod*, Alejandro Rosales Ortiz [31], así como los libros de texto siguientes: *Stochastic Differential Equations*, de Bernt Oksendal [29], *Brownian Motion, Martingales and Stochastic Calculus* de Jean-Francois Le Gall [16], *Stochastic Calculus with Financial Applications* de J. Michael Steele [38], y *Brownian Motion and Stochastic Calculus* de Ioannis Karatzas y Steven Shreve [23].

Definición 2.1.1 (Proceso estocástico real). Un proceso estocástico real es una colección parametrizada de variables aleatorias

$$X = (X_t)_{t \in T},$$

con $T \subseteq \mathbb{R}$, definidas en un mismo espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$ y que toman valores en $\mathbb{R}$. Para cada $t \in T$

$$\omega \mapsto X_t(\omega) \quad \omega \in \Omega,$$

es una variable aleatoria, mientras que para un $\omega \in \Omega$ fijo,

$$t \mapsto X_t(\omega) \quad t \in T,$$

se llama una trayectoria de X_t

Definición 2.1.2. Sean X, Y procesos estocásticos reales indizados por el mismo conjunto de índices T .

Decimos que Y es una modificación de X si

$$\forall t \in T, \quad \mathbb{P}[Y_t = X_t] = 1.$$

Decimos también que el proceso Y es indistinguible de un proceso X si existe un conjunto de medida nula N de Ω tal que

$$\forall \omega \in \Omega \setminus N, \quad \forall t \in T, \quad X_t(\omega) = Y_t(\omega).$$

Definición 2.1.3 (Filtración). Una filtración en el espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$ es una colección de sub-sigma-álgebras de $\mathcal{F}$, $(\mathcal{F}_t)_{0 \leq t \leq \infty}$ tales que $\mathcal{F}_t \subseteq \mathcal{F}_s$ si $t \leq s \leq \infty$. Entonces, para $0 \leq t \leq s$

$$\mathcal{F}_0 \subseteq \mathcal{F}_t \subseteq \mathcal{F}_s \subseteq \mathcal{F}_\infty \subseteq \mathcal{F}.$$

A $(\Omega, \mathcal{F}, (\mathcal{F}_t), \mathbb{P})$ se le llama un espacio de probabilidad filtrado.

Es importante definir las condiciones bajo las cuales sean medibles las variables aleatorias que forman parte de un proceso estocástico.

Definición 2.1.4 (Procesos adaptados y progresivamente medibles). Un proceso estocástico $X = (X_t)$ que toma valores en $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ es adaptado a la filtración $(\mathcal{F}_t)$ si para cada $t \in T$, X_t es $\mathcal{F}_t$ -medible. Decimos además que es progresivamente medible (o progresivo) si, para cada $t \in T$, el mapeo

$$(\omega, s) \mapsto X_s(\omega),$$

definido en $\Omega \times [0, t]$ es $\mathcal{B}([0, t]) \otimes \mathcal{F}_t$ -medible

Para un proceso $X = (X_t)$ en el espacio de probabilidad $(\Omega, \mathcal{F}, (\mathcal{F}_t), \mathbb{P})$, la mínima filtración con respecto a la cual X_t es $\mathcal{F}_t$ -medible es la definida por $\mathcal{F}_t^X = \sigma(X_u : u \leq t)$ para cada t , y $\mathcal{F}_\infty^X = \sigma(X_u : u \geq 0)$. Esta es llamada la filtración canónica o natural de X .

Definición 2.1.5 (Tiempo de paro). Una variable aleatoria en $(\Omega, \mathcal{F})$, $\tau : \Omega \mapsto [0, \infty]$ se le llama un tiempo de paro con respecto a una filtración $(\mathcal{F}_t)$ si $\{\tau \leq t\} \in \mathcal{F}_t$ para todo $t \geq 0$.

Definición 2.1.6 (Movimiento Browniano). Un proceso estocástico $(W_t)_{t \geq 0}$ adaptado a una filtración $(\mathcal{F}_t)_{t \in \mathbb{R}^+}$, con valores en $\mathbb{R}$, es llamado un movimiento browniano siempre que se satisfagan las siguientes condiciones:




Figura 2.1: Simulación por computadora de una trayectoria de un movimiento browniano que inicia en $X_0 = 0$

1. Las trayectorias $W_t(\omega)$ son funciones continuas de t para casi todo $\omega \in \Omega$.
2. $W_0(\omega) = 0$ para casi todo $\omega \in \Omega$.
3. Para $0 \leq t \leq s$, el incremento $W_s - W_t$ es una variable aleatoria gaussiana con media cero y varianza $s - t$.
4. Para $0 \leq t \leq s$, el incremento $W_s - W_t$ es independiente de la σ -álgebra $\mathcal{F}_t$.

Demostrar de manera rigurosa que existe un proceso estocástico que cumpla con esta serie de características es un problema complejo que fue abordado por los grandes probabilistas del siglo XX. Una exposición detallada de algunos métodos constructivos para establecer su existencia puede encontrarse en [23].

La definición 2.1.5 implica además que la distribución de probabilidad correspondiente al movimiento browniano es la siguiente:

$$\mathbb{P}(W_t \in A | W_0 = x) = \frac{1}{\sqrt{2\pi t}} \int_A e^{-\frac{(y-x)^2}{2t}} dy. \quad (2.1)$$

Podemos también definir el movimiento browniano en d -dimensiones como un vector de movimientos brownianos.

Definición 2.1.7. Un proceso $(W^d) = (W^1, \dots, W^d)$ con valores en $\mathbb{R}^d$, se llama un movimiento browniano d -dimensional si sus componentes $W^1, \dots, W^d$ son movimientos brownianos unidimensionales independientes entre sí.

De aquí en adelante nuestras definiciones teóricas serán para el movimiento browniano unidimensional, pero se pueden generalizar a dimensiones más altas a partir de la definición anterior.

Para trabajar con el movimiento browniano se utiliza una filtración especial, la cual es el punto de referencia para muchos resultados importantes. Dicha filtración, que se obtiene con una modificación de la filtración generada por el movimiento browniano, es llamada la filtración browniana estándar, la cual definiremos a continuación.

Definición 2.1.8 (Filtración browniana estándar). Sea el espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$, y W un movimiento browniano. Consideremos los conjuntos $\mathbb{P}$ -nulos, que definimos a continuación:

$$\mathcal{N} := \{G \subseteq \Omega \mid \exists F \in \mathcal{F} : G \subseteq F, P(F) = 0\}.$$

Entonces, la filtración browniana estándar se define como

$$\mathcal{G}_t^W := \sigma(\mathcal{F}_t^W \bigcup \mathcal{N}).$$

Dicha filtración cumple las siguientes condiciones:

1. $\mathcal{G}_t^W$ contiene todos los conjuntos $\mathbb{P}$ -nulos.
2. $\mathcal{G}_t^W$ es continua por la derecha, es decir:

$$\mathcal{G}_t^W = \bigcap_{s:t < s} \mathcal{G}_s.$$

Diremos que una filtración cumple las condiciones usuales si cumple 1. y 2.

Una vez que contamos con el movimiento browniano, que se asume inicia en 0, podemos definir el movimiento browniano que inicia en un punto $x \in \mathbb{R}$.

Definición 2.1.9. Para cualquier $x \in \mathbb{R}$, el proceso que se define como sigue

$$W^x = (W_t^x)_{t \geq 0}, \quad W_t^x = x + W_t, \quad W_0 = 0,$$

es llamado el movimiento browniano que inicia en x . De (2.1) se sigue que para cualquier $A \in \mathcal{B}(\mathbb{R})$, y $t > 0$,

$$\mathbb{P}(W_t \in A \mid W_0 = x) = \mathbb{P}(W_t^x \in A) = \frac{1}{\sqrt{2\pi t}} \int_A e^{-\frac{(y-x)^2}{2t}} dy, \quad (2.2)$$

ya que $(W_t - W_0) = (W_t - x)$ es una variable aleatoria Gaussiana con media 0 y varianza t .

2.2. El movimiento browniano como martingala

Una martingala es un proceso que en la media no tiene tendencia a crecer o decrecer. Si pensamos en que el proceso represente, por ejemplo, las ganancias de un jugador en cierto juego de azar, entonces una martingala es el modelo de un juego justo - el jugador y su adversario están nivelados en promedio. Es por esta misma razón que se usan como modelos de transacciones justas en la teoría financiera. Su estudio fue formalizado en la Teoría de la Probabilidad por Wolfgang Doeblin y Paul Levy. Posteriormente fue profundizado por Joseph Leo Doob.

A continuación listamos algunos resultados, para los cuales nos basamos principalmente en las siguientes fuentes: 'Probability and Stochastics', Erhan Cinlar [11], [38] cap. 4 y 7

Definición 2.2.1 (Definición de Martingala). Un proceso estocástico $M = (M_t)$ en el espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$ es una martingala respecto de una filtración $(\mathcal{F}_t)$, o $(\mathcal{F}_t)$ -martingala, si satisface las siguientes condiciones:

1. Adaptado: M_t es $\mathcal{F}_t$ -medible para todo t
2. Integrable: $\mathbb{E}|M_t| < \infty$ para todo t y
3. Propiedad de Martingala: $\mathbb{E}[M_s | \mathcal{F}_t] = M_t$ para todo $s \geq t$.

Definición 2.2.2 (Martingala continua). Una martingala $X = (X_t)$ es llamada martingala continua si existe un $\Omega_0 \subset \Omega$ que cumple $\mathbb{P}(\Omega_0) = 1$, de tal modo que para cada $\omega \in \Omega_0$, la trayectoria $f : [0, \infty) \mapsto X_t(\omega)$ es continua.

El movimiento browniano es el ejemplo más importante de una martingala continua.

Proposición 2.2.3. *El movimiento browniano es una martingala.*

Demostración. Fijemos $0 \leq t < s$. Entonces, por independencia de los incrementos, tenemos que

$$\begin{aligned} \mathbb{E}(W_s | \mathcal{F}_t) &= \mathbb{E}(W_s - W_t + W_t | \mathcal{F}_t) \\ &= \mathbb{E}(W_s - W_t | \mathcal{F}_t) + \mathbb{E}(W_t | \mathcal{F}_t) \\ &= 0 + W_t \\ &= W_t, \end{aligned}$$

puesto que $\mathbb{E}(W_s - W_t | \mathcal{F}_t) = \mathbb{E}(W_s - W_t) = 0$, al ser el incremento $W_s - W_t$ una variable aleatoria gaussiana con media 0 e independiente de $\mathcal{F}_t$. Además, como W_t es $\mathcal{F}_t$ -medible, resulta que $\mathbb{E}(W_t | \mathcal{F}_t) = W_t$. $\square$

Los siguientes resultados, que citamos sin demostración de [38], cap.4, así como [12], nos permiten aprovechar distintas propiedades útiles de las martingalas, así como una clase más general de proceso llamado martingala local.

Teorema 2.2.4 (Teorema del paro opcional de Doob). *Sea $M = (M_t)$ una martingala continua adaptada a la filtración $\mathcal{F} = (\mathcal{F}_t)$, que satisface las condiciones usuales.*

Sea τ un tiempo de paro respecto a $(\mathcal{F}_t)$. Entonces, el proceso parado, definido por

$$X_t = M_{t \wedge \tau}, \quad (2.3)$$

es una martingala continua respecto a $(\mathcal{F}_t)$.

A continuación se definen las martingalas locales, que generalizan el Teorema del Paro Opcional de Doob a una clase más grande de procesos. Una martingala local se construye por medio de una sucesión localizadora de tiempos de paro, que son tiempos de paro que cumplen una condición de cota para el proceso. El proceso parado, definido para cada tiempo de paro de la sucesión localizadora, resulta ser una martingala.

Definición 2.2.5 (Martingala Local). Un proceso $M = (M_t)$ adaptado a la filtración $(\mathcal{F}_t)$ es llamado una *martingala local* si existe una sucesión no decreciente de tiempos de paro $\{\tau_k\}$ tales que

$$\mathbb{P}[\lim_{k \rightarrow \infty} \tau_k = \infty] = 1,$$

y para cada k , el proceso parado en τ_k , definido por

$$M_{t \wedge \tau_k},$$

es una martingala respecto de la filtración $(\mathcal{F}_t)$.

La sucesión de tiempos de paro τ_k es llamada una sucesión localizadora.

Los siguientes resultados relacionados con las martingalas locales son vitales para las técnicas que utilizaremos en el capítulo 3.

Lema 2.2.6. *Si M es una martingala local, y τ un tiempo de paro, entonces el proceso parado $Y = M_{t \wedge \tau}$ es una martingala local.*

Lema 2.2.7 (Las martingalas locales acotadas son martingalas). *Si M es una martingala local continua y C una constante tal que $|M| \leq C$ para todo $t \geq 0$, entonces M es una martingala.*

Finalmente, a continuación se enuncia la condición de cota que debe cumplir la sucesión localizadora de una martingala continua.

Lema 2.2.8 (Sucesión localizadora para martingalas continuas). *Sea M una martingala continua. Entonces, una sucesión localizadora para M es la siguiente:*

$$\tau_n = \inf\{t : |M_t| > n\}.$$

2.3. El movimiento browniano como proceso de Markov

La idea de un proceso de Markov es la siguiente: es un proceso para el cual la probabilidad condicional de su desarrollo futuro sólo depende de su estado actual, para cada momento de tiempo que consideremos. Para formalizar esta discusión, daremos especificidad a esta idea por medio de la siguiente definición y sus consecuencias.

A continuación veremos que la familia de medidas de probabilidad de transición que corresponden al movimiento browniano unidimensional que empieza en $x \in \mathbb{R}$, tiene la propiedad de Markov tanto cuando condicionamos a partir de un tiempo t usual, como cuando condicionamos con un tiempo de paro τ . En palabras de Taira [40], “...los procesos de Markov son una abstracción de la idea del movimiento browniano.”. Nuestra exposición se puede complementar con las siguientes referencias: ‘Brownian Motion’ de Peres y Mörters ([32]). Véase también [31].

Definición 2.3.1 (Proceso de Markov). Sea $(\Omega, \mathcal{F}, \mathbb{P})$ un espacio de probabilidad y $s \geq t \geq 0$. Un proceso estocástico $X = (X_t)_{t \geq 0}$, con $X_t : \Omega \rightarrow \mathbb{R}^d$, con filtración natural $\mathcal{F}_t^X = \sigma(X_u : u \leq t)$, cumple la propiedad de Markov si para cada $A \in \mathcal{B}(\mathbb{R}^d)$:

$$\mathbb{P}(X_s \in A | \mathcal{F}_t) = \mathbb{P}(X_s \in A | \sigma(X_t)). \quad (2.4)$$

Para un proceso X que cumpla la propiedad de Markov, para cada A en $\mathcal{B}(\mathbb{R})$, la probabilidad condicional respecto a $\mathcal{F}_t$ es una variable $\sigma(X_t)$ -medible, y puesto que $\mathbb{P}(X_s \in A | \sigma(X_t))$ es $\sigma(X_t)$ -medible, existe una función $h : \mathbb{R} \mapsto \mathbb{R}$ tal que $\mathbb{P}(X_s \in A | \sigma(X_t)) = h(X_t)$.

Dicha función depende tanto de A como t y s , por lo cual la denotaremos $P_{t,s}(x, A)$, es decir:

$$\mathbb{P}(X_s \in A | \sigma(X_t)) = P_{t,s}(X_t, A). \quad (2.5)$$

Esto motiva la siguiente definición.

Definición 2.3.2 (Kernel o probabilidad de transición). Un *kernel o probabilidad de transición* en $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$ es una función $P : \mathbb{R} \times \mathcal{B}(\mathbb{R}) \mapsto [0, 1]$ que cumple lo siguiente

1. para cada $x \in \mathbb{R}$, el mapeo $A \mapsto P(x, A)$ es una medida de probabilidad en $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$.

Cuando integramos una función f respecto a esta medida, escribimos:

$$\int_{\mathbb{R}} P(x, dy) f(y).$$

2. para cada $A \in \mathcal{B}(\mathbb{R})$, el mapeo $x \mapsto P(x, A)$ es $\mathcal{B}(\mathbb{R})/\mathcal{B}([0, 1])$ -medible.

Definición 2.3.3. Una familia de probabilidades de transición $P_{t,s}$ es llamada homogénea si para $s > t$ cualesquiera:

$$P_{t,s} = P_{0,s-t}.$$

En dicho caso denotaremos por P_t a $P_{0,t}$ y trabajaremos con la colección $(P_t)_{t \geq 0}$. De aquí en adelante sólo consideramos familias de este tipo.

Teorema 2.3.4 (Ecuación de Chapman-Kolmogorov). *Sea (P_t) la familia de probabilidades de transición de un proceso de Markov. Para todo $A \in \mathcal{B}(\mathbb{R})$, $x \in \mathbb{R}$ y $t, s > 0$, dicha familia satisface la siguiente ecuación:*

$$P_{t+s}(x, A) = \int_{\mathbb{R}} P_t(x, dy) P_s(y, A), \quad (2.6)$$

conocida como la Ecuación de Chapman-Kolmogorov.

Proposición 2.3.5. *Si X es un proceso de Márkov, su familia de probabilidades de transición cumple la propiedad de semigrupo. Es decir, para P_0 definido como el operador identidad, tenemos*

$$P_{t+s} = P_t P_s = P_s P_t. \quad (2.7)$$

A una familia de operadores que cumpla esta propiedad para $f \in \mathcal{E}_b$ se le conoce como semigrupo de operadores para dicho conjunto de funciones.

Demostración. Para verificarlo, veamos cómo actúa sobre funciones indicadoras.

$$\begin{aligned} P_{s+t}1_A(x) &= \int_E 1_A(y) P_{s+t}(x, dy) \\ &= P_{s+t}(x, A) \\ &= \mathbb{P}(X_{t+s} \in A | X_0 = x) \\ &= P_{t+s}(x, A) \\ &= \int_{\mathbb{R}} P_t(y, A) P_s(x, dy) \\ &= P_s P_t(x, A) \\ &= P_s P_t 1_A(x) \end{aligned}$$

El resultado para f medible se sigue por los teoremas de convergencia. $\square$

La familia de probabilidades de transición del movimiento browniano se identificará con su distribución de la siguiente manera:

$$P_t(x, A) := p(t, x, A). \quad (2.8)$$

Con esto podemos enunciar la definición de la propiedad de Markov en términos de su función de transición.

Definición 2.3.6 (Propiedad de Markov). Sea $(\Omega, \mathcal{F}, (\mathcal{F}_t), \mathbb{P})$ un espacio de probabilidad filtrado. Un proceso X , adaptado a la filtración $(\mathcal{F}_t)$, satisface la propiedad de Markov respecto a dicha filtración, y con función de transición (P_t) , si para cualesquiera $t, s \geq 0$:

$$\mathbb{E}(f(X_{t+s})|\mathcal{F}_t) = P_s f(X_t), \quad (2.9)$$

para cualquier f medible y no negativa.

Observación 2.3.7. Bajo las condiciones que hemos establecido, el semigrupo de operadores es la esperanza condicional de la variable aleatoria X_t dado que $X_0 = x$. Entonces, la propiedad de Markov y la definición del kernel de transición implica las siguientes ecuaciones:

$$\begin{aligned} \mathbb{E}^x[f(X_t)] &= P_t f(x) \\ \mathbb{E}^{X_0}[f(X_t)] &= P_t f(X_0) \end{aligned}$$

las cuales son útiles para aplicar dicha propiedad en conjunción con la ecuación 2.7.

Dada la definición anterior, un proceso tiene la **propiedad fuerte de Markov** si podemos generalizar la propiedad de Markov de tiempos t fijos, a tiempos de paro τ . No siempre sucede que un proceso que cumpla la propiedad débil de Markov cumpla también la propiedad fuerte.

Teorema 2.3.8 (Propiedad de Markov del movimiento browniano). Sea $(W_t)_{t \geq 0}$ un movimiento browniano con $W_0 = x$. Para cada $t \geq 0$ fijo, $(W_{t+r} - W_t)_{r \geq 0}$ es un movimiento browniano iniciado en cero, independiente de $\mathcal{F}_t$. Por tanto, para $s > t$ y $A \in \mathcal{B}(\mathbb{R})$,

$$\mathbb{P}^x(W_s \in A | \mathcal{F}_t) = P_{s-t}(W_t, A) = \frac{1}{\sqrt{2\pi(s-t)}} \int_A e^{-(y-W_t)^2/(2(s-t))} dy. \quad (2.10)$$

Demostración. Esta propiedad es consecuencia directa de que $(W_t)_{t \geq 0}$ tenga incrementos independientes y estacionarios. $\square$

Teorema 2.3.9 (Propiedad fuerte de Markov del movimiento browniano). Sea τ un tiempo de paro finito casi seguramente. Entonces, el proceso $W_{t+\tau} - W_\tau$ es un movimiento browniano y es independiente de $\mathcal{F}_\tau$.

Demostración. La demostración depende del resultado que establece que los tiempos de paro continuos pueden ser aproximados por tiempos de paro discretos. Véase [23]. $\square$

Observación 2.3.10. El movimiento browniano tiene el siguiente semigrupo de operadores de transición, llamado el **semigrupo browniano** u **operador de Green**:

$$P_t f(x) = \int_{\mathbb{R}} \frac{1}{\sqrt{2\pi t}} e^{-\frac{(y-x)^2}{2t}} f(y) dy.$$

Esto se sigue directamente de la definición anterior.

Además, haciendo el cambio de variable $z = \frac{y-x}{\sqrt{t}}$, $dz = \frac{dy}{\sqrt{t}}$ lo podemos expresar en términos de una integral gaussiana más conveniente.

$$P_t f(x) = \int_{\mathbb{R}} p_t(x, y) f(y) dy \quad (2.11)$$

$$= \int_{\mathbb{R}} \frac{1}{\sqrt{2\pi t}} e^{-\frac{(y-x)^2}{2t}} f(y) dy \quad (2.12)$$

$$= \int_{\mathbb{R}} \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}} f(x + \sqrt{t}z) dz. \quad (2.13)$$

Si usamos $\phi(z) = \frac{1}{\sqrt{2\pi}} e^{-\frac{z^2}{2}}$, nos queda la expresión compacta:

$$P_t f(x) = \int_{\mathbb{R}} f(x + \sqrt{t}z) \phi(z) dz. \quad (2.14)$$

2.4. Generador Infinitesimal de un proceso estocástico

El *generador infinitesimal* de un proceso estocástico nos proporciona una descripción de la dinámica instantánea que tiene el proceso, conforme transita de un punto a otro de su espacio de estados. Dicho generador es, en el caso que es pertinente para nuestro estudio, un operador diferencial de segundo orden. Las principales fuentes para los resultados enunciados en esta sección es [29] cap.7, así como [16] Cap 6, sec.2.

Definición 2.4.1. El **generador infinitesimal** L de un proceso estocástico X se define como:

$$(Lf)(x) := \lim_{t \rightarrow 0} \frac{\mathbb{E}^x[f(X_t)] - f(x)}{t}. \quad (2.15)$$

El conjunto de funciones $f : \mathbb{R} \rightarrow \mathbb{R}$ para las cuales este límite existe en x se denomina $\mathcal{D}_L(x)$, y $\mathcal{D}_L$ denota el conjunto de funciones para las cuales este límite existe para todo $x \in \mathbb{R}$.

Observación 2.4.2. Notemos que puesto que $\mathbb{E}^x[f(X_t)] = P_t f(x)$, la definición anterior puede reescribirse en términos del kernel de transición:

$$(Lf)(x) := \lim_{t \rightarrow 0} \frac{P_t f(x) - f(x)}{t}. \quad (2.16)$$

Como menciona [30], para $f \in \mathcal{D}_L(x)$, el generador L nos da el comportamiento infinitesimal de $f(X_0) = f(x)$, de manera similar a como lo hace la derivada en 0 de una función diferenciable. El siguiente resultado que citamos de esa fuente clarifica esta idea.

Corolario 2.4.3. *Sea X una difusión con generador L y función de transición P_t . Entonces,*

$$L = \frac{\partial}{\partial t} \Big|_{t=0} P_t.$$

Demostración.

$$Lf(x) = \lim_{t \rightarrow 0} \frac{\mathbb{E}^x [f(X_t) - f(X_0)]}{t} = \lim_{t \downarrow 0} \frac{P_t f(x) - P_0 f(x)}{t} = \frac{\partial P_t f(x)}{\partial t} \Big|_{t=0}.$$

□

El generador cumple además la siguiente relación con la función de transición P_t como se describe en el resultado que se cita a continuación. La demostración puede consultarse en [16], sección 6.2, proposición. 6.10

Lema 2.4.4. *Sea (P_t) un semigrupo fuertemente continuo en un espacio de Banach, y sea L su generador, con el límite definido en la norma de ese espacio. Para $f \in \mathcal{D}_L$ y $s > 0$, $P_s f \in \mathcal{D}_L$ y $L(P_s f) = P_s(Lf)$. La existencia de un límite sólo puntual no basta para esta afirmación.*

Existen distintas formas de demostrar la forma explícita del generador infinitesimal del movimiento browniano. A continuación vamos a mostrar que la familia de probabilidades de transición del movimiento browniano satisface la ecuación del calor de la física, de lo cual se deduce la expresión del generador infinitesimal.

La ecuación del calor, también llamada la ecuación de difusión, es usada en muchos modelos que describen la evolución, a través del tiempo, de la densidad de una cantidad física, ya sea el calor, o la densidad de una sustancia.

Lema 2.4.5 (Solución Fundamental de la ecuación de calor). *Sea la función*

$$G(t, x) = \frac{1}{\sqrt{2\pi t}} e^{-\frac{(x)^2}{2t}}.$$

*Dicha función satisface la **ecuación del calor** de la física*

$$\frac{\partial G}{\partial t} = \frac{1}{2} \frac{\partial^2 G}{\partial x^2}$$

*y se le conoce como la **solución fundamental** de tal ecuación.*

Demostración. Podemos demostrarla directamente tomando derivadas y comparando:

$$\begin{aligned}\frac{\partial G}{\partial t} &= \frac{\partial}{\partial t} \frac{1}{\sqrt{2\pi t}} \exp\left(\frac{-x^2}{2t}\right) \\ &= \exp\left(\frac{-x^2}{2t}\right) \frac{1}{\sqrt{2\pi t}} \left(\frac{x^2}{2t^2} - \frac{1}{2t}\right).\end{aligned}\tag{2.17}$$

$$\begin{aligned}\frac{\partial G}{\partial x} &= \exp\left(\frac{-x^2}{2t}\right) \frac{1}{\sqrt{2\pi t}} \frac{-x}{t} \\ \frac{\partial^2 G}{\partial x^2} &= \exp\left(\frac{-x^2}{2t}\right) \frac{1}{\sqrt{2\pi t}} \left(\frac{x^2}{t^2} - \frac{1}{t}\right).\end{aligned}\tag{2.18}$$

La comparación de estas ecuaciones nos conduce a la ecuación del calor:

$$\frac{\partial G}{\partial t} = \frac{1}{2} \frac{\partial^2 G}{\partial x^2}.\tag{2.19}$$

□

Con este resultado podemos deducir la forma del generador infinitesimal del movimiento browniano.

Proposición 2.4.6. *Sea $f \in C_K^2$. El generador infinitesimal del movimiento browniano tiene la siguiente forma:*

$$Lf = \frac{1}{2} f'' = \frac{1}{2} \frac{\partial^2 f}{\partial x^2}.$$

Demostración. Esto es consecuencia del lema anterior al observar que $G(t, x)$ es la densidad gaussiana del movimiento browniano, así como del corolario 2.4.3. De ello además se sigue que $C_K^2 \subseteq \mathcal{D}_L$. □


La solución fundamental $G(t, x)$ de la ecuación del calor tiene algunas propiedades que vale la pena destacar. Para $x \in \mathbb{R}^n$, dicha función tiene una simetría radial respecto del origen, lo que simplifica su deducción en el caso más general.

Se sabe también que la solución fundamental de la ecuación del calor satisface el siguiente problema de valores iniciales:

$$\begin{cases} \frac{\partial}{\partial t} G - \frac{1}{2} \Delta G = 0 & \text{en } \mathbb{R} \times (0, \infty) \\ G = \delta_0 & \text{en } \mathbb{R} \times \{t = 0\} \end{cases},$$

donde δ_0 es la medida de Dirac que le da una masa unitaria al 0.

Esto significa que conforme t se va a 0, las soluciones convergen a la distribución delta de Dirac que concentra toda la masa de la sustancia en un solo punto en el instante $t = 0$.



La demostración de este fenómeno, así como otras propiedades interesantes de la ecuación del calor desde el punto de vista de la teoría de las ecuaciones diferenciales parciales, se pueden consultar en [13], cap. 2 sec 2.3.

Podemos también demostrar que la familia de probabilidades de transición del movimiento browniano satisface la ecuación del calor, por medio del análisis de la integral gaussiana en sí.

Proposición 2.4.7. Sea $f \in C_K^2(\mathbb{R})$ y definamos la función:

$$u(t, x) := (P_t)f(x) = \int_{\mathbb{R}} f(y) \frac{1}{\sqrt{2\pi t}} e^{-\frac{(y-x)^2}{2t}} dy,$$

entonces $u(t, x)$ satisface la **ecuación del calor** de la física:

$$\frac{\partial u}{\partial t} = \frac{1}{2} \frac{\partial^2 u}{\partial x^2}$$

con la condición de valores a la frontera siguiente:

$$u(t, x) \rightarrow f(x) \text{ siempre que } t \rightarrow 0$$

Demostración. Para ver este hecho, definamos $u(t, x) = \mathbb{E}(f(W_t^x))$.

Aplicando los cambios de variable que habíamos establecido:

$$u(t, x) = \int_{\mathbb{R}} f(x + z\sqrt{t}) \frac{1}{\sqrt{2\pi}} e^{-\frac{|z|^2}{2}} dz$$

Ahora, para cierto x fijo y $t > 0$

$$\frac{\partial u}{\partial t} = \frac{1}{\sqrt{2\pi}} \lim_{h \rightarrow 0} \int_{-\infty}^{\infty} \exp\left(\frac{-z^2}{2}\right) \frac{1}{h} (f(x + \sqrt{t+hz}) - f(x + \sqrt{t}z)) dz$$

Por el teorema del valor medio, para una h arbitrariamente pequeña, existe una $c \in [t, t+h]$ tal que

$$\frac{1}{h} (f(x + \sqrt{t+hz}) - f(x + \sqrt{t}z)) = z \frac{1}{2\sqrt{c}} f'(x + \sqrt{c}z)$$

Dado que $f(x + \sqrt{s}z)$ es suave, entonces es acotada para todo $s \in [t, t+h]$. Por otra parte, puesto que $t > 0$, $\frac{1}{2\sqrt{s}}$ es acotada en el mismo intervalo.

Ahora, definamos

$$g(x, z) := \sup_{s \in [t, t+h]} \left| z \frac{1}{2\sqrt{s}} f'(x + \sqrt{s}z) \right|$$

Para h arbitrariamente pequeña tenemos entonces que

$$\left| \exp\left(\frac{-z^2}{2}\right) \frac{1}{h} (f(x + \sqrt{t+hz}) - f(x + \sqrt{t}z)) \right| \leq \left| \exp\left(\frac{-z^2}{2}\right) g(x, z) \right|$$

donde resulta que

$$\exp\left(\frac{-z^2}{2}\right) g(x, z)$$

es claramente integrable, así que usándola como función dominante podemos aplicar el Teorema de Convergencia Dominada y calcular las derivadas, como hicimos en el lema anterior.

$$\begin{aligned} \frac{\partial u}{\partial t} &= \int_{-\infty}^{\infty} \frac{\partial}{\partial t} \frac{1}{\sqrt{2\pi t}} \exp\left(\frac{-(x-y)^2}{2t}\right) f(y) dy \\ &= \int_{-\infty}^{\infty} f(y) \exp\left(\frac{-(x-y)^2}{2t}\right) \frac{1}{\sqrt{2\pi t}} \left(\frac{(x-y)^2}{2t^2} - \frac{1}{2t}\right) dy. \end{aligned} \quad (2.20)$$

De manera análoga lo podemos aplicar respecto a la variable x . Diferenciando dos veces respecto a x obtenemos

$$\begin{aligned} \frac{\partial u}{\partial x} &= \int_{-\infty}^{\infty} f(y) \exp\left(\frac{-(x-y)^2}{2t}\right) \frac{1}{\sqrt{2\pi t}} \frac{-(x-y)}{t} dy. \\ \frac{\partial^2 u}{\partial x^2} &= \int_{-\infty}^{\infty} f(y) \exp\left(\frac{-(x-y)^2}{2t}\right) \frac{1}{\sqrt{2\pi t}} \left(\frac{(x-y)^2}{t^2} - \frac{1}{t}\right) dy. \end{aligned} \quad (2.21)$$

La comparación de estas ecuaciones nos conduce a la ecuación del calor:

$$\frac{\partial u}{\partial t} = \frac{1}{2} \frac{\partial^2 u}{\partial x^2}. \quad (2.22)$$

Para comprobar la condición a la frontera, procedemos recordando los cambios de variable que habíamos establecido:

$$u(t, x) = \int_{\mathbb{R}} f(x + z\sqrt{t}) \frac{1}{\sqrt{2\pi}} e^{-\frac{|z|^2}{2}} dz.$$

Entonces, al hacer tender t a 0, tenemos que

$$u(0, x) = \int_{\mathbb{R}} f(x) \frac{1}{\sqrt{2\pi}} e^{-\frac{|z|^2}{2}} dz = f(x),$$

puesto que $\int_{\mathbb{R}} e^{-\frac{|z|^2}{2}} dz = \sqrt{2\pi}$. □

Partiendo del último resultado de la sección anterior, puesto que $u(t, x)$ así definida cumple la ecuación de calor, tomemos su transformada de Laplace¹:

$$g_{\lambda}(x) = \int_0^{\infty} e^{-\lambda t} u(t, x) dt,$$

y calculando las derivadas de esta transformada, es posible demostrar que se satisface la siguiente identidad:

$$\lambda g_{\lambda}(x) - \frac{1}{2} g_{\lambda}''(x) = f(x).$$

Esto nos dice que podemos encontrar soluciones (con unicidad) en la clase de funciones acotadas.²

2.5. Fundamentos de Cálculo Estocástico y Ecuaciones Diferenciales Estocásticas

La integración estocástica es una de las herramientas más modernas de la teoría de la probabilidad, la cual nos permite extender el concepto de integral a procesos estocásticos y funciones de los mismos. Una de sus principales motivaciones es la solución de ecuaciones diferenciales estocásticas, que son una manera de generalizar las ecuaciones diferenciales ordinarias. La idea básica es la siguiente: si tenemos un modelo matemático de un fenómeno,

¹Para $\lambda > 0$, $|u(t, x)| \leq \|f\|_{\infty}$ implica $\int_0^{\infty} e^{-\lambda t} |u(t, x)| dt \leq \|f\|_{\infty} / \lambda < \infty$.

²Para ser precisos, esta es una condición de suficiencia determinada por la relación algebraica de las derivadas de la transformada de Laplace de una función continua. Véase el teorema 5.42b en [35]

expresado como una ecuación diferencial ordinaria de la forma

$$\frac{dy}{dt} = b(y(t)),$$

es posible imaginarse que tenemos un factor de “ruido” o perturbaciones aleatorias, que influyen en la variación del sistema. Esto significa que, vista en forma de diferenciales, a la variación determinista

$$dy = b(y(t))dt,$$

se le sumaría un término de la forma $\sigma(y(t))dW_t$, donde σ es una función (o, en el caso más simple, una constante) que determina la magnitud del ruido, el cual se modela como un movimiento browniano W_t . Esto nos da la forma de una ecuación diferencial estocástica:

$$dy = b(y(t))dt + \sigma(y(t))dW_t,$$

la cual, a su vez, se expresa en forma integral de la siguiente manera, utilizando el movimiento browniano como integrador del componente estocástico de la dinámica del fenómeno:

$$y(t) = y_0 + \int_0^t b(y(s))ds + \int_0^t \sigma(y(s))dW_s.$$

La teoría del cálculo estocástico, iniciada por Kiyoshi Itô en 1942 y continuada después por muchos otros probabilistas a lo largo del siglo XX, permite clarificar el significado preciso de esta ecuación, y más aún; en su forma más desarrollada, proporciona una manera de lidiar con integrales en las cuales tanto el integrando como el integrador son procesos estocásticos. Por ejemplo, dicha teoría clarifica qué clase de objetos podemos representar simbólicamente por medio de la siguiente integral:

$$\int_0^t f(W_s)dW_s.$$

Es importante enfatizar que debido a que el mapeo $t \mapsto W_t$ no es de variación acotada, esta integral no se puede interpretar como una forma de integral de Lebesgue-Stieltjes, y su construcción exige de cierto cuidado técnico, definiéndose en primer lugar para una clase bastante restringida de martingalas continuas, y extendiéndose, por medio de un proceso de aproximación, a una clase más amplia de procesos estocásticos.

Para efectos de este trabajo utilizaremos las propiedades de la integral estocástica de procesos que estén en $\mathcal{L}_{LOC}^2$, la cual se construye como una extensión de la integral de Itô de procesos medibles en $\mathcal{H}^2$ por medio del procedimiento de localización.

Una introducción a estas ideas se puede consultar en [33] cap.9 , mientras que los detalles más finos de la teoría de las integrales estocásticas de Itô [29], cap. 4 y 8, [9] cap.1, [41] cap. 6 sec. 3.

A continuación enunciamos las propiedades de la integral estocástica, asumiendo como

dada la construcción detallada antes mencionada.

Teorema 2.5.1 (Propiedades de la Integral Estocástica de Itô). *Sea $X \in \mathcal{L}_{LOC}^2$ y W un movimiento browniano. La integral estocástica de X respecto a W se escribe de la siguiente manera:*

$$I_t(X) = \int_0^t X_s dW_s, \quad (2.23)$$

donde I_t es un mapeo $I_t : \mathcal{L}_{LOC}^2 \mapsto L^0(\mathbb{P})$. Aquí $L^0(\mathbb{P})$ denota las variables aleatorias finitas casi seguramente; la pertenencia a $L^2(\mathbb{P})$ queda garantizada cuando $X \in \mathcal{H}^2$. En general, decimos que un proceso X es Itô-integrable si $I_t(X)$ está bien definido y cumple las siguientes propiedades:

1. $I_t : \mathcal{L}_{LOC}^2 \mapsto L^0(\mathbb{P})$ es lineal, es decir, para c una constante y $X_s, Y_s \in \mathcal{L}_{LOC}^2$:

$$\int_0^t (cX_s + Y_s) dW_s = c \int_0^t X_s dW_s + \int_0^t Y_s dW_s.$$

2. Si $X \in \mathcal{H}^2$, entonces $\mathbb{E}[I_t(X)] = 0$.

3. Si $X \in \mathcal{H}^2$ se cumple la isometría de Itô:

$$\mathbb{E} \left[\left| \int_0^t X_s dW_s \right|^2 \right] = \mathbb{E} \left[\int_0^t |X_s|^2 ds \right].$$

4. Si $X \in \mathcal{H}^2$, $I_t(X)$ es una $(\mathcal{F}_t)$ -martingala, es decir

$$\mathbb{E} \left[\int_0^t X_u dW_u | \mathcal{F}_s \right] = \int_0^s X_u dW_u.$$

Respecto al inciso 4, cabe destacar que en general, las integrales de Itô para procesos en $\mathcal{L}_{LOC}^2$ son martingalas locales, como se enuncia a continuación.

Teorema 2.5.2 (Las integrales de Itô son martingalas locales). *Para cualquier $X \in \mathcal{L}_{LOC}^2$ existe una martingala local continua M tal que*

$$\mathbb{P} \left[M_t(\omega) = \int_0^t X(\omega, s) dW_s \right] = 1.$$

Además, la sucesión localizadora necesaria es aquella dada por:

$$\tau_n(\omega) = \inf \left\{ t \geq 0 : \int_0^t X^2(\omega, s) ds \geq n \right\} \wedge n.$$

Como consecuencia de la propiedad de martingala local de la integral de Itô, resulta entonces que la integral de Itô está bien definida con respecto de una sucesión localizadora de tiempos de paro τ :

$$I_{t \wedge \tau}(X) = \int_0^{t \wedge \tau} X_s dW_s. \quad (2.24)$$

Para cada tiempo τ_n de la sucesión anterior, la integral detenida es una martingala cuadrado-integrable. Para un tiempo de paro arbitrario sólo se garantiza, en general, que sea una martingala local.

Avanzando con la teoría de Itô, se define, a partir de la integral estocástica respecto del movimiento browniano, un proceso especial con una condición inicial $X_0 = x$, el cual es de la forma

$$X_t^x(\omega) = x + \int_0^t u(s, \omega) ds + \int_0^t \nu(s, \omega) dW_s,$$

visto como una integral de los procesos u, ν con límite de integración t y para cada $\omega \in \Omega$. Esta integral es la idea detrás de la siguiente definición.

Definición 2.5.3 (Proceso de Itô). Un proceso de Itô es un proceso $X = X_t^x$ en el espacio $(\Omega, \mathcal{F}, \mathbb{P})$ que satisfaga la siguiente ecuación integral

$$X_t^x(\omega) = x + \int_0^t u(s, \omega) ds + \int_0^t \nu(s, \omega) dW_s,$$

cuyos coeficientes cumplen la condición de integrabilidad $u \in \mathcal{L}_{LOC}$ y $\nu \in \mathcal{L}_{LOC}^2$ es decir,

$$\mathbb{P} \left[\int_0^T |u(t, \omega)| dt < \infty \right] = 1,$$

y

$$\mathbb{P} \left[\int_0^T \nu^2(t, \omega) dt < \infty \right] = 1.$$

En forma diferencial, este proceso se describe por la siguiente ecuación diferencial estocástica

$$dX_t = u dt + \nu dW_t.$$

A continuación enunciamos la Fórmula de Itô, la cual muestra que los procesos de Itô son estables bajo transformaciones suaves.

Teorema 2.5.4 (Fórmula de Itô). Sea X_t un proceso de Itô de la forma

$$dX_t = u dt + \nu dW_t.$$

Sea $g(t, x) \in C^2([0, \infty) \times \mathbb{R})$. Entonces, $Y = g(t, X)$ cumple la siguiente identidad

$$dY_t = \frac{\partial g}{\partial t}(t, X_t)dt + \frac{\partial g}{\partial x}(t, X_t)dX_t + \frac{1}{2} \frac{\partial^2}{\partial x^2} g(t, X_t) \cdot (dX_t)^2, \quad (2.25)$$

donde $(dX_t)^2 = (dX_t) \cdot (dX_t)$ se calcula conforme a las reglas de Itô-McKean:

$$dt \cdot dt = dt \cdot dW_t = dW_t \cdot dt = 0 \quad dW_t \cdot dW_t = dt.$$

Estas reglas representan identidades de covariación cuadrática: $[W]_t = t$, $[t, W]_t = 0$ y $[t]_t = 0$. Un proceso continuo de variación finita tiene variación cuadrática nula y covariación nula con las martingalas continuas. Por ello, si $dX_t = b_t dt + \sigma_t dW_t$, entonces $d[X]_t = \sigma_t^2 dt$. El término de segundo orden de la fórmula de Itô proviene de esta variación cuadrática; las reglas anteriores no son productos de diferenciales ordinarios.

La Fórmula de Itô nos permite resolver ecuaciones diferenciales estocásticas, cuya teoría se extiende a aquellas cuyos coeficientes sean funciones del tiempo t y el estado del proceso X_t , las cuales son de la forma

$$dX_t = b(t, X_t)dt + \sigma(t, X_t)dW_t. \quad (2.26)$$

A continuación definimos el significado de los distintas nociones de existencia y unicidad para las soluciones de una ecuación diferencial estocástica de la forma (2.26).

Definición 2.5.5. Para la ecuación (2.26), se dice que tiene

1. Una solución con existencia en un sentido débil, si para cada $x \in \mathbb{R}$ existe un proceso de Itô X que la satisfaga.
2. Una solución con existencia débil y unicidad débil si además, para cada $x \in \mathbb{R}$, todas las soluciones tienen la misma ley.
3. Una solución con unicidad de trayectorias si, para un espacio de probabilidad fijo $(\Omega, \mathcal{F}, (\mathcal{F}_t), \mathbb{P})$ y un mismo movimiento browniano W definido con respecto a $(\mathcal{F}_t)$, cualesquiera dos soluciones X, Y que cumplan $X_0 = Y_0$ son indistinguibles.
4. Una solución fuerte si X es adaptado con respecto a la filtración browniana estándar de W .

El siguiente resultado es clásico y nos da las condiciones usuales bajo las cuales se tiene la existencia y unicidad en trayectoria de las soluciones de las ecuaciones diferenciales estocásticas.

Teorema 2.5.6 (Teorema de existencia y unicidad para Ecuaciones Diferenciales Estocásticas). Sea $T > 0$ y $b(\cdot, \cdot) : [0, T] \times \mathbb{R} \mapsto \mathbb{R}$, $\sigma(\cdot, \cdot) : [0, T] \times \mathbb{R} \mapsto \mathbb{R}$ funciones medibles que

satisfacen la condición de crecimiento lineal:

$$|b(t, x)| + |\sigma(t, x)| \leq C(1 + |x|); \quad x \in \mathbb{R}, t \in [0, T], \quad (2.27)$$

para cierta constante C , así como la condición de Lipschitz

$$|b(t, x) - b(t, y)| + |\sigma(t, x) - \sigma(t, y)| \leq D|x - y|; \quad x \in \mathbb{R}, t \in [0, T], \quad (2.28)$$

para cierta constante D . Sea Z una variable aleatoria que es independiente de la sigma-álgebra $\mathcal{F}_\infty^0 = \sigma(W_s(\cdot), s \geq 0)$ tal que

$$\mathbb{E}[|Z|^2] < \infty.$$

Entonces, la ecuación diferencial estocástica

$$dX_t = b(t, X_t)dt + \sigma(t, X_t)dW_t; \quad 0 \leq t \leq T, X_0 = Z, \quad (2.29)$$

tiene una solución fuerte única (salvo indistinguibilidad), continua respecto a t , $X_t(\omega)$, con la propiedad de que $X_t(\omega)$ es adaptado a la filtración $\mathcal{F}_t^Z$ generada por Z y $(W_s(\cdot), s \leq t)$ y

$$\mathbb{E} \left[\int_0^T |X_t|^2 dt \right] < \infty. \quad (2.30)$$

Corolario 2.5.7. *Bajo las hipótesis del teorema anterior, si además*

$$\mathbb{E}[|Z|^{2r}] < \infty,$$

para algún $r \geq 1$, entonces tenemos, para cada $T > 0$, las siguientes desigualdades

$$\mathbb{E} \left[\sup_{0 \leq t \leq T} |X_t|^{2r} \right] \leq K(1 + \mathbb{E}[|Z|^{2r}])e^{KT} \quad (2.31)$$

$$\mathbb{E} \left[\sup_{0 \leq t \leq T} |X_t - Z|^{2r} \right] \leq \hat{K}T^r(1 + \mathbb{E}[|Z|^{2r}]), \quad (2.32)$$

donde $K, \hat{K}$ dependen de T , de r y de las constantes de las hipótesis sobre los coeficientes, pero no de Z .

Al igual que las ecuaciones diferenciales ordinarias, existen algunas ecuaciones diferenciales estocásticas de importancia particular, que tienen soluciones cuyas distribuciones se pueden expresar en términos de fórmulas cerradas. El ejemplo que aquí vamos a presentar es el movimiento browniano geométrico, el cual es uno de los modelos más recurridos en muchas aplicaciones.

Ejemplo 2.5.8 (Movimiento Browniano Geométrico). Sea la ecuación diferencial estocástica con valores en $\mathbb{R}$

$$dX_t = bX_t dt + \sigma X_t dW_t \quad (2.33)$$

$$X_0 = x_0 \in \mathbb{R}. \quad (2.34)$$

Vamos a resolverla por medio de la fórmula de Itô. Primero notemos que podemos reescribir la ecuación de la siguiente forma:

$$\frac{dX_t}{X_t} = bdt + \sigma dW_t.$$

Asumiendo la condición de que X sea positivo, en forma integral, esto se ve así:

$$\int_0^t \frac{dX_s}{X_s} = bt + \sigma W_t.$$

El lado izquierdo nos recuerda entonces la derivada del logaritmo. Vamos a proponer $g(t, x) = \ln(x)$ para $x > 0$ y a esta función le aplicamos la fórmula de Itô:

$$\begin{aligned} d(\ln X_t) &= \frac{1}{X_t} dX_t + \frac{1}{2} \left(-\frac{1}{X_t^2} \right) (dX_t)^2 \\ &= \frac{dX_t}{X_t} - \frac{1}{2X_t^2} \sigma^2 X_t^2 dt \\ &= \frac{dX_t}{X_t} - \frac{1}{2} \sigma^2 dt, \end{aligned}$$

puesto que aplicando las reglas de Itô-McKean a dX tenemos que $(dX)^2 = \sigma^2 X_t^2 dt$. Dado lo anterior despejamos para dX_t/X_t ,

$$\frac{dX_t}{X_t} = d(\ln X_t) + \frac{1}{2} \sigma^2 dt,$$

y sustituyéndolo en la forma integral de la ecuación diferencial estocástica, obtenemos lo siguiente:

$$\begin{aligned} \int_0^t \left[d(\ln X_s) + \frac{1}{2} \sigma^2 ds \right] &= bt + \sigma W_t \\ \ln X_t - \ln X_0 + \frac{1}{2} \sigma^2 t &= bt + \sigma W_t, \end{aligned}$$

es decir,

$$\ln \frac{X_t}{X_0} = (b - \frac{1}{2} \sigma^2)t + \sigma W_t,$$




Figura 2.2: Simulación por computadora de una trayectoria de un movimiento browniano geométrico que inicia en $X_0 = 1$

y finalmente encontramos el proceso X que resuelve la ecuación diferencial estocástica propuesta:

$$X_t = X_0 \exp\left(\left(b - \frac{1}{2}\sigma^2\right)t + \sigma W_t\right). \quad (2.35)$$

Una aplicación directa de la fórmula de Itô nos proporciona una representación útil de la esperanza de una función cuyo argumento es la solución de una ecuación diferencial estocástica.

Lema 2.5.9. *Sea $Y = Y_t^x$ la solución de una ecuación diferencial estocástica en $\mathbb{R}$ de la forma*

$$Y_t^x(\omega) = x + \int_0^t b(s, \omega) ds + \int_0^t \sigma(s, \omega) dW_s,$$

donde W es un movimiento browniano. Sean $f \in C_K^2(\mathbb{R})$, y sea τ un tiempo de paro respecto a la filtración $\mathcal{F}_t$, cuya esperanza sea finita: $\mathbb{E}^x(\tau) < \infty$. Asumiremos que b y σ sean acotados en el conjunto de (t, ω) tales que $Y(t, \omega)$ pertenece al soporte de f . Entonces

$$\mathbb{E}^x[f(Y_\tau)] = f(x) + \mathbb{E}^x \left[\int_0^\tau \left(b(s, \omega) \frac{\partial f}{\partial x}(Y_s) + \frac{1}{2} \sigma^2(s, \omega) \frac{\partial^2 f}{\partial x^2}(Y_s) \right) ds \right].$$

2.6. Difusiones de Itô

En el presente trabajo, vamos a definir los procesos de difusión de Itô como procesos de Itô que resuelven una clase de ecuaciones diferenciales estocásticas, cuyos coeficientes

satisfacen ciertas condiciones de crecimiento más restringidas. Por lo tanto, no todos los procesos de Itô son difusiones.

En ese sentido nos concentraremos en analizar el caso de difusiones en $\mathbb{R}$ con coeficientes homogéneos respecto al tiempo, como se define a continuación. Esta sección se basa en resultados obtenidos en el libro [29] cap. 7 sec. 1-4 y cap. 8 sec. 1.

Cabe señalar que la definición precisa de un proceso de difusión difiere en la literatura. Algunos autores los definen como procesos de Markov que cumplen ciertas propiedades particulares y plantean la definición a partir de la relación que existe entre su familia de kernels de probabilidad de transición y el generador infinitesimal. Véase, por ejemplo [16], cap. 6.

Definición 2.6.1. Una difusión de Itô (homogénea respecto al tiempo) es un proceso estocástico $X = X_t(\omega) = X(t, \omega) : [0, \infty) \times \Omega \mapsto \mathbb{R}$ que satisface una ecuación diferencial estocástica de la forma:

$$dX_t = b(X_t)dt + \sigma(X_t)dW_t, \quad (2.36)$$

donde $X_0 = x, t \geq 0$, $W = (W_t)_{t \geq 0}$ es un movimiento browniano y $b : \mathbb{R} \mapsto \mathbb{R}$, $\sigma : \mathbb{R} \mapsto \mathbb{R}$ satisfacen la siguiente condición de continuidad de Lipschitz:

$$|b(x) - b(y)| + |\sigma(x) - \sigma(y)| \leq D|x - y|, \quad (2.37)$$

para $x, y \in \mathbb{R}$ y cierta constante D .

A partir del siguiente teorema, cuya demostración se sigue del lema de representación de la esperanza al final de la sección anterior, haciendo $\tau = t$, y de la definición del generador infinitesimal L , podemos enunciar la fórmula explícita del generador L de una difusión de Itô. Además, el generador se encuentra representado explícitamente en la fórmula de Itô aplicada a una difusión X .

Teorema 2.6.2 (Generador infinitesimal de la difusión de Itô). *Sea X una difusión de Itô que cumpla la siguiente ecuación diferencial estocástica*

$$dX_t = b(X_t)dt + \sigma(X_t)dW_t. \quad (2.38)$$

Si $f \in C_K^2(\mathbb{R})$ entonces $f \in \mathcal{D}_L$ y

$$Lf(x) = b(x)\frac{\partial f}{\partial x} + \frac{1}{2}\sigma(x)^2\frac{\partial^2 f}{\partial x^2}. \quad (2.39)$$

Además, para cualquier $f \in C^2$:

$$f(X_t) = f(X_0) + \int_0^t \frac{\partial f}{\partial x}(X_s)\sigma(X_s)dW_s + \int_0^t Lf(X_s)ds, \quad (2.40)$$

donde

$$\int_0^t \frac{\partial f}{\partial x}(X_s) \sigma(X_s) dW_s, \quad (2.41)$$

es una martingala local.

Si combinamos los dos resultados anteriores tenemos la siguiente fórmula, que resultará de gran utilidad después.

Teorema 2.6.3 (Fórmula de Dynkin). *Sea $f \in C_K^2(\mathbb{R})$, y supongamos τ es un tiempo de paro, $\mathbb{E}[\tau] < \infty$. Entonces*

$$\mathbb{E}^x(f(X_\tau)) = f(x) + \mathbb{E}^x\left(\int_0^\tau Lf(X_s)ds\right). \quad (2.42)$$

Teorema 2.6.4 (Propiedad fuerte de Markov para difusiones). *Sea $f \in \mathcal{B}(\mathbb{R}^n)_b$, y τ un tiempo de paro respecto de la filtración $\mathcal{F}_t^{(m)}$ que cumpla que $\tau < \infty$ casi seguramente. Entonces*

$$\mathbb{E}^x(f(X_{\tau+h})|\mathcal{F}_\tau^{(m)}) = \mathbb{E}^{X_\tau}[f(X_h)], \quad (2.43)$$

para todo $h \geq 0$.

De la propiedad fuerte de Markov se sigue que también cumplen la propiedad débil de Markov.

Las demostraciones de estas propiedades se pueden consultar en [29], pp. 109-113.

Finalmente, citamos este importante resultado que nos dice que las funciones de transición satisfacen las ecuaciones hacia atrás y hacia adelante de Kolmogorov.

Teorema 2.6.5 (Ecuaciones hacia atrás y hacia adelante de Kolmogorov). *Sea $f \in C_K^2$, y definamos*

$$u(t, x) := \mathbb{E}^x[f(X_t)] = P_t f(x). \quad (2.44)$$

Entonces, $u(t, \cdot) \in \mathcal{D}_L$ y se satisface la siguiente ecuación, conocida como ecuación hacia atrás de Kolmogorov:

$$\frac{\partial}{\partial t} P_t f(x) = L P_t f(x) \quad t > 0, x \in \mathbb{R}, \quad (2.45)$$

es decir

$$\frac{\partial u}{\partial t} = Lu \quad t > 0, x \in \mathbb{R}, \quad (2.46)$$

con la condición inicial $u(0, x) = f(x)$

Aquí interpretamos que el operador diferencial L se aplica a la función $x \mapsto u(t, x)$.

Por otra parte, también se satisface la siguiente identidad del semigrupo sobre funciones:

$$\frac{\partial}{\partial t} P_t f(x) = P_t L f(x) \quad t > 0, x \in \mathbb{R}, \quad (2.47)$$

es decir

$$\frac{\partial u}{\partial t} = \mathbb{E}^x[Lf(X_t)]. \quad (2.48)$$

Cuando la ley del proceso admite una densidad ρ con la regularidad necesaria, su evolución está descrita por el adjunto del generador:

$$\partial_t \rho = L^* \rho = -\partial_x(b\rho) + \frac{1}{2} \partial_x^2(\sigma^2 \rho).$$

Esta es la ecuación hacia adelante de Kolmogorov o de Fokker–Planck; se obtiene por dualidad e integración por partes con las condiciones de frontera pertinentes.

Enunciaremos la versión del teorema de Girsanov para difusiones de Itô

Teorema 2.6.6 (Girsanov). Sean $X = X_t^x$ una difusión de Itô de la forma

$$dX_t = b(X_t)dt + \sigma(X_t)dW_t; \quad t \leq T, \quad X_0 = x, \quad (2.49)$$

y $Y = Y_t^x$ un proceso que sea solución de la siguiente ecuación diferencial estocástica,

$$dY_t = [\gamma(t, \omega) + b(Y_t)]dt + \sigma(Y_t)dW_t; \quad t \leq T, Y_0 = x, \quad (2.50)$$

donde las funciones $b : \mathbb{R}^d \rightarrow \mathbb{R}^d$ y $\sigma : \mathbb{R}^d \rightarrow \mathbb{R}^{d \times m}$ satisfacen la condición de Lipschitz de las difusiones de Itô, con $\gamma(t, \omega)$ Itô-integrable y $x \in \mathbb{R}^d$. Supongamos que existe un proceso Itô-integrable $u(t, \omega)$, de tal manera que

$$\sigma(Y_t)u(t, \omega) = \gamma(t, \omega).$$

Sea entonces

$$L_t := \int_0^t u(s, \omega) dW_s, \quad (2.51)$$

y supongamos que se cumple la condición de Novikov

$$\mathbb{E} \left[\exp \left(\frac{1}{2} \int_0^T |u(s, \omega)|^2 ds \right) \right] < \infty. \quad (2.52)$$

Definamos entonces el proceso

$$D_t = \exp \left(- \int_0^t u(s, \omega) dW_s - \frac{1}{2} \int_0^t |u(s, \omega)|^2 ds \right),$$

y definamos la medida $\mathbb{Q}$ en $(\Omega, \mathcal{F}_T^{(m)})$ a través de la derivada de Radon-Nikodym

$$d\mathbb{Q}(\omega) = D_T(\omega)d\mathbb{P}(\omega) \quad \text{en } \mathcal{F}_T^{(m)}. \quad (2.53)$$

Entonces, el proceso

$$\widehat{W}_t := \int_0^t u(s, \omega) ds + W_t; \quad t \leq T, \quad (2.54)$$

es un movimiento browniano respecto a $\mathbb{Q}$, y Y tiene por lo tanto la siguiente representación en términos del proceso $\widehat{W}$:

$$dY_t = b(Y_t)dt + \sigma(Y_t)d\widehat{W}(t), \quad (2.55)$$

y además, la $\mathbb{Q}$ -ley del proceso Y^x es la misma que la $\mathbb{P}$ -ley del proceso X^x , para $t \leq T$, es decir,

$$\mathbb{E}_{\mathbb{P}}^x[f_1(X_{t_1}) \cdots f_k(X_{t_k})] = \mathbb{E}_{\mathbb{Q}}^x[f_1(Y_{t_1}) \cdots f_k(Y_{t_k})], \quad (2.56)$$

para toda colección de $f_1, \dots, f_k \in C_K(\mathbb{R}^d)$.

La demostración de este importante resultado puede consultarse en [29], pp.155-158.

Una aplicación típica del teorema de Girsanov es la obtención de soluciones con existencia débil para ecuaciones diferenciales estocásticas, utilizando una transformación de medida para encontrar la solución a partir de otra ecuación diferencial estocástica que resulte más conveniente.

El ejemplo canónico de este proceso es el procedimiento de “cambio de tendencia” de una ecuación diferencial estocástica, el cual explicamos a continuación.

Ejemplo 2.6.7 (Cambio de tendencia de una ecuación diferencial estocástica). Sea Y_t una solución conocida, en un sentido fuerte, de la siguiente ecuación diferencial estocástica

$$dY_t = b(Y_t)dt + \sigma(Y_t)dW_t, \quad (2.57)$$

donde b y σ son como en el teorema 2.6.6. Buscamos una solución X_t , con existencia en el sentido débil, de una ecuación de la forma

$$dX_t = a(X_t)dt + \sigma(X_t)dW_t, \quad (2.58)$$

donde el coeficiente de tendencia es una función $a : \mathbb{R} \mapsto \mathbb{R}$. Supongamos que tenemos una función $u_0 : \mathbb{R} \mapsto \mathbb{R}$ tal que cumpla

$$\sigma(y)u_0(y) = b(y) - a(y) \quad \forall y \in \mathbb{R}. \quad (2.59)$$

Entonces, si $u(t, \omega) = u_0(Y_t(\omega))$ satisface la condición de Novikov, tenemos $\mathbb{Q}$ y $\widehat{W}$ como en

el teorema 2.6.6, con lo cual se satisface la ecuación

$$dY_t = a(Y_t)dt + \sigma(Y_t)d\widehat{W}_t. \quad (2.60)$$

Así, hemos encontrado un movimiento browniano $\widehat{W}$ con respecto a una medida $\mathbb{Q}$, el cual nos permite calcular la solución X de la ecuación (2.58), a partir de la solución Y de la ecuación conocida (2.57).

Capítulo 3

Fórmulas de Feynman-Kac

3.1. Proceso de Feynman-Kac

Como notamos en la introducción, el problema de valores a la frontera que tiene una representación de Feynman-Kac, corresponde a una ecuación de difusión modificada.

Cuando la ecuación de difusión es de la forma $u_t = (L - k)u$, donde L es el generador infinitesimal de una difusión de Itô y $k : \mathbb{R} \mapsto \mathbb{R}^+$, tenemos un caso especial de lo que se conoce como una difusión exponencialmente matada. Nuestra exposición se basa principalmente en el material contenido en [11], capítulo 5, sección 2; [29], cap. 8 sec. 2; [16], cap.6, sección 1 y ejercicio 6.26; [41] cap.5 sec.5.

En dicho proceso las partículas son aniquiladas conforme a una función de intensidad de muerte k , con una distribución de supervivencia de tipo exponencial. Consideraremos que se trata de un proceso de difusión que toma valores en $E = \mathbb{R}$, de tal modo que $(E, \mathcal{E}) = (\mathbb{R}, \mathcal{B}(\mathbb{R}))$.

Vamos a definir el proceso de difusión matado $\hat{X}$ como sigue

Definición 3.1.1 (Proceso de Feynman-Kac). Sean t en $\mathbb{R}^+$, ω en Ω , y X un proceso de difusión de Itô, que satisface la siguiente ecuación diferencial estocástica:

$$dX_t = \mu(X_t)dt + \sigma(X_t)dW_t, \quad (3.1)$$

donde $\mu : \mathbb{R} \mapsto \mathbb{R}$ y $\sigma : \mathbb{R} \mapsto \mathbb{R}$ cumplen la propiedad de Lipschitz:

$$|\mu(x) - \mu(y)| + |\sigma(x) - \sigma(y)| \leq D|x - y|,$$

para cierta constante D , así como la propiedad de crecimiento lineal:

$$|\mu(x)| + |\sigma(x)| \leq C(1 + |x|); \quad x \in \mathbb{R}, t \in [0, T],$$

para cierta constante $C > 0$.

Sea $k : \mathbb{R} \rightarrow [0, \infty)$ medible, con $\int_0^t k(X_s)ds < \infty$ casi seguramente para todo $t < \infty$. Sea T una variable aleatoria independiente del proceso X , con distribución exponencial estándar:

$$T \sim \exp(1). \quad (3.2)$$

Es decir, para $x \geq 0$, $\mathbb{P}(T \leq x) = 1 - e^{-x}$.

El proceso de difusión exponencialmente matado $\hat{X}$, con intensidad de muerte k , al cual llamaremos **proceso de Feynman-Kac**, se define como sigue:

$$\hat{X}_t = \begin{cases} X_t(\omega) & \text{si } T(\omega) > \int_0^t k(X_s(\omega))ds \\ \dagger & \text{en otro caso} \end{cases}, \quad (3.3)$$

donde $\dagger$ es un punto fuera de $\mathbb{R}$. Esto define un proceso $\hat{X}$ con espacio de estados $\bar{\mathbb{R}} = \mathbb{R} \cup \{\dagger\}$.

$\dagger$ es llamado el estado de cementerio, puesto que en el momento en que llega a este estado el proceso se queda allí para todo tiempo futuro.

El tiempo

$$\zeta = \inf\{t \in \mathbb{R}^+ : \hat{X}_t = \dagger\}, \quad (3.4)$$

representa el instante en que X es matado y enviado al cementerio.

Con esta definición hemos establecido que las partículas de la difusión serán “matadas” en el tiempo de muerte ζ .

Se sabe (véase [11] cap. 5 sec.2) que para $\mathcal{F}_\infty^X = \sigma(X_u : u \geq 0)$

$$\mathbb{P}[\zeta > t | \mathcal{F}_\infty^X] = e^{-\int_0^t k(X_s)ds}. \quad (3.5)$$

Dado lo anterior, también se sabe, por la misma referencia, que

$$\hat{P}_t(x, E) = 1 - \mathbb{P}^x\{\zeta \leq t\}.$$

Lema 3.1.2. Sea $(\bar{\mathbb{R}}, \mathcal{E})$ donde $\bar{\mathbb{R}} = \mathbb{R} \cup \{\dagger\}$ y $\mathcal{E} = \sigma(\mathcal{B}(\mathbb{R}) \cup \{\{\dagger\}\})$. Sea $\dagger$ tal que para toda f en $\mathcal{E}^+$, se defina $f(\dagger) = 0$.

Entonces, el proceso $\hat{X}$ tiene el siguiente kernel de transición:

$$\hat{P}_t f(x) = \mathbb{E}^x \left[f(X_t) e^{-\int_0^t k(X_s)ds} \right]. \quad (3.6)$$

Demostración. Recordemos que $(\mathbb{R}, \mathcal{E})$ es el espacio donde el proceso “está vivo” y el punto $\dagger$ es el cementerio. Entonces, condicionando con $\mathcal{F}_\infty^X$ y retomando las identidades antes citadas,

tenemos lo siguiente

$$\begin{aligned}
 \hat{P}_t f(x) &:= \mathbb{E}^x[f(\hat{X}_t)] \\
 &= \mathbb{E}^x[f(X_t)1_{\{\zeta > t\}}] \\
 &= \mathbb{E}^x[f(X_t)\mathbb{E}[1_{\{\zeta > t\}}|\mathcal{F}_\infty^X]], \\
 &= \mathbb{E}^x[f(X_t)\mathbb{P}[\zeta > t|\mathcal{F}_\infty^X]] \\
 &= \mathbb{E}^x \left[f(X_t) e^{-\int_0^t k(X_s) ds} \right]
 \end{aligned}$$

con f en $\mathcal{E}^+$ y t en $\mathbb{R}^+$, y x en $\bar{\mathbb{R}}$.

Por otra parte, $\hat{X}$ es un proceso de Markov en $(\bar{\mathbb{R}}, \bar{\mathcal{E}})$ y por lo mismo, $(\hat{P}_t)$ debe ser un semigrupo de operadores de transición, es decir

$$\hat{P}_{s+t}f = \hat{P}_t(\hat{P}_s f), \quad (3.7)$$

para toda $f \in \mathcal{E}$ y $t, s > 0$: Este semigrupo es llamado **semigrupo de Feynman-Kac**.

La verificación de su propiedad de semigrupo se puede hacer condicionando con $\sigma(X_s)$ y utilizando la propiedad de torre de la esperanza condicional. Para más detalle, véase [41], cap. 5, sec.5, pp.385 a 396. $\square$

En la interpretación que corresponde a una difusión cuyas partículas son matadas, la función $P_t f(x) = u(t, x)$ determinada por el semigrupo de Feynman-Kac, representa el promedio de partículas, o trayectorias, que sobreviven al proceso de muerte.




Figura 3.1: En el proceso de Feynman-Kac, $u(t, x)$ es el promedio de $f(X_t)$, tomado sobre todas las trayectorias del proceso que sobreviven a tiempo t .

Vamos a demostrar ahora que si una difusión de Ito X tiene un generador L , el proceso de Feynman-Kac asociado a dicha difusión tiene generador $L - k$, el cual corresponde a la ecuación de difusión con disipación, un caso particular de las ecuaciones de difusión modificadas. La técnica de demostración que se presenta a continuación la utilizaremos para demostrar otras variaciones particulares de las fórmulas de Feynman-Kac.

Teorema 3.1.3 (Fórmula de Feynman-Kac para la ecuación de difusión con disipación). *Sea el siguiente problema de valores iniciales*

$$\frac{\partial u}{\partial t} = (L - k)u, \quad (3.8)$$

con condición inicial $u(0, x) = f(x)$, $f \in \mathcal{B}(\mathbb{R})_b$, $k \in \mathcal{B}(\mathbb{R})^+$. y L tal que

$$Lf(x) = \mu(x) \frac{\partial f}{\partial x} + \frac{1}{2} \sigma(x)^2 \frac{\partial^2 f}{\partial x^2}, \quad (3.9)$$

donde $\mu : \mathbb{R} \mapsto \mathbb{R}$ y $\sigma : \mathbb{R} \mapsto \mathbb{R}$ cumplen la propiedad de Lipschitz:

$$|\mu(x) - \mu(y)| + |\sigma(x) - \sigma(y)| \leq D|x - y|,$$

para cierta constante D , así como la propiedad de crecimiento lineal:

$$|\mu(x)| + |\sigma(x)| \leq C(1 + |x|); \quad x \in \mathbb{R}, t \in [0, T],$$

para cierta constante $C > 0$.

Entonces, si $u \in C^{1,2}((0, \infty) \times \mathbb{R}) \cap C([0, \infty) \times \mathbb{R})$ es una solución acotada del problema de valores iniciales y $k(X_s)$ es localmente integrable en el tiempo, u admite la siguiente

representación

$$u(t, x) = \hat{P}_t f(x) = \mathbb{E}^x \left[f(X_t) e^{-\int_0^t k(X_s) ds} \right], \quad (3.10)$$

donde $\hat{P}_t$ es la función de transición de Feynman-Kac para una difusión de Itô $X = (X_t)_{t \geq 0}$, la cual es solución de la siguiente ecuación diferencial estocástica

$$dX_t = \mu(X_t)dt + \sigma(X_t)dW_t, \quad (3.11)$$

con condición inicial $X_0 = x$.

A la ecuación (3.8) se le conoce por ciertos autores (véase [36]) como la Ecuación de Feynman-Kac.

Demostración. Vamos a trabajar con un proceso $M = (M_s)_{s \geq 0}$ que definimos como se muestra a continuación. Sea, para $s < t$, con t fijo,

$$I_s = e^{-\int_0^s k(X_r) dr},$$

y

$$U_s = u(t - s, X_s),$$

con lo cual definimos

$$M_s := U_s I_s = u(t - s, X_s) e^{-\int_0^s k(X_r) dr}. \quad (3.12)$$

Vamos a mostrar que (M_s) es una martingala local.

En primer lugar, aplicando la fórmula de Ito a U_s , tenemos que

$$\begin{aligned} dU_s &= \frac{\partial u}{\partial x}(t - s, X_s) dX_s \\ &+ \frac{1}{2} \frac{\partial^2 u}{\partial x^2}(t - s, X_s) dX_s \cdot dX_s - \frac{\partial u}{\partial t}(t - s, X_s) ds \\ &= \frac{\partial u}{\partial x}(t - s, X_s) \sigma(X_s) dW_s \\ &+ \left\{ \frac{1}{2} \frac{\partial^2 u}{\partial x^2}(t - s, X_s) \sigma^2(X_s) + \frac{\partial u}{\partial x}(t - s, X_s) \mu(X_s) - \frac{\partial u}{\partial t}(t - s, X_s) \right\} ds. \end{aligned}$$

Puesto que $u(t, x)$ satisface la ecuación diferencial parcial 3.8 por hipótesis, tenemos que

$$\frac{\partial u}{\partial t} = \mu(x) \frac{\partial u}{\partial x} + \sigma(x)^2 \frac{1}{2} \frac{\partial^2 u}{\partial x^2} - k(x)u(t, x), \quad (3.13)$$

y sustituyendo resulta

$$dU_s = \frac{\partial u}{\partial x}(t - s, X_s) \sigma(X_s) dW_s + k(X_s)u(t - s, X_s) ds. \quad (3.14)$$

Por otra parte, para I_s tenemos

$$dI_s = (e^{-\int_0^s k(X_r)dr}) \cdot (-k(X_s)ds) = -I_s k(X_s)ds, \quad (3.15)$$

y aplicando la regla del producto de Ito a dM_s y notando que $dI_s \cdot dU_s = 0$, vemos que

$$\begin{aligned} dM_s &= I_s dU_s + U_s dI_s \\ &= I_s \left[\frac{\partial u}{\partial x}(t-s, X_s) \sigma(X_s) dW_s + k(X_s) u(t-s, X_s) ds \right] \\ &\quad - u(t-s, X_s) I_s k(X_s) ds \\ &= I_s \frac{\partial u}{\partial x}(t-s, X_s) \sigma(X_s) dW_s. \end{aligned}$$

Puesto que términos con el diferencial ds se anulan, el último renglón del anterior desarrollo nos dice que M es, efectivamente, una integral de Ito (escrita en notación diferencial):

$$dM_s = e^{-\int_0^s k(X_r)dr} \frac{\partial u}{\partial x}(t-s, X_s) \sigma(X_s) dW_s.$$

Además, M es una martingala local. Por la manera en que definimos M , dado que u y f son acotadas y k es no negativa,

$$\sup_{0 \leq s \leq t} |M_s| \leq \|u\|_\infty < \infty.$$

Entonces, la martingala local M es acotada, y por lo tanto una martingala.

Finalmente, como consecuencia de la propiedad de martingala, su esperanza es constante para cualquier tiempo que escojamos, así que en particular $\mathbb{E}^x(M_0) = \mathbb{E}^x(M_s)$. Como consecuencia de ello obtenemos que

$$\mathbb{E}^x[M_0] = u(t, x) = \mathbb{E}^x[M_t] = \mathbb{E}^x \left[f(X_t) e^{-\int_0^t k(X_s)ds} \right],$$

que es exactamente lo que se buscaba. □

Vamos ahora a demostrar fórmulas de Feynman-Kac en las cuales la función k no es necesariamente positiva. En dado caso, tales fórmulas ya no tienen la interpretación de un proceso matado, y la función adicional del problema de valores a la frontera modificado será una función acotada que llamaremos q .

3.2. Fórmulas de Feynman-Kac para ecuaciones de difusión modificadas

Si bien hemos establecido un teorema de representación para cierta clase de ecuaciones de difusión, por medio de un proceso de difusión matado, es posible utilizar las técnicas

del cálculo estocástico para encontrar fórmulas similares para ecuaciones de difusión más generales. El primer caso que discutiremos será el de la **ecuación de difusión modificada**.

A continuación trabajaremos con fórmulas de representación de Feynman-Kac para las soluciones de ecuaciones de difusión modificadas, las cuales son ecuaciones diferenciales parabólicas que tienen la siguiente forma:

$$\frac{\partial u}{\partial t}(t, x) = \frac{1}{2}\sigma^2(x)\frac{\partial^2 u}{\partial x^2}(t, x) + \mu(x)\frac{\partial u}{\partial x}(t, x) + q(x)u(t, x).$$

Dadas ciertas condiciones de crecimiento y acotamiento para los coeficientes de la ecuación, las cuales se plantean a detalle en cada una de las fórmulas obtenidas, vamos a describir brevemente y a grandes rasgos el impacto de cada uno de los términos de la ecuación.

El término de difusión, $\frac{1}{2}\sigma^2(x)\frac{\partial^2 u}{\partial x^2}(t, x)$, representa la manera en que $u(t, x)$ se esparce, dependiendo del coeficiente de difusividad $\sigma^2(x)$, el cual es espacialmente dependiente al ser una función de x .

El término de advección, $\mu(x)\frac{\partial u}{\partial x}(t, x)$, representa un movimiento direccional inducido por $\mu(x)$.

El término fuente/sumidero $q(x)u(t, x)$ representa una tasa de crecimiento (o decaimiento) que afecta a $u(t, x)$, la cual es espacialmente dependiente, puesto que $q(x)$ es una función de $x \in \mathbb{R}$. Cuando $q(x) > 0$, el término $q(x)u(t, x)$ es positivo, lo cual incrementa $\frac{\partial u}{\partial t}$.

Esto significa que las partes del dominio de $q(x)$ donde sea positiva actúan como fuentes que aumentan la densidad $u(t, x)$. Recíprocamente, en aquellas partes donde $q(x) < 0$, $\frac{\partial u}{\partial t}$ disminuye y en ellas la densidad se disipa. De ahí que $q(x)$ sea llamado un término de fuente o de disipación, dependiendo del signo que tenga $q(x)$.

La solución de la ecuación de difusión se plantea en términos de un problema de valores iniciales, en el cual se conoce el valor de la función en $t = 0$:

$$u(0, x) = f(x).$$

Dadas las condiciones sobre los coeficientes y las condiciones iniciales que enunciaremos para cada caso particular, esta clase de problemas está bien planteada, es decir, tiene solución, dicha solución es única y la solución depende continuamente de la condición inicial. Cabe destacar que el problema de valores finales, es decir, donde se conoce $u(T, x) = f(x)$, no está bien planteado con la ecuación de difusión dada.

Para un problema terminal bien orientado se considera $u_t + Lu + qu = 0$, con $u(T, x) = f(x)$. El cambio $v(\tau, x) = u(T - \tau, x)$ da

$$v_\tau = Lv + qv, \quad v(0, x) = f(x).$$

Finalmente, incorporaremos una fuente independiente de la solución. En la convención de

muerte $k \geq 0$, escribimos

$$u_t = Lu - ku + g.$$

Su versión estacionaria es el problema de Dirichlet-Poisson $(L - k)u = -g$ con un dato en la frontera. La función g , llamada aquí el lagrangiano, representa una fuente o un costo acumulado a lo largo de la trayectoria.

A continuación procederemos a demostrar la fórmula de Feynman-Kac que corresponde a la ecuación de difusión modificada con el termino $q(x)u(t, x)$. Esto lo lograremos profundizando el argumento proporcionado en [38], cap.15 sec.5.

Teorema 3.2.1 (Fórmula de Feynman-Kac para ecuaciones de difusión modificadas). *Sean $q, f \in \mathcal{B}(\mathbb{R})_b$, y sea $u(t, x)$ una solución clásica acotada, continua hasta el dato inicial, del problema de valores iniciales*

$$\frac{\partial u}{\partial t}(t, x) = \frac{1}{2}\sigma^2(x)\frac{\partial^2 u}{\partial x^2}(t, x) + \mu(x)\frac{\partial u}{\partial x}(t, x) + q(x)u(t, x), \quad (3.16)$$

con condición inicial $u(0, x) = f(x)$.

Si $\mu : \mathbb{R} \mapsto \mathbb{R}$ y $\sigma : \mathbb{R} \mapsto \mathbb{R}$ cumplen la propiedad de Lipschitz:

$$|\mu(x) - \mu(y)| + |\sigma(x) - \sigma(y)| \leq D|x - y|,$$

para cierta constante D , así como la propiedad de crecimiento lineal:

$$|\mu(x)| + |\sigma(x)| \leq C(1 + |x|); \quad x \in \mathbb{R}, t \in [0, T],$$

para cierta constante $C > 0$ entonces $u(t, x)$ tiene la siguiente representación:

$$u(t, x) = \mathbb{E}^x \left[f(X_t) e^{\int_0^t q(X_s) ds} \right], \quad (3.17)$$

donde $X = (X_t)$ es solución de la siguiente ecuación diferencial estocástica

$$dX_t = \mu(X_t)dt + \sigma(X_t)dW_t, \quad (3.18)$$

con condición inicial $X_0 = x$.

Demostración. De manera similar al procedimiento utilizado con el proceso de Feynman-Kac, vamos a trabajar con un proceso producto $M = (M_s)_{s \geq 0}$, que se define como sigue. Sean

$$I_s = e^{\int_0^s q(X_r) dr},$$

y

$$U_s = u(t - s, X_s),$$

con lo cual definimos

$$M_s := U_s I_s = u(t-s, X_s) e^{\int_0^s q(X_r) dr}. \quad (3.19)$$

Vamos a mostrar que (M_s) es una martingala local.

Ahora, aplicando la fórmula de Ito a U_s , tenemos que

$$\begin{aligned} dU_s &= \frac{\partial u}{\partial x}(t-s, X_s) dX_s \\ &+ \frac{1}{2} \frac{\partial^2 u}{\partial x^2}(t-s, X_s) dX_s \cdot dX_s - \frac{\partial u}{\partial t}(t-s, X_s) ds \\ &= \frac{\partial u}{\partial x}(t-s, X_s) \sigma(X_s) dW_s \\ &+ \left[\frac{1}{2} \frac{\partial^2 u}{\partial x^2}(t-s, X_s) \sigma^2(X_s) + \mu(X_s) \frac{\partial u}{\partial x}(t-s, X_s) - \frac{\partial u}{\partial t}(t-s, X_s) \right] ds. \end{aligned}$$

Puesto que $u(t, x)$ satisface 3.16 por hipótesis, tenemos que

$$dU_s = \frac{\partial u}{\partial x}(t-s, X_s) \sigma(X_s) dW_s - q(X_s) u(t-s, X_s) ds. \quad (3.20)$$

Por otra parte, para I_s tenemos

$$dI_s = \left[e^{\int_0^s q(X_r) dr} \right] q(X_s) ds = I_s q(X_s) ds, \quad (3.21)$$

y aplicando la regla del producto de Ito a dM_s y notando que $dI_s \cdot dU_s = 0$, vemos que

$$\begin{aligned} dM_s &= I_s dU_s + U_s dI_s \\ &= I_s \left[\frac{\partial u}{\partial x}(t-s, X_s) \sigma(X_s) dW_s - q(X_s) u(t-s, X_s) ds \right] \\ &+ u(t-s, X_s) I_s q(X_s) ds \\ &= I_s \frac{\partial u}{\partial x}(t-s, X_s) \sigma(X_s) dW_s. \end{aligned}$$

Puesto que los términos con el diferencial ds se cancelan, tenemos que M es una integral de Ito:

$$dM_s = e^{\int_0^s q(X_r) dr} \frac{\partial u}{\partial x}(t-s, X_s) \sigma(X_s) dW_s.$$

Por ende, M es una martingala local. Por la manera en que definimos M tenemos además que

$$\sup_{0 \leq s \leq t} |M_s| \leq \|u\|_\infty \exp(t\|q\|_\infty),$$

y como $\|u\|_\infty < \infty$, $\|q\|_\infty < \infty$ por la condición de que u y q sean acotadas, y en particular son acotadas bajo la norma $\|\cdot\|_\infty$, resulta entonces que la martingala local M es acotada, y por lo tanto una martingala.

Finalmente, como consecuencia de la propiedad de martingala, su esperanza es constante para cualquier tiempo que escojamos, así que en particular $\mathbb{E}^x(M_0) = \mathbb{E}^x(M_s)$. Como consecuencia de ello obtenemos que

$$\mathbb{E}^x[M_0] = u(t, x) = \mathbb{E}^x[M_t] = \mathbb{E}^x \left[f(X_t) e^{\int_0^t q(X_s) ds} \right],$$

que es exactamente lo que se buscaba. $\square$

3.3. Fórmula de Feynman-Kac para la ecuación de calor modificada

Vamos a estudiar el caso particular de la ecuación del calor modificada,

$$\frac{\partial u}{\partial t} = \frac{1}{2} \frac{\partial^2 u}{\partial x^2} + q(x)u(t, x),$$

cuya representación de Feynman-Kac utiliza el movimiento browniano como el proceso de difusión correspondiente. Para demostrarla, utilizaremos nuevamente la técnica de la martingala local, como se hace en [38] cap. 15 sec. 1.

Teorema 3.3.1 (Fórmula de Kac para el movimiento browniano). *Sean $q, f \in \mathcal{B}(\mathbb{R})_b$. Sea $u(t, x)$ una solución clásica acotada, continua hasta el dato inicial, de*

$$\frac{\partial u}{\partial t} = \frac{1}{2} \frac{\partial^2 u}{\partial x^2} + q(x)u(t, x), \quad (3.22)$$

con la condición a la frontera (inicial)

$$u(0, x) = f(x). \quad (3.23)$$

Entonces, $u(t, x)$ tiene la siguiente representación

$$u(t, x) = \mathbb{E}^x \left[f(W_t) e^{\int_0^t q(W_s) ds} \right], \quad (3.24)$$

donde $W = (W_t)$ es un movimiento browniano.

Demostración. Vamos a definir un proceso M de manera similar a como hemos hecho antes. Sean

$$I_s = e^{\int_0^s q(W_r) dr},$$

y

$$U_s = u(t - s, W_s).$$

Entonces,

$$M_s := U_s I_s = u(t-s, W_s) e^{\int_0^s q(W_r) dr}. \quad (3.25)$$

Por la fórmula de Itô aplicada a U_s , y notando que satisface la ecuación diferencial 3.22 vemos que

$$\begin{aligned} du(t-s, W_s) &= u_x(t-s, W_s) dW_s \\ &\quad + \frac{1}{2} u_{xx}(t-s, W_s) ds - u_t(t-s, W_s) ds \\ &= u_x(t-s, W_s) dW_s - q(W_s) u(t-s, W_s) ds, \end{aligned}$$

Por otra parte, para I_s tenemos

$$dI_s = \left[e^{\int_0^s q(W_r) dr} \right] q(W_s) ds = I_s q(W_s) ds, \quad (3.26)$$

y aplicando la regla del producto para $M_s = U_s \cdot I_s$ tenemos

$$\begin{aligned} &\exp\left(\int_0^s q(W_r) dr\right) \{u_x(t-s, W_s) dW_s - q(W_s) u(t-s, W_s) ds\} \\ &\quad + \exp\left(\int_0^s q(W_r) dr\right) \{q(W_s) u(t-s, W_s) ds\} \\ &= \exp\left(\int_0^s q(W_r) dr\right) \{u_x(t-s, W_s)\} dW_s. \end{aligned}$$

Por ende, M es una integral estocástica de Itô y por ende una martingala local. Además, como $\|u\|_\infty < \infty$ y $\|q\|_\infty < \infty$, tenemos

$$\sup_{0 \leq s \leq t} |M_s| \leq \|u\|_\infty \exp(t\|q\|_\infty),$$

Por lo tanto, M es acotada y por ende una martingala. Aplicando la propiedad de martingala nos da

$$\mathbb{E}^x[M_0] = u(t, x) = \mathbb{E}^x[M_t] = \mathbb{E}^x \left[f(W_t) \exp\left(\int_0^t q(W_s) ds\right) \right],$$

que es la representación buscada. □

3.4. Fórmulas de Feynman-Kac para problemas de tipo Dirichlet-Poisson

En esta sección demostramos una representación de Feynman-Kac para problemas de Dirichlet-Poisson. Usamos la convención de muerte $L - k$ y fuente g , como en el problema de Cauchy posterior. Nuestra exposición se basa en [4], cap. 40, y [24], cap. 21, sec. 3.

Teorema 3.4.1. *Sea $D \subset \mathbb{R}$ abierto y sea $u \in C^2(D) \cap C(\overline{D})$ una solución acotada del problema de valores a la frontera*

$$\mu(x)u'(x) + \frac{1}{2}\sigma^2(x)u''(x) - k(x)u(x) = -g(x), \quad x \in D, \quad (3.27)$$

con $u(y) = f(y)$ para $y \in \partial D$, $k \in C(\mathbb{R})$ no negativa, $f \in C(\partial D)$ y $g \in C(D)$. Sea X la difusión de Itô

$$dX_t = \mu(X_t)dt + \sigma(X_t)dW_t, \quad X_0 = x \in D,$$

y $\tau_D = \inf\{t \geq 0 : X_t \notin D\}$. Supongamos que

$$\mathbb{E}^x[\tau_D] < \infty, \quad \mathbb{E}^x \left[\int_0^{\tau_D} |g(X_s)|ds \right] < \infty.$$

Entonces

$$u(x) = \mathbb{E}^x \left[f(X_{\tau_D})e^{-\int_0^{\tau_D} k(X_s)ds} + \int_0^{\tau_D} g(X_s)e^{-\int_0^s k(X_r)dr} ds \right].$$

Demostración. Definamos $I_t = e^{-\int_0^t k(X_s)ds}$ y $M_t = I_t u(X_t)$ hasta la salida. Itô y la regla del producto dan

$$\begin{aligned} dM_s &= I_s(Lu - ku)(X_s)ds + I_s u'(X_s)\sigma(X_s)dW_s \\ &= -I_s g(X_s)ds + I_s u'(X_s)\sigma(X_s)dW_s. \end{aligned}$$

Por tanto, el proceso compensado

$$N_t = M_{t \wedge \tau_D} + \int_0^{t \wedge \tau_D} I_s g(X_s)ds$$

es una martingala local, extendida a la salida por continuidad. Puesto que $0 \leq I_s \leq 1$, todos sus valores detenidos están dominados por la variable integrable

$$\|u\|_\infty + \int_0^{\tau_D} |g(X_s)|ds.$$

Al retirar una localización mediante convergencia dominada, N es una martingala y

$$u(x) = \mathbb{E}^x \left[I_{t \wedge \tau_D} u(X_{t \wedge \tau_D}) + \int_0^{t \wedge \tau_D} I_s g(X_s)ds \right].$$

La esperanza finita de τ_D implica $\tau_D < \infty$ casi seguramente. La continuidad de X y de u hasta la frontera da $u(X_{\tau_D}) = f(X_{\tau_D})$. Haciendo $t \rightarrow \infty$ y usando la misma dominación obtenemos la fórmula. $\square$




Figura 3.2: Las partículas markovianas de la difusión X^x recorren aleatoriamente la región D , y eventualmente tienen dos posibles destinos: alcanzan la frontera ∂D en cierto tiempo finito τ_D , o sufren una muerte prematura en algún instante aleatorio y son transferidas al cementerio.

3.5. Fórmulas de Feynman-Kac para problemas de tipo Cauchy

Ahora, exploremos la conexión entre procesos de difusión de Ito y ecuaciones diferenciales parciales de tipo parabólico, con coeficientes que también dependen del tiempo. El primer caso lo vamos a resolver con la misma técnica utilizada hasta ahora, y vamos a resolver lo que se conoce como la ecuación parabólica hacia atrás, dada una condición terminal.

3.5.1. Fórmula de Feynman-Kac para la ecuación diferencial parabólica hacia atrás

Ahora vamos a resolver un caso especial de la EDP parabólica, que es una ecuación parabólica hacia atrás, donde en lugar de condición inicial $u(0, x) = f(x)$ usamos una condición terminal $u(T, x) = f(x)$. En este caso utilizaremos la técnica de la martingala local como se hace en [38] cap.15 sec.5, modificándola con un caso ligeramente diferente al que se presenta en dicho texto.

Teorema 3.5.1 (Fórmula de Feynman-Kac para la ecuación parabólica hacia atrás). *Sea $q : [0, T] \times \mathbb{R} \rightarrow [0, \infty)$ continua, $f \in C_b(\mathbb{R})$, y sea $u \in C^{1,2}([0, T] \times \mathbb{R}) \cap C([0, T] \times \mathbb{R})$ una*

solución acotada del problema de valores terminales

$$\frac{\partial u}{\partial t}(t, x) + \frac{1}{2}\sigma^2(t, x)\frac{\partial^2 u}{\partial x^2}(t, x) + \mu(t, x)\frac{\partial u}{\partial x}(t, x) - q(t, x)u(t, x) = 0 \quad (3.28)$$

$$u(T, x) = f(x). \quad (3.29)$$

Si $\mu : \mathbb{R}^+ \times \mathbb{R} \mapsto \mathbb{R}$ y $\sigma : \mathbb{R}^+ \times \mathbb{R} \mapsto \mathbb{R}$ cumplen la propiedad de Lipschitz:

$$|\mu(t, x) - \mu(t, y)| + |\sigma(t, x) - \sigma(t, y)| \leq D|x - y|,$$

para cierta constante D , así como la propiedad de crecimiento lineal:

$$|\mu(t, x)| + |\sigma(t, x)| \leq C(1 + |x|); \quad x \in \mathbb{R}, t \in [0, T],$$

para cierta constante $C > 0$ entonces $u(t, x)$ tiene la siguiente representación:

$$u(t, x) = \mathbb{E}^{t,x} \left[f(X_T) e^{-\int_t^T q(r, X_r) dr} \right], \quad (3.30)$$

donde $X = (X_t)$ es solución de la siguiente ecuación diferencial estocástica

$$dX_s = \mu(s, X_s)ds + \sigma(s, X_s)dW_s, \quad t \leq s \leq T, \quad (3.31)$$

con condición inicial $X_t = x$.

Demostración. Vamos a usar la técnica de la martingala local. Definamos, para $s > t$ con t fija, el proceso $M = (M_s)$

$$M_s = u(s, X_s^{t,x}) \cdot \exp\left(-\int_t^s q(r, X_r^{t,x})dr\right) = U_s I_s. \quad (3.32)$$

Entonces, desarrollamos dU conforme la fórmula de Itô, denotando las derivadas parciales de u con subíndices.

$$\begin{aligned} dU_s &= \{u_1(s, X_s^{t,x}) + \frac{1}{2}\sigma^2(s, X_s^{t,x})u_{22}(s, X_s^{t,x})\}ds + u_2(s, X_s^{t,x})dX_s^{t,x} \\ &= \{u_1(s, X_s^{t,x}) + \frac{1}{2}\sigma^2(s, X_s^{t,x})u_{22}(s, X_s^{t,x}) + u_2(s, X_s^{t,x})\mu(s, X_s^{t,x})\}ds \\ &\quad + u_2(s, X_s^{t,x})\sigma(s, X_s^{t,x})dW_s. \end{aligned}$$

Por otra parte,

$$dI_s = -I_s q(s, X_s^{t,x})ds.$$

Aplicando la regla del producto de Itô a M tenemos

$$\begin{aligned}
dM_s &= I_s dU_s + U_s dI_s \\
&= I_s \{dU_s - U_s q(s, X_s^{t,x}) ds\} \\
&= I_s \{u_1(s, X_s^{t,x}) + \frac{1}{2} \sigma^2(s, X_s^{t,x}) u_{22}(s, X_s^{t,x}) \\
&\quad + u_2(s, X_s^{t,x}) \mu(s, X_s^{t,x}) - u(s, X_s^{t,x}) q(s, X_s^{t,x})\} ds \\
&\quad + I_s u_2(s, X_s^{t,x}) \sigma(s, X_s^{t,x}) dW_s.
\end{aligned}$$

Por la hipótesis de que u satisface la ecuación diferencial parcial en 3.29, tenemos que todos los términos entre corchetes se cancelan y tenemos

$$dM_s = I_s u_2(s, X_s^{t,x}) \sigma(s, X_s^{t,x}) dW_s.$$

Por lo cual M es martingala local. Como q es no negativa y u es acotada por hipótesis, M es acotada y, por tanto, es martingala. Puesto que $M_t = u(t, x)$, al evaluar su esperanza en T obtenemos la representación (3.30):

$$\mathbb{E}^{t,x}[M_T] = \mathbb{E}^{t,x} \left[f(X_T) e^{-\int_t^T q(r, X_r) dr} \right] = M_t = u(t, x).$$

□

Observación 3.5.2. La ecuación diferencial parcial que acabamos de resolver corresponde a una generalización de la ecuación de Black-Scholes-Merton, que citaremos en la sección relativa a las aplicaciones en finanzas:

$$\frac{\partial u}{\partial t}(t, x) + \frac{1}{2} \sigma^2(t, x) \frac{\partial^2 u}{\partial x^2}(t, x) + \mu(t, x) \frac{\partial u}{\partial x}(t, x) - q(t, x) u(t, x) = 0. \quad (3.33)$$

3.5.2. Fórmula de Feynman-Kac para la ecuación diferencial parabólica no homogénea

De manera similar a como hicimos con el problema de Dirichlet-Poisson, vamos a considerar una ecuación diferencial parcial parabólica hacia atrás, con un lagrangiano que también depende del tiempo: $g = g(t, x)$. Nuestra demostración se basa en el caso expuesto en [41] cap.6 sec.3.

Teorema 3.5.3. *Sea $u = u(t, x)$ una solución del siguiente problema de valores terminales*

de Cauchy:

$$\frac{\partial u}{\partial t} + \frac{1}{2}\sigma^2 \frac{\partial^2 u}{\partial x^2} + \mu(t, x) \frac{\partial u}{\partial x} - k(t, x)u + g(t, x) = 0; (t, x) \in [0, T] \times \mathbb{R} \quad (3.34)$$

$$u(T, x) = f(x); x \in \mathbb{R}. \quad (3.35)$$

Supongamos que $f(x) : \mathbb{R} \mapsto \mathbb{R}$, $g(t, x) : [0, T] \times \mathbb{R} \mapsto \mathbb{R}$ y $k(t, x) : [0, T] \times \mathbb{R} \mapsto \mathbb{R}^+$ satisfacen las siguientes condiciones

1. $|f(x)| \leq L(1 + |x|^{2\lambda}); \quad \forall x \in \mathbb{R}$
2. $|g(t, x)| \leq L(1 + |x|^{2\lambda}); \quad \forall t \in [0, T], x \in \mathbb{R}$

para $L > 0, \lambda \geq 1$.

Además, supongamos que $\mu : \mathbb{R}^+ \times \mathbb{R} \mapsto \mathbb{R}$ y $\sigma : \mathbb{R}^+ \times \mathbb{R} \mapsto \mathbb{R}$ cumplen la propiedad de Lipschitz:

$$|\mu(t, x) - \mu(t, y)| + |\sigma(t, x) - \sigma(t, y)| \leq D|x - y|,$$

para cierta constante D , así como la propiedad de crecimiento lineal:

$$|\mu(t, x)| + |\sigma(t, x)| \leq C(1 + |x|); \quad x \in \mathbb{R}, t \in [0, T],$$

para cierta constante $C > 0$

Suponemos además que f, g, k son continuas en sus respectivos dominios. Si $u \in C^{1,2}([0, T] \times \mathbb{R}) \cap C([0, T] \times \mathbb{R})$ y u satisface la condición de crecimiento polinomial:

$$\max_{0 \leq t \leq T} |u(t, x)| \leq M(1 + |x|^{2r}),$$

para $M > 0, r \geq 1$, entonces u tiene la siguiente representación de Feynman-Kac:

$$u(t, x) = \mathbb{E}^{t,x} \left[f(X_T) e^{-\int_t^T k(u, X_u) du} + \int_t^T g(s, X_s) e^{-\int_t^s k(u, X_u) du} ds \right], \quad (3.36)$$

en $[0, T] \times \mathbb{R}$.

Demostración. Definamos $U_s = u(s, X_s^{t,x})$ e $I_s = e^{-\int_t^s k(u, X_u^{t,x}) du}$, por lo que el proceso producto $M_s = U_s I_s$ queda así:

$$(M_s)_{t \leq s \leq T} = u(s, X_s^{t,x}) e^{-\int_t^s k(u, X_u^{t,x}) du}. \quad (3.37)$$

Como hicimos en el caso anterior, desarrollamos dU y dI conforme la fórmula de Itô, deno-

tando las derivadas parciales de u con subíndices.

$$\begin{aligned} dU_s &= \{u_1(s, X_s^{t,x}) + \frac{1}{2}\sigma^2(s, X_s^{t,x})u_{22}(s, X_s^{t,x})\}ds + u_2(s, X_s^{t,x})dX_s^{t,x} \\ &= \{u_1(s, X_s^{t,x}) + \frac{1}{2}\sigma^2(s, X_s^{t,x})u_{22}(s, X_s^{t,x}) + u_2(s, X_s^{t,x})\mu(s, X_s^{t,x})\}ds \\ &\quad + u_2(s, X_s^{t,x})\sigma(s, X_s^{t,x})dW_s. \end{aligned}$$

Por otra parte,

$$dI_s = -I_s k(s, X_s^{t,x})ds.$$

dM_s queda entonces así

$$\begin{aligned} dM_s &= I_s dU_s + U_s dI_s \\ &= I_s \{dU_s - U_s k(s, X_s^{t,x})ds\} \\ &= I_s \{u_1(s, X_s^{t,x}) + \frac{1}{2}\sigma^2(s, X_s^{t,x})u_{22}(s, X_s^{t,x}) \\ &\quad + u_2(s, X_s^{t,x})\mu(s, X_s^{t,x}) - u(s, X_s^{t,x})k(s, X_s^{t,x})\}ds \\ &\quad + I_s u_2(s, X_s^{t,x})\sigma(s, X_s^{t,x})dW_s. \end{aligned}$$

Por la hipótesis de que u es solución del problema de valores terminales, los términos entre corchetes son iguales a $-g(s, X_s^{t,x})$ y tenemos que

$$dM_s = I_s [-g(s, X_s^{t,x})ds + u_2(s, X_s^{t,x})\sigma(s, X_s^{t,x})dW_s], \quad (3.38)$$

es decir

$$dM_s = e^{-\int_t^s k(u, X_u^{t,x})du} \left[-g(s, X_s^{t,x})ds + \frac{\partial u}{\partial x}(s, X_s^{t,x})\sigma(s, X_s^{t,x})dW_s \right]. \quad (3.39)$$

Consideremos la siguiente sucesión localizadora para el proceso X :

$$\tau_n = \inf(s \geq t : |X_s^{t,x}| \geq n) \wedge T. \quad (3.40)$$

Integrando dM_s entre t y τ_n , tenemos

$$M_{\tau_n} - M_t = - \int_t^{\tau_n} I_s g(s, X_s^{t,x})ds + \int_t^{\tau_n} I_s \frac{\partial u}{\partial x}(s, X_s^{t,x})\sigma(s, X_s^{t,x})dW_s.$$

Dado que $M_t = u(t, x)$,

$$M_{\tau_n} - u(t, x) = - \int_t^{\tau_n} I_s g(s, X_s^{t,x})ds + \int_t^{\tau_n} I_s \frac{\partial u}{\partial x}(s, X_s^{t,x})\sigma(s, X_s^{t,x})dW_s. \quad (3.41)$$

Para $n > |x|$, el proceso compensado $N_s = M_s + \int_t^s I_r g(r, X_r)dr$, detenido en τ_n , está

acotado por $M(1 + n^{2r}) + L(T - t)(1 + n^{2\lambda})$. Es, por tanto, una martingala. La continuidad hasta T permite alcanzar el extremo terminal sin suponer que u_x esté acotada allí. La integral estocástica de 3.41 tiene entonces esperanza cero y obtenemos:

$$\begin{aligned}\mathbb{E}^{t,x}[M_{\tau_n}] - u(t, x) &= -\mathbb{E}^{t,x} \left[\int_t^{\tau_n} I_s g(s, X_s) ds \right] \\ u(t, x) &= \mathbb{E}^{t,x}[M_{\tau_n}] + \mathbb{E}^{t,x} \left[\int_t^{\tau_n} I_s g(s, X_s) ds \right],\end{aligned}$$

es decir,

$$u(t, x) = \mathbb{E}^{t,x} \left[u(\tau_n, X_{\tau_n}) e^{-\int_t^{\tau_n} k(u, X_u) du} \right] + \mathbb{E}^{t,x} \left[\int_t^{\tau_n} g(s, X_s) e^{-\int_t^s k(u, X_u) du} ds \right]. \quad (3.42)$$

Ahora, por el corolario 2.5.7, tenemos la siguiente desigualdad:

$$\mathbb{E}^{t,x} \left[\sup_{t \leq s \leq T} |X_s|^{2m} \right] \leq C_m(t, T, x) < \infty, \quad (3.43)$$

la cual podemos utilizar para verificar la convergencia de τ_n usando la desigualdad de Markov:

$$\mathbb{P}^{t,x}(\tau_n < T) \leq \mathbb{P}^{t,x} \left(\sup_{t \leq s \leq T} |X_s| \geq n \right) \leq \frac{\mathbb{E}^{t,x} [\sup_{t \leq s \leq T} |X_s|^{2m}]}{n^{2m}} \leq \frac{C_m(t, T, x)}{n^{2m}}.$$

En el límite tenemos que

$$\lim_{n \rightarrow \infty} \frac{C_m(t, T, x)}{n^{2m}} = 0,$$

Además, por continuidad y no explosión, cada trayectoria está acotada en $[t, T]$, por lo que eventualmente $\tau_n = T$ casi seguramente.

Asimismo, 3.43 y la condición terminal implican que la sucesión formada con el primer término de 3.42 converge cuando $n \rightarrow \infty$ a:

$$\mathbb{E}^{t,x} \left[u(T, X_T) e^{-\int_t^T k(u, X_u) du} \right] = \mathbb{E}^{t,x} \left[f(X_T) e^{-\int_t^T k(u, X_u) du} \right].$$

El segundo término converge a

$$\mathbb{E}^{t,x} \left[\int_t^T g(s, X_s) e^{-\int_t^s k(u, X_u) du} ds \right],$$

por el teorema de convergencia dominada: los dos términos están dominados, respectivamente, por $M(1 + \sup_{t \leq s \leq T} |X_s|^{2r})$ y $L(T - t)(1 + \sup_{t \leq s \leq T} |X_s|^{2\lambda})$, integrables por el corolario 2.5.7. De la convergencia de ambos términos se sigue la ecuación 3.36, que es lo que se buscaba. $\square$

Observación 3.5.4. En el teorema anterior, es posible sustituir las condiciones de cota 1. y 2. para las funciones $f(x)$ y $g(t, x)$, por una condición de no negatividad: $f(x) \geq 0 \forall x \in \mathbb{R}$

y $g(t, x) \geq 0 \forall t \in [0, T], x \in \mathbb{R}$. En dicho caso se concreta el último paso de la demostración utilizando los teoremas de convergencia de martingalas. Véase [41], p.463.

Capítulo 4

Conexiones entre el proceso de Feynman-Kac y otras técnicas de condicionamiento y transformación de procesos estocásticos

Este capítulo discute la relación que tiene el proceso de Feynman-Kac con otros procesos especiales que se obtienen por medio de técnicas de condicionamiento de un proceso de difusión. Estudiaremos sus relaciones mediante semigrupos ponderados, condicionamiento y cambios de medida; para las difusiones con cambio de deriva utilizaremos el teorema de Girsanov.

El proceso de Feynman-Kac, como vimos en el capítulo 3, es obtenido a través de la modificación de la función de transición correspondiente a una difusión de Itô ordinaria, transformándolo en una difusión cuyas trayectorias son matadas a una cierta tasa exponencial.

Por otra parte, es posible modificar la función de transición de un proceso de Markov por medio de lo que se conoce como la h -transformada de Doob, donde usamos una cierta clase de funciones h , con el fin de condicionar el proceso para que tenga un comportamiento concreto.

Puesto que el condicionamiento de un proceso de Markov por medio de la h -transformada de Doob es un tema conceptualmente difícil, iniciamos con dos ejemplos de su aplicación para condicionar cadenas de Markov, puesto que aquí es más evidente el papel que tiene la función h para modificar la función de transición del proceso, que en este caso es una matriz de probabilidades de transición.

Después, mostramos una relación directa entre un proceso de difusión sesgado, cuyos coeficientes son dependientes de una cierta función h , con el proceso de Feynman-Kac, a través de una h -transformada de Doob aplicada a la función de transición del proceso de

Feynman-Kac.

Posteriormente mostramos la manera en que el teorema de Girsanov nos proporciona la solución estocástica a una ecuación de difusión más general, expresada en términos de un movimiento browniano, de manera análoga a la expresión obtenida en las fórmulas de Feynman-Kac obtenidas en el capítulo 3.

4.1. Breve repaso de la teoría de las cadenas de Markov

En esta sección repasaremos las definiciones más básicas que necesitamos de la teoría de las cadenas de Markov. Los resultados que aquí se enuncian se citan del capítulo 2 del libro de texto de Daniel Stroock, [39], así como del texto de Maria Emilia Caballero et al, [7].

Definición 4.1.1 (Cadena de Markov). Sea el espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$, y $\mathbb{S}$ un conjunto no vacío, finito o numerable, el cual es el espacio de estados en que toma valores el proceso.

Una cadena de Markov homogénea es una sucesión de variables aleatorias $\mathbb{S}$ -valuadas:

$$X = (X_n)_{n \geq 0}, \quad X_n : \Omega \rightarrow \mathbb{S},$$

que satisface la condición de Markov: para todo $n \geq 0$ y todo vector de estados $(i_0, \dots, i_n, j) \in \mathbb{S}^{n+2}$,

$$\mathbb{P}[X_{n+1} = j | X_0 = i_0, \dots, X_n = i_n] = \mathbb{P}[X_{n+1} = j | X_n = i_n]. \quad (4.1)$$

En el caso en que $\mathbb{S}$ sea finito, existe una matriz $\mathbf{P}$ tal que sus entradas satisfacen que:

$$\mathbb{P}[X_{n+1} = j | X_n = i_n] = (\mathbf{P})_{ij}, \quad (4.2)$$

la cual es conocida como la matriz de probabilidades de transición. Además, sus entradas son no-negativas y cada uno de sus renglones suma 1. En términos de condicionamiento de las variables aleatorias del proceso, esto se escribe así:

$$\mathbb{P}[X_{n+1} = j | X_0, \dots, X_n] = (\mathbf{P})_{X_n, j}. \quad (4.3)$$

En este caso, la distribución de la variable aleatoria X_0 es un vector de probabilidad y se le llama la distribución inicial de la cadena.

Definición 4.1.2 (Estados accesibles de una cadena de Markov). Dado un par de estados $i, j \in \mathbb{S}$ decimos que j es accesible desde i si la cadena puede pasar del estado i al estado j , es decir

$$(\mathbf{P}^n)_{ij} > 0 \quad \text{para algún } n \in \mathbb{N}. \quad (4.4)$$

Esto lo escribimos como $i \rightarrow j$. Si i y j son mutuamente accesibles entre sí, decimos que i se comunica con j y escribimos $i \leftrightarrow j$.

A continuación definimos los conceptos de recurrencia y transitoriedad de un estado $j \in \mathbb{S}$ en términos del concepto de tiempo de retorno.

Definición 4.1.3 (Clasificación de estados de una cadena de Markov). Sea ρ_j el primer momento en que la cadena alcanza el estado j , es decir,

$$\rho_j := \inf\{n \geq 1 : X_n = j\} \quad (= \infty \text{ si } X_n \neq j \quad \forall n \geq 1). \quad (4.5)$$

Diremos que un estado $j \in \mathbb{S}$ es recurrente si

$$\mathbb{P}[\rho_j < \infty | X_0 = j] = 1, \quad (4.6)$$

y diremos que es transitorio si

$$\mathbb{P}[\rho_j < \infty | X_0 = j] < 1. \quad (4.7)$$

Esta definición nos dice que un estado es recurrente si la probabilidad de que retorne a dicho estado en un tiempo finito es igual a 1.

Teorema 4.1.4 (Propiedad de Markov de una cadena de Markov). Sea $F : \mathbb{S}^{n+1} \mapsto \mathbb{R}$ acotada o no negativa y $m, n \geq 1$. Entonces, una cadena de Markov cumple la propiedad de Markov, es decir:

$$\begin{aligned} \mathbb{E}[F(X_m, \dots, X_{m+n}) | X_0 = i_0, \dots, X_m = i_m] \\ = \mathbb{E}[F(X_0, \dots, X_n) | X_0 = i_m]. \end{aligned}$$

4.2. Condicionamiento de una cadena de Markov por medio de la h-transformada de Doob

En esta sección vamos a construir cadenas de Markov condicionadas, utilizando la técnica de la h-transformada de Doob. Los resultados que aquí se presentan se basan en los ejercicios 2.4.9 y 2.4.10 de [39].

Proposición 4.2.1 (h-transformada de Doob para condicionar estados no alcanzables). Sea $\mathbf{P}$ una matriz de probabilidades de transición en el espacio de estados $\mathbb{S}$. Sea $\emptyset \neq \Gamma \subsetneq \mathbb{S}$ un subconjunto dado de $\mathbb{S}$ y $\hat{\mathbb{S}} = \mathbb{S} \setminus \Gamma$. Definamos

$$\rho_\Gamma = \inf\{n \geq 0 : X_n \in \Gamma\}. \quad (4.8)$$

Asumamos que

$$h(i) \equiv \mathbb{P}[\rho_\Gamma = \infty | X_0 = i] > 0 \quad \forall i \in \hat{\mathbb{S}}. \quad (4.9)$$

Entonces, tenemos las siguientes propiedades:

1. h es una función armónica, es decir: $h(i) = \sum_{j \in \hat{\mathbb{S}}} (\mathbf{P})_{ij} h(j) \quad \forall i \in \hat{\mathbb{S}}.$

2. La matriz

$$(\hat{\mathbf{P}})_{ij} = \frac{1}{h(i)} (\mathbf{P})_{ij} h(j),$$

es una matriz de probabilidades de transición en $\hat{\mathbb{S}}$.

3. Para toda $n \in \mathbb{N}$ y todo vector de estados $(j_0, \dots, j_n) \in (\hat{\mathbb{S}})^{n+1}$, se cumple que para cada $i \in \hat{\mathbb{S}}$:

$$\begin{aligned} \hat{\mathbb{P}}[X_0 = j_0, \dots, X_n = j_n | X_0 = i] = \\ \mathbb{P}[X_0 = j_0, \dots, X_n = j_n | \rho_\Gamma = \infty \quad \& \quad X_0 = i], \end{aligned}$$

donde $\hat{\mathbb{P}}$ denota las probabilidades calculadas para la cadena de Markov en $\hat{\mathbb{S}}$, cuya matriz de probabilidades de transición es $\hat{\mathbf{P}}$.

Esto significa que la cadena de Markov definida por $\hat{\mathbf{P}}$ es una modificación de la cadena de Markov determinada por $\mathbf{P}$, condicionada de tal modo que nunca alcance al conjunto Γ .

Demostración. 1. Para demostrar esta relación, notemos que $h(i)$ es la probabilidad de que el proceso nunca alcance Γ condicionado a que empiece en el estado i . Utilizando la ley de la probabilidad total respecto de los estados j e i , así como la propiedad de Markov respecto al estado X_1 , lo podemos escribir así:

$$h(i) = \mathbb{P}[\rho_\Gamma = \infty | X_0 = i] = \sum_{j \in \hat{\mathbb{S}}} \mathbb{P}[\rho_\Gamma = \infty | X_1 = j] \mathbb{P}[X_1 = j | X_0 = i].$$

Puesto que $\mathbb{P}[X_1 = j | X_0 = i] = (\mathbf{P})_{ij}$ y $\mathbb{P}[\rho_\Gamma = \infty | X_1 = j] = h(j)$ para $j \in \hat{\mathbb{S}}$, tenemos que

$$h(i) = \sum_{j \in \hat{\mathbb{S}}} (\mathbf{P})_{ij} h(j) + \sum_{j \in \Gamma} (\mathbf{P})_{ij} \cdot 0,$$

dado que para $j \in \Gamma$ $\rho_\Gamma \leq 1$ y $\mathbb{P}[\rho_\Gamma = \infty | X_1 = j] = 0$. Eso hace que el segundo término sea 0, obteniendo así el resultado buscado.

2. Para mostrar que $\hat{\mathbf{P}}$ es una matriz de probabilidades de transición, tenemos que mostrar que $(\hat{\mathbf{P}})_{ij} \geq 0$ para todo $i, j \in \hat{\mathbb{S}}$, y que $\sum_{j \in \hat{\mathbb{S}}} (\hat{\mathbf{P}})_{ij} = 1$ para todo $i \in \hat{\mathbb{S}}$.

Lo primero resulta claro si observamos lo siguiente: dado que $h(i) > 0$ y $(\mathbf{P})_{ij} \geq 0$, se sigue que $(\hat{\mathbf{P}})_{ij} = \frac{1}{h(i)} (\mathbf{P})_{ij} h(j) \geq 0$.

Para la segunda propiedad de una matriz de transición, notemos que

$$\sum_{j \in \hat{\mathbb{S}}} (\hat{\mathbf{P}})_{ij} = \sum_{j \in \hat{\mathbb{S}}} \frac{1}{h(i)} (\mathbf{P})_{ij} h(j) = \frac{1}{h(i)} \sum_{j \in \hat{\mathbb{S}}} (\mathbf{P})_{ij} h(j).$$

Del inciso anterior sabemos que $h(i) = \sum_{j \in \hat{\mathbb{S}}} (\mathbf{P})_{ij} h(j)$, por lo cual resulta que

$$\sum_{j \in \hat{\mathbb{S}}} (\hat{\mathbf{P}})_{ij} = \frac{1}{h(i)} \cdot h(i) = 1.$$

Por ende, $\hat{\mathbf{P}}$ es una matriz de probabilidades de transición en $\hat{\mathbb{S}}$.

3. Para demostrar este inciso, retomemos primero la definición de $\hat{\mathbf{P}}$ para $i, j \in \hat{\mathbb{S}}$:

$$(\hat{\mathbf{P}})_{ij} = \frac{1}{h(i)} (\mathbf{P})_{ij} h(j).$$

Una trayectoria particular $(j_0, j_1, \dots, j_n)$ que inicia en i tiene probabilidad

$$\hat{\mathbb{P}}[X_0 = j_0, \dots, X_n = j_n | X_0 = i] = \delta_{ij_0} \prod_{k=1}^n (\hat{\mathbf{P}})_{j_{k-1}j_k},$$

donde δ_{ij_0} es la delta de Kronecker, que es 1 si $i = j_0$ y 0 en otro caso.

Ahora expresamos la probabilidad condicional de que la cadena nunca alcance Γ con respecto a las matrices $(\mathbf{P})$

$$\begin{aligned} & \mathbb{P}[X_0 = j_0, \dots, X_n = j_n | \rho_\Gamma = \infty \ \& \ X_0 = i] \\ &= \frac{\mathbb{P}[X_0 = j_0, \dots, X_n = j_n, \rho_\Gamma = \infty | X_0 = i]}{\mathbb{P}[\rho_\Gamma = \infty | X_0 = i]}. \end{aligned}$$

Por la propiedad de Markov, para $j_0, \dots, j_n \in \hat{\mathbb{S}}$, la probabilidad de evitar Γ después del tiempo n , condicionada a esa trayectoria, es $h(j_n)$. Por tanto,

$$\begin{aligned} & \mathbb{P}[X_0 = j_0, \dots, X_n = j_n \mid \rho_\Gamma = \infty, X_0 = i] \\ &= \frac{h(j_n)}{h(i)} \delta_{ij_0} \prod_{k=1}^n P_{j_{k-1}j_k} \\ &= \delta_{ij_0} \prod_{k=1}^n \left(\frac{h(j_k)}{h(j_{k-1})} P_{j_{k-1}j_k} \right) \\ &= \hat{\mathbb{P}}[X_0 = j_0, \dots, X_n = j_n \mid X_0 = i]. \end{aligned}$$

Con esto se obtiene la identidad buscada.

□

La conclusión que sacamos del anterior ejercicio es que utilizando una función armónica h podemos condicionar las probabilidades de transición de una cadena de Markov para que tengan un comportamiento específico, que en este caso fue la de hacer que ciertos estados en un conjunto Γ de $\mathbb{S}$ sean inaccesibles.

Es posible utilizar esta técnica para lograr otros comportamientos. Por ejemplo, se puede demostrar de una manera similar que si $j_0 \in \mathbb{S}$ es un estado transitorio, pero tal que $i \rightarrow j_0$ para todo $i \in \mathbb{S}$, y hacemos

$$h(j_0) = 1 \quad \text{y} \quad h(i) = \mathbb{P}[\rho_{j_0} < \infty | X_0 = i] \quad i \neq j_0. \quad (4.10)$$

Para condicionar a alcanzar j_0 , definimos $\hat{P}_{ij} = P_{ij}h(j)/h(i)$ para $i \neq j_0$ y fijamos por separado $\hat{P}_{j_0j} = \delta_{j_0j}$. Esta cadena llega a j_0 casi seguramente y permanece allí. La absorción se impone mediante esa fila de la matriz; recurrencia y absorción no son sinónimos.

4.3. Transformada de Doob para procesos de difusión de Itô

Los fundamentos teóricos de esta sección están apoyados principalmente en el trabajo presentado por A. Rosales Ortiz, véase [30], cap.4, así como [10]

Primero, establezcamos algunas ideas preliminares. Sea X un proceso y la familia de funciones medibles $\{g_i\}_{i \in I}$ tales que $g_i : \mathbb{R}^n \mapsto \mathbb{R}$.

Definimos al *operador de traslación* Θ_{t_0} de la manera siguiente:

$$\Theta_{t_0}g_1(X_t) \cdots g_n(X_t) = g_1(X_t \circ \Theta_{t_0}) \cdots g_n(X_t \circ \Theta_{t_0}) := g_1(X_{t_0+t}) \cdots g_n(X_{t_0+t}).$$

Llamaremos $\mathcal{I}$ al conjunto de funciones invariantes bajo el operador de traslación, es decir, aquellas que satisfacen $F = F \circ \Theta_t$ para todo $t > 0$.

Definición 4.3.1 (Eventos invariantes). Sea A un evento. Decimos que A es invariante bajo $(\Theta_t)_{t \geq 0}$ si $1_A \in \mathcal{I}$.

Proposición 4.3.2. Para un evento invariante A , definamos $h(x) = \mathbb{P}^x(A)$ y sea $\tilde{S} = \{x \in E : h(x) > 0\}$ el conjunto de puntos en E desde los cuales el evento invariante A es accesible. Sea la medida $\tilde{\mathbb{P}}^x$ como se define a continuación:

$$d\tilde{\mathbb{P}}^x = \frac{1_A}{h(x)} d\mathbb{P}^x.$$

Entonces $\tilde{\mathbb{P}}$ es una medida de probabilidad en $(\Omega, \mathcal{F})$ y es absolutamente continua con respecto a $\mathbb{P}^x$ para todo $x \in \tilde{S}$.

Ahora, definamos la h -transformada de Doob conforme a la teoría general de los procesos de Markov.

Definición 4.3.3 (h -transformada de Doob). Sea X un proceso de Markov que admita a la familia de kernels (P_t) como función de transición. Sea h una función medible estrictamente positiva y armónica para el semigrupo, es decir, $P_t h = h$ para todo $t \geq 0$. Entonces, se define un nuevo kernel de transición a través de la siguiente fórmula

$$\tilde{P}_t(x, dy) = \frac{h(y)}{h(x)} P_t(x, dy),$$

es decir, $\tilde{P} = h^{-1} P h$. Tenemos así un semigrupo $\tilde{P}_t$ formado por los kernels de transición $\tilde{P}_t(x, \cdot)$.

En el caso particular $h(x) = \mathbb{P}^x(A)$ de un evento invariante, sobre los estados con $h(x) > 0$, la ley condicionada satisface:

$$\frac{d\tilde{\mathbb{P}}}{d\mathbb{P}} = \frac{1_A}{h(x)}.$$

Al proceso de Markov que admite a $(\tilde{P}_t)$ como función de transición se le llama la h -transformada de Doob del proceso X original.

Las h -transformadas de Doob de los procesos de difusión cumplen varias propiedades importantes, las cuales citamos de [30], cap.4.

Proposición 4.3.4 (Generador de la h -transformada de Doob de una difusión). Sea X una difusión de Itô con generador L , que satisface la siguiente ecuación diferencial estocástica:

$$dX_t = b(X_t)dt + \sigma(X_t)dW_t.$$

Si además $h \in C^2$ es positiva, $P_t h = h$ y $Lh = 0$, entonces la difusión $\tilde{X}$, condicionada con una h -transformada de Doob, tiene el siguiente generador para $f \in \mathcal{D}_L$:

$$\tilde{L}f = Lf + \sigma \sigma^T \frac{\nabla h}{h} \cdot \nabla f.$$

Con estas ideas en mente enunciaremos en la siguiente sección el resultado que nos interesa analizar.

4.4. Relación entre el proceso de Feynman-Kac y la difusión sesgada

Mostraremos una manera de expresar el semigrupo de transición de una difusión sesgada por medio de la h-transformada de Doob de un proceso de difusión de Feynman-Kac. Este resultado es el ejercicio 8.16 de [29], y nuestra intención al presentarlo aquí es enfatizar la conexión entre el semigrupo del proceso de Feynman-Kac y el semigrupo de una difusión sesgada particular, expresada a través de la h-transformada de Doob.

Teorema 4.4.1. *Sea W_t un movimiento browniano en $\mathbb{R}^n$ y consideremos la difusión X_t con sesgo en $\mathbb{R}^n$, definida por*

$$dX_t = \nabla h(X_t)dt + dW_t; \quad X_0 = x \in \mathbb{R}^n,$$

con $h \in C_b^2(\mathbb{R}^n)$ y derivadas de primer y segundo orden acotadas. Sea $f \in C_b(\mathbb{R}^n)$. Entonces, la función de transición de X es expresada en términos del movimiento browniano W_t como se describe a continuación:

$$\mathbb{E}^x[f(X_t)] = \mathbb{E}^x \left[f(W_t) \cdot \exp\left(-\int_0^t V(W_s)ds + h(W_t) - h(x)\right) \right],$$

donde

$$V(x) = \frac{1}{2}|\nabla h(x)|^2 + \frac{1}{2}\Delta h(x).$$

Además, el semigrupo de Feynman-Kac P_t^Y definido a continuación se relaciona con el proceso X mediante la transformada de Doob con función positiva $H = e^h$:

$$P_t^X f(x) = e^{-h(x)} P_t^Y (f e^h)(x),$$

cuya función de transición, definida por

$$P_t^Y f(x) = \mathbb{E}^x \left[f(W_t) e^{-\int_0^t V(W_s)ds} \right].$$

Cuando $V \geq 0$, este semigrupo corresponde al proceso Y obtenido al matar a W_t con tasa V . Si V toma valores negativos, la expresión sigue definiendo un semigrupo de Feynman-Kac, pero no admite esa interpretación como tasa de muerte. En la identidad anterior, el operador P_t^Y actúa sobre toda la función $y \mapsto f(y)e^{h(y)}$.

Demostración. La demostración utilizará el teorema de Girsanov para transformar a la difusión sesgada en un movimiento browniano. Definamos en primer lugar la martingala

cuadrado-integrable L de la siguiente manera

$$L_t = - \int_0^t \sum_{i=1}^n \frac{\partial h}{\partial x_i}(X_s) dW_s^i.$$

Además, $\langle L \rangle_T = \int_0^T |\nabla h(X_s)|^2 ds$ es acotada en todo intervalo finito si ∇h es acotado.

Entonces, si definimos la exponencial

$$D_t = \exp\{L_t - \frac{1}{2}\langle L \rangle_t\},$$

ésta cumple la condición de Novikov y es por tal una martingala bajo la medida $\mathbb{P}$ para todo $t \leq T$, lo cual definimos haciendo $d\mathbb{Q} = D_T d\mathbb{P}$

De ello se siguen dos consecuencias: primero

$$dX_t = \nabla h(X_t)dt + dW_t,$$

define un movimiento browniano bajo $\mathbb{Q}$, por el teorema de Girsanov. Además, como D_t es estrictamente positiva casi seguramente, entonces las medidas $\mathbb{P}$ y $\mathbb{Q}$ son equivalentes. Ésto nos garantiza que $d\mathbb{P} = D^{-1}d\mathbb{Q}$.

Entonces las esperanzas quedan

$$\begin{aligned} & \mathbb{E}^x[f(X_t)] \\ &= \bar{\mathbb{E}}_{\mathbb{Q}}^x[f(X_t)D_t^{-1}] \\ &= \bar{\mathbb{E}}_{\mathbb{Q}}^x \left[f(X_t) e^{\int_0^t \sum_{i=1}^n \frac{\partial h}{\partial x_i}(X_s) dX_s^i - \frac{1}{2} \int_0^t |\nabla h(X_s)|^2 ds} \right]. \end{aligned}$$

Como el proceso X es un movimiento browniano bajo la medida $\mathbb{Q}$, tenemos que aplicar la esperanza, con la medida $\mathbb{Q}$, de la transformación definida con la exponencial, cuyo argumento es X , es equivalente a aplicar tal transformación con argumento W_t en la medida $\mathbb{P}$, lo cual nos da la expresión de la esperanza con la medida $\mathbb{P}$.

$$= \mathbb{E}^x \left[f(W_t) e^{\int_0^t \sum_{i=1}^n \frac{\partial h}{\partial x_i}(W_s) dW_s^i - \frac{1}{2} \int_0^t |\nabla h(W_s)|^2 ds} \right].$$

Ahora, recordando el lema de Ito para la función $Z_t = h(W_t)$, obtenemos que

$$h(W_t) - h(W_0) = \int_0^t \sum_{i=1}^n \frac{\partial h}{\partial x_i}(W_s) dW_s^i + \frac{1}{2} \int_0^t \sum_{i=1}^n \frac{\partial^2 h}{\partial x_i^2}(W_s) ds,$$

y retomando a su vez la definición de V , con argumento W_t :

$$V(W_t) = \frac{1}{2} |\nabla h(W_t)|^2 + \frac{1}{2} \Delta h(W_t),$$

podemos expresar la esperanza de la siguiente forma

$$\mathbb{E}^x[f(X_t)] = \mathbb{E}^x \left[f(W_t) e^{h(W_t) - h(W_0)} e^{-\int_0^t V(W_s) ds} \right].$$

Con ello, puesto que la h -transformada de Doob de un proceso de Markov nos define el semigrupo correspondiente a un nuevo proceso de Markov, resulta que así hemos construido, por una parte, el semigrupo de Feynman-Kac del proceso Y , que, cuando $V \geq 0$, resulta de matar a W_t con la tasa V , y cuya función de transición es

$$P_t^Y f(x) = \mathbb{E}^x \left[f(W_t) e^{-\int_0^t V(W_s) ds} \right].$$

De tal se sigue la expresión del semigrupo de X en términos del semigrupo de Feynman-Kac del proceso Y , descrito en términos de una h -transformada de Doob:

$$P_t^X f(x) = e^{-h(x)} P_t^Y (f e^h)(x).$$

□

4.5. Solución de la ecuación de difusión a través del teorema de Girsanov

En esta sección ilustramos las conexiones entre las fórmulas de Feynman-Kac y el cambio de medida mediante el teorema de Girsanov.

Para mostrar este resultado, que se propone como el ejercicio 8.15a) de [29], utilizamos el teorema de Girsanov para expresar la solución de una ecuación de difusión, con ciertos coeficientes de tendencia determinista $\alpha_i(x)$, en términos de un movimiento browniano, a través de la igualdad en ley que establece dicho teorema.

Sean $f \in C_K^2(\mathbb{R}^n)$ $\alpha = (\alpha_1(x), \dots, \alpha_n(x))$ con $\alpha_i \in C_K^2(\mathbb{R}^n)$, y sea $u(t, x)$ la solución del siguiente problema de valores iniciales definido a continuación:

$$\begin{aligned} \frac{\partial u}{\partial t} &= \sum_{i=1}^n \alpha_i(x) \frac{\partial u}{\partial x_i} + \frac{1}{2} \sum_{i=1}^n \frac{\partial^2 u}{\partial x_i^2}, & t > 0, x \in \mathbb{R}^n \\ u(0, x) &= f(x); & x \in \mathbb{R}^n. \end{aligned} \quad (4.11)$$

Entonces, $u(t, x)$ se puede expresar de la siguiente forma

$$u(t, x) = \mathbb{E}^x \left[f(W_t) e^{\int_0^t \alpha(W_s) \cdot dW_s - \frac{1}{2} \int_0^t |\alpha(W_s)|^2 ds} \right]. \quad (4.12)$$

Demostración. Definamos la medida $\mathbb{Q}$ haciendo $d\mathbb{Q} = M_t d\mathbb{P}$, donde

$$M_t = \exp \left(\int_0^t \alpha(W_s) \cdot dW_s - \frac{1}{2} \int_0^t |\alpha(W_s)|^2 ds \right).$$

La acotación de α verifica Novikov, de modo que M es una martingala de esperanza uno. La medida se define coherentemente en cada $\mathcal{F}_t$. Por el teorema de Girsanov, $\hat{W}_t := W_t - x - \int_0^t \alpha(W_s) ds$ es un movimiento browniano bajo $\mathbb{Q}$ iniciado en cero. Entonces, W_t satisface la ecuación diferencial estocástica siguiente:

$$dW_t = \alpha(W_t)dt + d\hat{W}_t,$$

Bajo $\mathbb{Q}$, W tiene la ley de la difusión con deriva α iniciada en x . La representación de la solución acotada da, por tanto, $u(t, x) = \mathbb{E}_{\mathbb{Q}}^x[f(W_t)]$, y

$$\begin{aligned} \mathbb{E}_{\mathbb{Q}}^x[f(W_t)] &= \mathbb{E}_{\mathbb{P}}^x[f(W_t)M_t] \\ &= \mathbb{E}^x \left[f(W_t) e^{\int_0^t \alpha(W_s) \cdot dW_s - \frac{1}{2} \int_0^t |\alpha(W_s)|^2 ds} \right]. \end{aligned}$$

□

Capítulo 5

Aplicaciones

En este capítulo abordaremos dos aplicaciones de las fórmulas de Feynman-Kac, en las cuales, en conjunción con la transformada de Laplace, nos permiten deducir fórmulas explícitas para el cálculo de ciertas integrales de procesos de difusión que establecen propiedades estadísticas interesantes de tales procesos.

La primera aplicación es un resultado ya clásico, que es la ley del arco seno para el movimiento browniano. Para dicho problema, utilizamos la fórmula de Feynman-Kac del movimiento browniano para pasar de la esperanza de la integral que nos interesa calcular, a una ecuación diferencial parcial con soluciones conocidas, con la cual podemos obtener la función generadora de momentos de la variable aleatoria que nos interesa analizar.

Dicho resultado, descubierto inicialmente por Paul Levy, fue uno de los primeros ámbitos de aplicación de las fórmulas de Feynman-Kac por parte de Mark Kac. Para dicho desarrollo, analizamos la argumentación presentada en [38], cap. 15 sec. 3.

La segunda aplicación consiste en la aplicación de la fórmula de Feynman-Kac de una difusión especial conocida como el proceso de raíz cuadrada, la cual nos simplifica enormemente un problema de valuación de un instrumento financiero derivado especial.

En tal problema utilizamos la fórmula de Feynman-Kac para analizar la función generadora de momentos a partir de la EDP que le corresponde. Esta EDP también tiene una solución analítica conocida y gracias a ella podemos llegar a una expresión semi-cerrada para calcular la integral que nos da el precio del derivado.

En esta sección incluimos además un análisis computacional del costo comparativo de utilizar la solución obtenida gracias a las fórmulas de Feynman-Kac, versus la alternativa tradicional de una simulación Monte-Carlo directa.

En ambas aplicaciones nos apoyamos de la transformada de Laplace, otra herramienta de enorme utilidad para muchos problemas matemáticos.

5.1. Ley del Arcoseno para el Movimiento Browniano mediante Fórmulas de Feynman-Kac

La ley del arcoseno, descubierta por Paul Levy en 1938, establece lo siguiente.

Proposición 5.1.1 (Ley del Arcoseno para el Movimiento Browniano). *Sea $(W_t)_{t \geq 0}$ un movimiento browniano estándar definido en un espacio de probabilidad $(\Omega, \mathcal{F}, \mathbb{P})$.*

Para $t > 0$ fijo, definimos la variable aleatoria:

$$\tau_t = \int_0^t \mathbf{1}_{\{W_s > 0\}} ds, \quad (5.1)$$

que representa el tiempo total que el movimiento browniano ha pasado en el semieje positivo hasta el tiempo t .

Entonces, τ_t/t sigue una distribución arcoseno en $y \in [0, 1]$, es decir

$$\mathbb{P} \left[\frac{\tau_t}{t} \leq y \right] = \frac{2}{\pi} \arcsin \sqrt{y} = \frac{1}{\pi} \int_0^y \frac{du}{\sqrt{u(1-u)}}. \quad (5.2)$$

Esto equivale a decir que τ_t tiene la distribución arcoseno para $y \in [0, t]$:

$$\mathbb{P} [\tau_t \leq y] = \frac{2}{\pi} \arcsin \sqrt{\frac{y}{t}} = \frac{1}{\pi} \int_0^y \frac{du}{\sqrt{u(t-u)}}. \quad (5.3)$$

Demostración. Vamos a utilizar las fórmulas de Feynman-Kac para deducir la función de densidad de probabilidad de τ_t . Recordemos que Feynman-Kac para movimiento browniano se aplica con esperanzas de la forma

$$u(t, x) = \mathbb{E}_x \left[f(W_t) \exp \left(\int_0^t q(W_s) ds \right) \right]. \quad (5.4)$$

Fijemos $\lambda \geq 0$ y $\alpha > 0$. Entonces, hagamos $f(x) = 1$ y $q(x) = -\lambda \mathbf{1}_{x > 0}$, y sabemos que $1 = f(x) \in \mathcal{C}_b$, es decir, f es una función acotada y medible. Con eso definimos la función:

$$u(t, x) = \mathbb{E}_x \left[\exp \left(-\lambda \int_0^t \mathbf{1}_{\{W_s > 0\}} ds \right) \right], \quad (5.5)$$

donde $\mathbb{E}^x$ denota la esperanza tomada con respecto a la ley del movimiento browniano que comienza en x . Esto significa que $u(t, 0)$ es la transformada de Laplace de τ_t :

$$u(t, 0) = \mathbb{E}^0 [e^{-\lambda \tau_t}] = \int_{[0, t]} e^{-\lambda y} \mathbb{P}^0(\tau_t \in dy).$$

El potencial indicador es discontinuo en cero. La representación de Feynman-Kac se

interpreta aquí por regiones, con continuidad de la solución y de su primera derivada espacial en la interfaz (véase [38], cap. 15, sec. 3). Para $x \neq 0$, $u(t, x)$ satisface:

$$\frac{\partial u}{\partial t}(t, x) = \frac{1}{2} \frac{\partial^2 u}{\partial x^2}(t, x) - \lambda \mathbf{1}_{\{x>0\}} u(t, x), \quad (5.6)$$

con la condición inicial:

$$u(0, x) = f(x) = 1. \quad (5.7)$$

Por la condición de la función indicadora, esta EDP se transforma en dos ecuaciones dependiendo del valor de x :

$$\frac{\partial u}{\partial t}(t, x) = \begin{cases} \frac{1}{2} \frac{\partial^2 u}{\partial x^2}(t, x) - \lambda u(t, x) & x > 0 \\ \frac{1}{2} \frac{\partial^2 u}{\partial x^2}(t, x) & x < 0 \end{cases}. \quad (5.8)$$

Para resolver esta ecuación, aplicamos la transformada de Laplace respecto a la variable t :

$$\hat{u}(\alpha, x) = \int_0^\infty e^{-\alpha t} u(t, x) dt. \quad (5.9)$$

Tomando la transformada de Laplace de la ecuación diferencial parcial original, obtenemos la siguiente ecuación diferencial ordinaria (EDO) respecto a la variable x :

$$\alpha \hat{u}(\alpha, x) - 1 = \frac{1}{2} \frac{\partial^2 \hat{u}}{\partial x^2}(\alpha, x) - \lambda \mathbf{1}_{\{x>0\}} \hat{u}(\alpha, x). \quad (5.10)$$

Y esta a su vez se transforma en dos ecuaciones diferenciales ordinarias dependiendo del valor de x :

$$\alpha \hat{u}(\alpha, x) - 1 = \begin{cases} \frac{1}{2} \frac{\partial^2 \hat{u}}{\partial x^2}(\alpha, x) - \lambda \hat{u}(\alpha, x) & x > 0 \\ \frac{1}{2} \frac{\partial^2 \hat{u}}{\partial x^2}(\alpha, x) & x < 0 \end{cases}. \quad (5.11)$$

Vamos a encontrar la solución para las regiones $x > 0$ y $x < 0$

Para $x > 0$, la ecuación se convierte en:

$$\alpha \hat{u}(\alpha, x) - 1 = \frac{1}{2} \frac{\partial^2 \hat{u}}{\partial x^2}(\alpha, x) - \lambda \hat{u}(\alpha, x).$$

Para $x \leq 0$, tenemos:

$$\alpha \hat{u}(\alpha, x) - 1 = \frac{1}{2} \frac{\partial^2 \hat{u}}{\partial x^2}(\alpha, x).$$

Las únicas soluciones acotadas para estas ecuaciones son:

$$\hat{u}(\alpha, x) = \begin{cases} \frac{1}{\alpha + \lambda} + c_0 \exp\left(-x\sqrt{2(\alpha + \lambda)}\right), & x > 0, \\ \frac{1}{\alpha} + c_1 \exp\left(x\sqrt{2\alpha}\right), & x \leq 0. \end{cases} \quad (5.12)$$

La continuidad de $\hat{u}$ y de su primera derivada en cero determina las constantes c_0 y c_1 :

$$c_0 = \frac{\sqrt{\alpha + \lambda} - \sqrt{\alpha}}{\sqrt{\alpha}(\alpha + \lambda)},$$

y

$$c_1 = \frac{\sqrt{\alpha} - \sqrt{\alpha + \lambda}}{\alpha\sqrt{\alpha + \lambda}}.$$

Con lo cual, haciendo $x = 0$ nos queda que

$$\hat{u}(\alpha, 0) = \int_0^\infty e^{-\alpha t} u(t, 0) dt = \frac{1}{\sqrt{\alpha(\alpha + \lambda)}}. \quad (5.13)$$

Ahora identificaremos la ley de τ_t comparando sus transformadas de Laplace. Primero invertimos la transformada en tiempo de $u(t, 0)$; después, la unicidad de la transformada respecto de λ identifica la distribución en $[0, t]$.

Esto significa que queremos demostrar la siguiente ecuación:

$$u(t, 0) = \mathbb{E}(e^{-\lambda\tau_t}) = \int_0^t \frac{1}{\pi} \frac{e^{-\lambda s}}{\sqrt{s(t-s)}} ds. \quad (5.14)$$

Por la unicidad de la transformada de Laplace, la identidad (5.14) es válida si podemos encontrar que tienen la misma transformada, es decir:

$$\int_0^\infty \mathbb{E}(e^{-\lambda\tau_t}) e^{-\alpha t} dt = \int_0^\infty \int_0^t e^{-\alpha t} \frac{1}{\pi} \frac{e^{-\lambda s}}{\sqrt{s(t-s)}} ds dt. \quad (5.15)$$

El lado izquierdo de (5.15) es $\hat{u}(\alpha, 0)$, por lo que la demostración estará completa si verificamos que

$$\frac{1}{\sqrt{\alpha(\alpha + \lambda)}} = \int_0^\infty \int_0^t e^{-\alpha t} \frac{1}{\pi} \frac{e^{-\lambda s}}{\sqrt{s(t-s)}} ds dt. \quad (5.16)$$

Aplicando el teorema de Fubini, podemos sustituir la integral gamma siguiente:

$$\int_0^\infty \frac{e^{-\gamma t}}{\sqrt{t}} dt = \sqrt{\frac{\pi}{\gamma}}, \quad (5.17)$$

con lo cual sustituimos y obtenemos que

$$\begin{aligned}
\frac{1}{\pi} \int_0^\infty \frac{e^{-\lambda s}}{\sqrt{s}} \int_s^\infty \frac{e^{-\alpha t}}{\sqrt{t-s}} dt ds &= \frac{1}{\pi} \int_0^\infty \frac{e^{-\lambda s}}{\sqrt{s}} \int_0^\infty \frac{e^{-\alpha(t+s)}}{\sqrt{t}} dt ds \\
&= \frac{1}{\pi} \int_0^\infty \frac{e^{-(\lambda+\alpha)s}}{\sqrt{s}} ds \int_0^\infty \frac{e^{-\alpha t}}{\sqrt{t}} dt \\
&= \frac{1}{\pi} \sqrt{\frac{\pi}{\alpha+\lambda}} \sqrt{\frac{\pi}{\alpha}} = \frac{1}{\sqrt{\alpha(\alpha+\lambda)}},
\end{aligned}$$

y así completamos la demostración.

Hemos demostrado que τ_t , el tiempo que un movimiento browniano pasa en el semieje positivo hasta el tiempo t , sigue una distribución arco-seno para $y \in [0, 1]$ escalada por un factor t . Específicamente, τ_t/t tiene la función de densidad:

$$f_{\tau_t/t}(y) = \frac{1}{\pi \sqrt{y(1-y)}}, \quad 0 < y < 1. \quad (5.18)$$

Esta es la formulación clásica de la ley del arco-seno para el movimiento browniano. $\square$

Es importante destacar que hay muchos otros procesos que siguen leyes de tipo arco-seno como la que acabamos de demostrar, como la caminata aleatoria o el proceso de Poisson compuesto. Véase, por ejemplo, [6].

5.2. Fórmulas de Feynman-Kac en el contexto de las finanzas matemáticas

5.2.1. Introducción a los instrumentos financieros derivados

En el contexto tanto de la práctica de las finanzas, así como del análisis y la contabilidad financiera, los instrumentos financieros derivados desempeñan un papel crucial en los procesos de gestión del riesgo de las empresas, así como la especulación en los mercados financieros.

Conforme a los lineamientos planteados en las Normas de Información Financiera (NIF) publicadas por la Comisión de Principios de Contabilidad del Instituto Mexicano de Contadores Públicos (IMCP), un instrumento financiero derivado se define como un contrato cuyo valor cambia en respuesta a la variación en una variable subyacente, que requiere una inversión inicial nula o pequeña en comparación con otros tipos de contratos financieros, y que se liquida en una fecha futura.

Este concepto contable enfatiza la dependencia del valor del derivado con respecto a un subyacente, así como su función en la estructuración de posiciones de cobertura o apalancamiento.

Desde la perspectiva de las finanzas matemáticas, un derivado es entendido como un activo contingente cuyo precio depende de la evolución de un proceso estocástico que determina el valor del subyacente. En este sentido, el estudio de los derivados implica modelar la dinámica de los precios utilizando herramientas del cálculo estocástico, como la ecuación de Black-Scholes y sus soluciones analíticas, o métodos numéricos como Monte Carlo o diferencias finitas.

La formulación matemática se centra en la construcción de estrategias de cobertura y en la obtención de precios de no arbitraje, utilizando la teoría de la probabilidad con lo que se conoce como una medida neutral al riesgo.

Un caso particular de derivado es el contrato de opción, el cual otorga a su tenedor el derecho, pero no la obligación, de comprar (opción de compra) o vender (opción de venta) un activo subyacente a un precio determinado (precio de ejercicio) en una fecha futura o antes de ella.

La valuación de opciones bajo la metodología de finanzas matemáticas busca determinar el valor esperado del derivado bajo la medida de probabilidad neutral al riesgo, lo que permite establecer un precio teórico basado en el supuesto de ausencia de oportunidades de arbitraje.

Sin embargo, en el marco de las NIF, la medición, o determinación del valor contable, de un derivado se realiza con base en aquello que se conoce como valor razonable, lo cual es definido en la NIF B-17 como el precio que se recibiría por vender un activo o se pagaría por transferir un pasivo en una transacción ordenada entre participantes del mercado en la



Figura 5.1: Captura de pantalla de una terminal Bloomberg. Los instrumentos financieros derivados juegan un papel clave para protegerse, o cubrir, las variaciones de precio significativas. En esta imagen se muestra una repentina alza en el precio del gas natural de tipo El Paso-Permian, el cual es un insumo clave para muchos productores industriales en México y EE.UU. ©Bloomberg L.P., 2025

fecha de medición.

Esto implica que, si bien la teoría de la valuación matemática provee modelos fundamentales para estimar los precios de los derivados, en la práctica se debe considerar la evidencia de mercado, las metodologías de valuación aceptadas y los supuestos razonables utilizados por los participantes del mercado.

Lo anterior significa que un vendedor, o comprador, de un instrumento financiero derivado debe de examinar la relación entre el precio teórico, producido por los modelos matemáticos de valuación, y el precio de mercado, o aquel que le es ofrecido por los intermediarios de los mercados financieros, y utilizar esta información para determinar si se trata de un precio razonable y si resulta por ende apropiado para el objetivo que persiga.

5.2.2. Métodos matemáticos para la valuación de instrumentos financieros derivados

Como mencionamos en la Introducción, las fórmulas de Feynman-Kac nos permiten analizar un problema de valuación de derivados utilizando el método que resulte numéricamente más conveniente.

En el contexto de las finanzas cuantitativas, las fórmulas de Feynman-Kac adquieren una relevancia particular. Consideremos el problema de valuación de un derivado financiero, como una opción. Bajo los supuestos del modelo de Black-Scholes, el precio de un activo subyacente sigue un movimiento browniano geométrico:

$$dS_t = rS_t dt + \sigma S_t dW_t, \quad (5.19)$$

donde r es la tasa de interés libre de riesgo y σ es la volatilidad. Este modelo, sugerido por primera vez por el economista Paul Samuelson en 1965 [34], forma la base de lo que se conoce como el modelo Black-Scholes. En dicho modelo, cuyo desarrollo a detalle se puede consultar en [21], el precio de una opción europea con función de pago $h(S_T)$ al vencimiento T está dado por:

$$V(S_t, t) = e^{-r(T-t)} \mathbb{E}^{\mathbb{Q}} [h(S_T) | S_t], \quad (5.20)$$

donde $\mathbb{E}^{\mathbb{Q}}$ denota la esperanza calculada conforme a una medida $\mathbb{Q}$, conocida como la medida neutral al riesgo.

La fórmula de Feynman-Kac nos permite reexpresar este problema como una EDP, conocida como la Ecuación de Black-Scholes:

$$\frac{\partial V}{\partial t} + rS \frac{\partial V}{\partial S} + \frac{1}{2} \sigma^2 S^2 \frac{\partial^2 V}{\partial S^2} - rV = 0, \quad (5.21)$$

con la condición terminal $V(S, T) = h(S)$.

Esta reformulación del problema de valuación a partir de la solución una EDP ha sido fundamental para el desarrollo de métodos numéricos eficientes para la valuación de derivados complejos, así como para obtener fórmulas cerradas en casos específicos.

En la siguiente sección, profundizaremos en una aplicación particular de este marco teórico: la valuación de opciones asiáticas mediante el análisis de la transformada de Laplace de la variable aleatoria que modela el precio del activo subyacente.

Veremos cómo las fórmulas de Feynman-Kac nos permiten transformar un problema computacionalmente complejo en una EDP que, mediante manipulaciones adecuadas, nos proporciona una fórmula más manejable y directa de implementar para obtener el precio de estas opciones.

Para aterrizar nuestro análisis, reproduciremos el ejemplo trabajado por los autores G. Fusai y A. Roncoroni en [15], pp.225-228.

En general, los modelos matemáticos usados en finanzas cuantitativas requieren frecuentemente de herramientas analíticas sofisticadas para resolver problemas complejos de valuación de activos derivados. Entre estas herramientas, la transformada de Laplace destaca como un método poderoso y elegante que permite simplificar considerablemente ciertas clases de problemas. A continuación haremos un breve repaso de sus propiedades así como su relevancia en el contexto del problema que vamos a resolver.

Para una variable aleatoria no negativa Z , definimos su transformada de Laplace, para $\gamma \geq 0$, mediante:

$$\mathcal{L}_Z(\gamma) = \mathbb{E}[e^{-\gamma Z}]. \quad (5.22)$$

Si Z tiene densidad, esta expresión es su transformada de Laplace. La función generadora de momentos usa el signo positivo en el exponente, cuando la esperanza correspondiente es finita. Esta conexión resulta crucial para los desarrollos matemáticos que se presentarán a continuación.

Las opciones asiáticas, cuyas funciones de pago dependen del promedio del precio del activo subyacente durante un período específico, representan un desafío particular para los métodos de valuación tradicionales. La transformada de Laplace ofrece una vía elegante para abordar este problema, porque permite estudiar la ley del acumulado y recuperar la esperanza del pago mediante inversión; conocer únicamente el primer momento del acumulado no determina el precio de la opción.

En el caso que vamos a discutir, utilizamos un proceso de raíz cuadrada como modelo para el proceso de precios del subyacente. Dicho proceso satisface la siguiente ecuación diferencial estocástica:

$$dX_t = rX_t dt + \sigma\sqrt{X_t}dW_t. \quad (5.23)$$

Por otra parte, la valuación de una opción asiática requiere calcular esperanzas de

integrales que resultan computacionalmente demandantes si se implementan de manera directa. Como veremos en detalle, la transformada de Laplace y su representación en términos de la solución de una EDP ya conocida permitirá simplificar este cálculo significativamente.

Los desarrollos matemáticos que siguen demostrarán cómo, mediante la aplicación del teorema de Feynman-Kac y la inversión numérica de la transformada de Laplace, podemos obtener soluciones semi-analíticas o semi-cerradas que resultan ser de mucho menor costo computacional en comparación con la simulación Monte Carlo.

5.3. Valuación de una opción asiática usando Feynman-Kac

Consideraremos el uso de la transformada de Laplace con respecto al precio de ejercicio y no con respecto al tiempo hasta el vencimiento.

La transformada de Laplace de una variable aleatoria Z se define como $\mathbb{E}[e^{-\gamma Z}]$. En particular, si Z es una v.a. no negativa con densidad $f_Z(z)$, tenemos

$$\mathbb{E}[e^{-\gamma Z}] = \int_0^{+\infty} e^{-\gamma z} f_Z(z) dz, \quad (5.24)$$

La transformada se define también para leyes sin densidad, integrando respecto de su medida de probabilidad.

Si la transformada de Laplace de la variable aleatoria Z es conocida, también podemos obtener la transformada de Laplace de una opción de compra escrita sobre Z_t . Consideremos un activo contingente con función de pago dado por $\alpha(Z_t - Y)^+$, donde α y Y son constantes. Por argumentos de no-arbitraje, se sabe que el precio de la opción es:

$$C(Z_0, t, Y) = \alpha e^{-rt} \int_0^{+\infty} (z - Y)^+ f_Z(z) dz = \alpha e^{-rt} \int_Y^{+\infty} (z - Y) f_Z(z) dz, \quad (5.25)$$

donde $f_Z(z)$ es la densidad de Z_t con respecto a una medida neutral al riesgo. Definamos la transformada de Laplace con respecto al precio de ejercicio Y del precio anterior

$$c(Z_0, t; \gamma) = \mathcal{L}\{C(Z_0, t, Y)\} = \int_0^{+\infty} e^{-\gamma Y} C(Z_0, t, Y) dY. \quad (5.26)$$

Sustituyendo (5.26) en esta fórmula, [15] deducen el siguiente desarrollo

$$c(Z_0, t; \gamma) = \alpha e^{-rt} \int_0^{+\infty} e^{-\gamma Y} \int_Y^{+\infty} (z - Y) f_Z(z) dz dY \quad (5.27)$$

$$= \alpha e^{-rt} \int_0^{+\infty} \int_0^z e^{-\gamma Y} (z - Y) dY f_Z(z) dz \quad (5.28)$$

$$= \alpha e^{-rt} \int_0^{+\infty} \int_0^z z e^{-\gamma Y} - Y e^{-\gamma Y} dY f_Z(z) dz \quad (5.29)$$

$$= \alpha e^{-rt} \int_0^{+\infty} \left(\frac{e^{-\gamma z} + \gamma z - 1}{\gamma^2} \right) f_Z(z) dz \quad (5.30)$$

$$= \alpha e^{-rt} \left(\frac{\mathbb{E}[e^{-\gamma Z_t}]}{\gamma^2} + \frac{\mathbb{E}[Z_t]}{\gamma} - \frac{1}{\gamma^2} \right). \quad (5.31)$$

Usando el hecho de que la inversa de Laplace de $1/\gamma$ es 1 y la inversa de Laplace de $1/\gamma^2$ es Y , los autores antes citados encuentran la siguiente fórmula para el precio de la opción:

$$C(Z_0, t, Y) = \alpha e^{-rt} \left[\mathcal{L}_{\gamma \rightarrow Y}^{-1} \left\{ \frac{\mathbb{E}[e^{-\gamma Z_t}]}{\gamma^2} \right\} (Y) + \mathbb{E}[Z_t] - Y \right], \quad (5.32)$$

con lo cual concluyen que el problema se reduce a la inversión numérica de $\mathbb{E}[e^{-\gamma Z_t}]/\gamma^2$.

Como ejemplo concreto, se propone el proceso de raíz cuadrada

$$dX_t = rX_t dt + \sigma \sqrt{X_t} dW_t, \quad (5.33)$$

y nuestro objetivo es valorar una opción asiática de precio de ejercicio fijo, con función de pago

$$h(X_t) = \left(\frac{1}{t} \int_0^t X_u du - K \right)^+. \quad (5.34)$$

Para obtener el precio de la opción asiática, calculamos la transformada de Laplace de $\int_0^t X_u du$:

$$v(X_0, t; \gamma) = \mathbb{E} \left[e^{-\gamma \int_0^t X_u du} \right]. \quad (5.35)$$

Por las fórmulas de Feynman-Kac, $v(X_0, t; \gamma)$ es la solución de la EDP:

$$-\frac{\partial v}{\partial t} + rx \frac{\partial v}{\partial x} + \frac{1}{2} \sigma^2 x \frac{\partial^2 v}{\partial x^2} = \gamma x v, \quad (5.36)$$

con condición inicial

$$v(X_0, 0; \gamma) = 1. \quad (5.37)$$

Esta EDP admite un ansatz exponencial afín, relacionado con el utilizado en el modelo de Cox, Ingersoll y Ross (CIR). La difusión aquí usada tiene deriva rx , no la deriva de

reversión a la media del CIR usual. Trabajamos con su solución no negativa y cero absorbente. El coeficiente $\sqrt{x}$ no es Lipschitz en cero, de modo que el teorema global de Lipschitz del capítulo 2 no se aplica directamente a este ejemplo.

Siguiendo entonces el desarrollo de Cox, Ingersoll y Ross (1986) [22], pp. 397-398, se propone una solución de tipo:

$$v(X, t; \gamma) = e^{-A(t; \gamma)X - B(t; \gamma)}. \quad (5.38)$$

Reemplazando esta función en la EDP, Ingersoll muestra que $B(t; \gamma) = 0$ y

$$A(t; \gamma) = \frac{2\gamma(e^{t\lambda} - 1)}{\lambda + r + (\lambda - r)e^{t\lambda}}, \quad (5.39)$$

donde $\lambda = \sqrt{r^2 + 2\gamma\sigma^2}$. Por lo tanto, usando (5.32), podemos escribir el precio de la opción asiática como

$$C_0 = \frac{e^{-rt}}{t} \left[\mathcal{L}_{\gamma \rightarrow Y}^{-1} \left\{ \frac{e^{-A(t; \gamma)X_0 - B(t; \gamma)}}{\gamma^2} \right\} (Kt) + \mathbb{E} \left[\int_0^t X_u du \right] - Kt \right], \quad (5.40)$$

donde $\mathcal{L}^{-1}$ es la inversa respecto a Y ; aquí $\alpha = 1/t$ y $Y = Kt$. Todas las esperanzas de valuación se toman bajo la medida neutral al riesgo.

Además, el segundo término se simplifica de la siguiente manera:

$$\mathbb{E} \left[\int_0^t X_u du \right] = \int_0^t \mathbb{E}[X_u] du \quad (5.41)$$

$$= \int_0^t X_0 e^{ru} du \quad (5.42)$$

$$= \begin{cases} X_0(e^{rt} - 1)/r, & r \neq 0, \\ X_0 t, & r = 0. \end{cases} \quad (5.43)$$

En resumidas cuentas, en este problema específico de valuación de opciones asiáticas bajo el proceso de raíz cuadrada, aplicamos el teorema de Feynman-Kac para transformar el cálculo de la transformada de Laplace:

$$v(X_0, t; \gamma) = \mathbb{E} \left[e^{-\gamma \int_0^t X_u du} \right], \quad (5.44)$$

en la resolución de la EDP:

$$-\frac{\partial v}{\partial t} + rx \frac{\partial v}{\partial x} + \frac{1}{2} \sigma^2 x \frac{\partial^2 v}{\partial x^2} = \gamma x v, \quad (5.45)$$

con condición inicial $v(X_0, 0; \gamma) = 1$.

El método de las fórmulas de Feynman-Kac para simplificar el estudio de ciertas

integrales de funciones de un proceso de difusión, ha sido también aprovechado exitosamente por otros autores, en una gran variedad de problemas de valuación de derivados exóticos. Véase por ejemplo [25].

En dicho artículo, los autores deducen una fórmula comparable para un tipo de opción cuyo valor depende de una variable aleatoria, conocida como el “tiempo de ocupación”, es decir, la cantidad de tiempo que el proceso permanece en cierto intervalo o región de su espacio de estados.

5.4. Análisis comparativo entre el método de Feynman-Kac y una implementación Monte Carlo directa

Ahora, aplicando la fórmula propuesta por [15], vamos a reproducir los resultados numéricos que reportan dichos autores y en conjunto reportaremos un comparativo de eficiencia computacional en comparación con una implementación Monte Carlo directa.

Este análisis fue llevado a cabo en un programa escrito en el lenguaje de programación R, el cual se presenta adjunto al actual trabajo en el apéndice. R es un entorno de software gratuito, el cual está orientado especialmente hacia el cómputo estadístico y la visualización de datos.

Utilizamos R al ser un lenguaje con requisitos técnicos ligeros en cuanto a la infraestructura de cómputo requerida así como las habilidades de computación que se necesitan por parte del usuario para instalarlo y ejecutarlo. Además, es un lenguaje popular y reconocido tanto entre los profesionistas de la industria como en la academia, y como se puede ir ejecutando por bloques, los programas que se escriben en él resultan sencillos de analizar paso a paso.

La intención de este ejercicio es exponer una primera aproximación a la metodología general que se utiliza en la práctica real de las finanzas cuantitativas, en particular en los problemas de calibración de los algoritmos para los programas de valuación, pero no pretende ser un análisis profundo o exhaustivo de ambos métodos.¹

5.4.1. Reporte de resultados

Primero, empecemos por los resultados numéricos reportados por Fusai y Roncoroni (2008) en [15], p.227.

Roncoroni y Fusai obtuvieron estos resultados utilizando la fórmula (5.40), en conjunción con un programa escrito en MATLAB©, un entorno de software comercial, en el


¹Para empezar, un análisis más profundo se programaría en un lenguaje como C++, haciendo un seguimiento muy preciso de la asignación de memoria que está usándose por parte del intérprete en el entorno virtual utilizado, y se compararía con programas y librerías ya establecidos, con ciertos inputs de precios y datos de mercado adicionales.

Cuadro 5.1: Precios de una opción asiática en el modelo de raíz cuadrada reportados por [15]

K	$\sigma = 0,1$	$\sigma = 0,3$	$\sigma = 0,5$
0.9	0.13745	0.15384	0.18691
0.95	0.09294	0.12001	0.15821
1	0.05258	0.09075	0.13253
1.05	0.02268	0.06640	0.10987
1.1	0.00687	0.04696	0.09016

cual implementan el algoritmo de Abate-Whitt para calcular la inversa de la transformada de Laplace.

Utilizando el código proporcionado por los autores, reproducimos el programa en R y obtuvimos valores muy similares, aunque nuestra implementación tiende a infravalorar los precios por ciertos márgenes porcentuales, los cuales crecen para valores de σ más pequeños y valores de K más distantes del precio actual $S_0 = 1$.



Los resultados numéricos de la comparación se pueden consultar en la tabla 5.2

Los autores explican que escogieron ciertos valores particulares de sus parámetros al momento de invertir la transformada de Laplace, lo cual explica hasta cierto punto las diferencias. Los resultados obtenidos nos dicen que esta fórmula es además sensible para ciertos precios de ejercicios particulares.

Cuadro 5.2: Comparación entre precios calculados mediante Laplace y valores de referencia de [15]

Precios calculados con el método de Laplace			
K	$\sigma = 0,1$	$\sigma = 0,3$	$\sigma = 0,5$
0.90	0.119568	0.141142	0.177617
0.95	0.074231	0.107787	0.148950
1.00	0.036441	0.079585	0.123557
1.05	0.012828	0.056733	0.101387
1.10	0.003009	0.039014	0.082305
Valores de referencia de los autores			
K	$\sigma = 0,1$	$\sigma = 0,3$	$\sigma = 0,5$
0.90	0.13745	0.15384	0.18691
0.95	0.09294	0.12001	0.15821
1.00	0.05258	0.09075	0.13253
1.05	0.02268	0.06640	0.10987
1.10	0.00687	0.04696	0.09016
Diferencias absolutas (Calculado - Referencia)			
K	$\sigma = 0,1$	$\sigma = 0,3$	$\sigma = 0,5$
0.90	-0.017882	-0.012698	-0.009293
0.95	-0.018709	-0.012223	-0.009260
1.00	-0.016139	-0.011165	-0.008973
1.05	-0.009852	-0.009667	-0.008483
1.10	-0.003861	-0.007946	-0.007855
Diferencias porcentuales (%)			
K	$\sigma = 0,1$	$\sigma = 0,3$	$\sigma = 0,5$
0.90	-13.0	-8.25	-4.97
0.95	-20.1	-10.18	-5.85
1.00	-30.7	-12.30	-6.77
1.05	-43.4	-14.56	-7.72
1.10	-56.2	-16.92	-8.71

5.4.2. Comparación entre el método con transformada de Laplace y Feynman-Kac vs Simulación Monte Carlo con Euler-Maruyama

Ahora, nosotros implementamos la simulación Monte Carlo con el método de Euler-Maruyama para valorar opciones asiáticas bajo el proceso de raíz cuadrada. La implementación que usamos es estandarizada y la tomamos del texto de Stefano Iacus, “Simulation and Inference for Stochastic Differential Equations With R Examples” [19], cap. 2.

Este enfoque nos sirve como método de validación para comparar los resultados obtenidos mediante nuestra implementación del método de la transformada de Laplace con Feynman-Kac.

Por método de validación nos referimos a un método estandarizado, cuyas características conocemos de antemano, que es considerado como un método “aceptado” por la industria para dicho problema.

En ese sentido hay que hacer algunas consideraciones importantes, siguiendo las ideas que se proponen para la implementación de los métodos Monte Carlo en finanzas conforme al texto clásico de Paul Glasserman, “Monte Carlo Methods in Financial Engineering” [18]. Dichas consideraciones están implementadas en nuestro programa como se describe a continuación:

1. El método Monte Carlo necesita un número suficiente de pasos temporales (n_steps) para aproximar bien la integración continua del proceso, especialmente para opciones asiáticas.
2. Una variable de control con un coeficiente adecuado puede reducir la varianza; la implementación original requiere las correcciones que se detallan en el apartado de rendimiento.
3. Para el proceso de raíz cuadrada, es crucial manejar correctamente la posibilidad de valores negativos durante la simulación.

Para obtener resultados más precisos, se pueden ajustar los parámetros:

1. Aumentar n_paths (número de simulaciones) mejora la precisión pero aumenta el tiempo de cálculo.
2. Incrementar n_steps proporciona una mejor discretización del proceso continuo


Ahora mostramos la comparación entre los precios obtenidos mediante el método de Laplace y aquellos del método de Monte Carlo con Euler-Maruyama:

Los resultados de este experimento muestran además algo interesante: nuestro modelo de referencia para la validación de nuestro método, que es la simulación Monte Carlo directa,

Cuadro 5.3: Comparación de precios obtenidos con Monte Carlo y Laplace con Feynman Kac, por volatilidad (σ) y precio de ejercicio (K)

$\sigma = 0,1$			
K	Laplace	MC	Diff (%)
0.90	0.11957	0.11950	-0.05 %
0.95	0.07423	0.07417	-0.08 %
1.00	0.03644	0.03609	-0.97 %
1.05	0.01283	0.01240	-3.31 %
1.10	0.00301	0.00288	-4.43 %
$\sigma = 0,3$			
K	Laplace	MC	Diff (%)
0.90	0.14114	0.14011	-0.73 %
0.95	0.10779	0.10921	1.32 %
1.00	0.07959	0.07890	-0.86 %
1.05	0.05673	0.05801	2.26 %
1.10	0.03901	0.03857	-1.14 %
$\sigma = 0,5$			
K	Laplace	MC	Diff (%)
0.90	0.17762	0.17946	1.04 %
0.95	0.14895	0.15056	1.08 %
1.00	0.12356	0.12029	-2.65 %
1.05	0.10139	0.10158	0.19 %
1.10	0.08231	0.07779	-5.49 %

muestra diferencias porcentuales mucho más pequeñas con respecto a nuestros valores obtenidos por método de Laplace con Feynman-Kac, en contraste con las diferencias relativamente elevadas que se observaban en los datos reportados por [15]. Esta comparación entre ambos métodos contra los valores de referencia de los autores la podemos ver en las tablas y gráfico que presentamos a continuación.



Cuadro 5.4: Comparación de precios de opciones asiáticas bajo distintos métodos y volatilidades

Strike	$\sigma = 0,1$			$\sigma = 0,3$			$\sigma = 0,5$		
	Ref	Laplace	MC	Ref	Laplace	MC	Ref	Laplace	MC
0.90	0.13745	0.11957	0.11950	0.15384	0.14114	0.14011	0.18691	0.17762	0.17946
0.95	0.09294	0.07423	0.07417	0.12001	0.10779	0.10921	0.15821	0.14895	0.15056
1.00	0.05258	0.03644	0.03609	0.09075	0.07959	0.07890	0.13253	0.12356	0.12029
1.05	0.02268	0.01283	0.01240	0.06640	0.05673	0.05801	0.10987	0.10139	0.10158
1.10	0.00687	0.00301	0.00288	0.04696	0.03901	0.03857	0.09016	0.08231	0.07779

Cuadro 5.5: Diferencias porcentuales respecto a los valores de referencia

Strike	$\sigma = 0,1$		$\sigma = 0,3$		$\sigma = 0,5$	
	Laplace vs Ref	MC vs Ref	Laplace vs Ref	MC vs Ref	Laplace vs Ref	MC vs Ref
0.90	-13.01 %	-13.06 %	-8.25 %	-8.93 %	-4.97 %	-3.99 %
0.95	-20.13 %	-20.20 %	-10.18 %	-9.00 %	-5.85 %	-4.83 %
1.00	-30.69 %	-31.37 %	-12.30 %	-13.06 %	-6.77 %	-9.24 %
1.05	-43.44 %	-45.31 %	-14.56 %	-12.63 %	-7.72 %	-7.54 %
1.10	-56.20 %	-58.14 %	-16.92 %	-17.87 %	-8.71 %	-13.72 %

Cuadro 5.6: Estadísticas de error por método y volatilidad (RMSE)

Método	RMSE_01	RMSE_03	RMSE_05
Laplace	0.01444	0.01088	0.00879
Monte Carlo	0.01462	0.01083	0.00985

Cuadro 5.7: Estadísticas de error por método y volatilidad (MAE)

Método	MAE_01	MAE_03	MAE_05
Laplace	0.01329	0.01074	0.00877
Monte Carlo	0.01350	0.01063	0.00960

Cuadro 5.8: Estadísticas de error por método y volatilidad (MAPE)

Método	MAPE_01	MAPE_03	MAPE_05
Laplace	32.69 %	12.44 %	6.81 %
Monte Carlo	33.61 %	12.30 %	7.86 %

5.4.3. Benchmark de rendimiento computacional

Las cifras siguientes corresponden al programa y a las configuraciones originales. No constituyen una comparación universal a igual precisión. Aumentar las trayectorias con pasos fijos no elimina el error de discretización; el esquema implementado recorta a cero los valores negativos. Los resúmenes agrupan configuraciones distintas, no repeticiones de un único experimento. La medición basada en diferencias de `gc()` describe memoria administrada por R, no memoria total ni máxima del proceso.

La implementación original fija el coeficiente de control en $\beta = -1$, que no es necesariamente óptimo, y calcula el error estándar sobre pagos sin descontar ni ajustar. Para el estimador $Y + \beta(C - \mathbb{E}C)$, el óptimo es $-\text{Cov}(Y, C)/\text{Var}(C)$ cuando la varianza es positiva; el error estándar debe calcularse sobre las observaciones efectivamente usadas en el precio. Los resultados numéricos se conservan como registro del experimento original y requieren una nueva ejecución antes de usar esos errores como validación.

A continuación realizamos algunas pruebas de rendimiento computacional para comparar la eficiencia de ambos métodos. Para dicha comparación vamos a incorporar mediciones de tiempo de ejecución y uso de memoria. El tipo de pruebas que realizamos son frecuentemente utilizadas en la industria y se pueden reproducir en casi cualquier lenguaje de programación o entornos de software de cómputo numérico.

Nuestra implementación se apoya de las recomendaciones descritas en el reconocido texto de Hadley Wickham, “Advanced R” [42], particularmente los capítulos 23 y 24. Dicho texto se puede consultar de manera gratuita en <https://adv-r.hadley.nz/index.html>.

En la tabla 5.9, reportamos los resultados obtenidos cuando utilizamos distintas configuraciones de ambos métodos. Para Monte Carlo implementamos diferentes combinaciones de número de simulaciones y pasos temporales, mientras que para Laplace con Feynman-Kac aplicamos diferentes combinaciones de términos y términos extra en el algoritmo.

Dicha tabla muestra claramente las diferencias de rendimiento entre los dos métodos, con Laplace mostrando tiempos de ejecución mucho más consistentes y un uso de memoria significativamente menor, mientras que Monte Carlo muestra una gran variabilidad dependiendo de la configuración.

Por otra parte, en la tabla 5.10 se destaca claramente la diferencia significativa en rendimiento entre ambos métodos, mostrando que Laplace es considerablemente más rápido y eficiente en términos de memoria que Monte Carlo.

Para concluir, en la tabla 5.11, mostramos los resultados del análisis de convergencia. Dicho análisis busca encontrar cuánto tiempo lleva a cada método alcanzar una precisión objetivo. Para tal fin, establece un precio de referencia interno usando el método de Laplace con muchos términos, cuya exactitud no se valida de manera independiente, e incrementa gradualmente el número de simulaciones (Monte Carlo) o términos (Laplace). Finalmente, registra el tiempo tomado hasta alcanzar un error relativo preestablecido




Figura 5.2: Comparación de uso de memoria




Figura 5.3: Comparación de tiempos de ejecución

En la tabla, el error relativo mínimo observado es 0.00596 para Monte Carlo y 0.00098 para Laplace, respecto de la referencia interna. Con el umbral 0.001 del programa, Monte Carlo no alcanzó la precisión objetivo. Su tiempo reportado es el máximo de las ejecuciones probadas, no un tiempo de convergencia; por ello no procede interpretar el cociente de tiempos como una aceleración a igual precisión.

Cuadro 5.9: Comparación de rendimiento entre métodos Monte Carlo y Laplace

Método	Configuración	Tiempo (ms)	Memoria (MB)	Precio
Monte Carlo				
Monte Carlo	paths=100, steps=100	66.78	14.0	0.0806
Monte Carlo	paths=100, steps=500	151.89	32.2	0.0921
Monte Carlo	paths=100, steps=1000	269.46	33.1	0.0814
Monte Carlo	paths=500, steps=100	155.22	32.2	0.0839
Monte Carlo	paths=500, steps=500	587.21	36.4	0.0775
Monte Carlo	paths=500, steps=1000	1,119.38	41.0	0.0767
Monte Carlo	paths=1000, steps=100	243.96	33.2	0.0791
Monte Carlo	paths=1000, steps=500	1,058.48	41.0	0.0783
Monte Carlo	paths=1000, steps=1000	2,083.28	50.2	0.0788
Monte Carlo	paths=5000, steps=100	1,091.89	41.4	0.0805
Monte Carlo	paths=5000, steps=500	5,179.92	66.5	0.0781
Monte Carlo	paths=5000, steps=1000	10,098.57	110.0	0.0789
Laplace				
Laplace	terms=10, extraterms=5	39.22	0.0	0.0796
Laplace	terms=10, extraterms=10	39.07	0.1	0.0796
Laplace	terms=10, extraterms=15	39.21	0.1	0.0796
Laplace	terms=20, extraterms=5	40.58	0.1	0.0796
Laplace	terms=20, extraterms=10	40.73	0.1	0.0796
Laplace	terms=20, extraterms=15	40.82	0.1	0.0796
Laplace	terms=50, extraterms=5	40.50	0.2	0.0796
Laplace	terms=50, extraterms=10	41.83	0.2	0.0796
Laplace	terms=50, extraterms=15	41.11	0.2	0.0796

Cuadro 5.10: Resumen comparativo de rendimiento: Laplace vs Monte Carlo

Método	Tiempo (ms)		Tiempo Extremo (ms)		Memoria (MB)	
	Media	Mediana	Mínimo	Máximo	Media	Mediana
Laplace	40.34	40.58	39.07	41.83	0.12	0.10
Monte Carlo	1,842.17	822.85	66.78	10,098.57	44.27	38.70

Cuadro 5.11: Comparación de convergencia entre métodos

Método	Tiempo reportado (ms)	Error relativo mínimo
Monte Carlo	1,022.03	0.00596
Laplace	0.12	0.00098

5.4.4. Conclusiones acerca de la aplicación de las fórmulas de Feynman-Kac en problemas numéricos

Las fórmulas de Feynman-Kac, en conjunción con la transformada de Laplace, nos proporcionan aquí un ejemplo claro de cómo es que los resultados profundos de la teoría de probabilidad y el análisis matemático pueden traducirse en herramientas prácticas y eficientes para la resolución de problemas financieros complejos.

La aplicación de las fórmulas de Feynman-Kac en este tipo de problemas representa una transformación simbólica de gran utilidad por los siguientes motivos:

1. **Transformación de un problema integral-estocástico a uno diferencial:** Estas fórmulas permiten convertir un problema que involucra esperanzas sobre integrales de procesos estocásticos en una EDP determinista.
2. **Posibilidad de soluciones en forma cerrada:** Como hemos visto en nuestro desarrollo, al aplicar la fórmula, pudimos proponer una solución de la forma $v(X, t; \gamma) = e^{-A(t; \gamma)X - B(t; \gamma)}$, que resultó en una expresión analítica para $A(t; \gamma)$ con una expresión semi-analítica para la solución de la EDP, algo que hubiera sido mucho más complicado de obtener analizando directamente la esperanza de este proceso de difusión particular.

Además, las implicaciones prácticas de este tipo de técnicas son numerosas y significativas:

Eficiencia computacional: La solución mediante la transformada de Laplace y las fórmulas de Feynman-Kac nos permite implementar algoritmos numéricamente eficientes para la valuación de opciones asiáticas, en las configuraciones estudiadas; no se ha evaluado una exigencia de latencia para aplicaciones en tiempo real.

Precisión numérica: La transformada tiene una expresión analítica, pero el precio requiere inversión numérica. Su error depende del truncamiento y de la estabilidad de dicha inversión. Las diferencias con la referencia publicada requieren una validación adicional.

Este método puede además extenderse a una amplia gama de procesos estocásticos y estructuras de opciones, proporcionando un marco unificado para la valuación de derivados exóticos.

5.4.5. Otras aplicaciones de las Fórmulas de Feynman-Kac

Existen muchas otras aplicaciones de las fórmulas de Feynman-Kac para procesos de difusión de Itô, las cuales no estudiamos a detalle puesto que exceden en gran medida el alcance de este trabajo. A continuación citaremos algunas fuentes en libros de texto y monografías que consideramos pueden ser de interés para la persona que lee:

1. Al igual que como hicimos con la ley arco seno, se utilizan con frecuencia para encontrar la distribución de otras variables aleatorias del movimiento browniano, como tiempos de ocupación o de llegada, y su relación con ecuaciones diferenciales tanto ordinarias como parciales. En ese sentido, [5] hace un estudio bastante detallado.
2. La fórmula de Feynman-Kac para la ecuación diferencial parabólica no homogénea (que dedujimos en el teorema 3.5.3, en el capítulo 3) es utilizada en problemas de finanzas matemáticas. En ese tipo de problemas se utiliza el término adicional $g(t, x)$, conocido como el lagrangiano de la EDP, para especificar algún tipo de función de costo adicional que debe de cumplir la solución buscada. Para tales ejemplos recomendamos leer [20], cap 3 sec 4, en donde se discute dicha ecuación como una generalización del modelo de Black-Scholes.
3. En el caso de la teoría de los procesos de Markov controlados, también se utiliza la fórmula para la EDP parabólica no homogénea de 3.5.3. En este contexto se utiliza para estudiar lo que se conoce como “soluciones de viscosidad”, las cuales generalizan el concepto de solución de una EDP. Sugerimos como referencia [14], cap. 4 sec. 3 y cap. 6 sec. 4.
4. En la monografía de [27] encontramos una generalización de las fórmulas de Feynman-Kac para cadenas de Markov. Estas fórmulas son aplicadas en problemas computacionales como el Método Secuencial de Monte Carlo, y en problemas estadísticos como los filtros no lineales y los modelos de espacio de estados. Véase también el libro de texto [28].

5.5. Conclusiones y perspectivas

Así, hemos establecido que el enfoque que nos proporcionan las fórmulas de Feynman-Kac representa no solo una técnica de cálculo, sino una herramienta de análisis que amplía significativamente nuestra capacidad para abordar problemas matemáticos, en un ámbito tanto teórico como práctico.

Como continuación de este trabajo, sería de interés tanto práctico como teórico comparar una implementación tradicional de Monte Carlo con una implementación en CUDA por medio de CuPy. Dicha comparación permitiría estudiar hasta qué punto el cómputo en paralelo modifica los tiempos de ejecución y el uso de memoria, manteniendo una precisión comparable, así como revisar el alcance de las diferencias observadas aquí entre la simulación directa y el método basado en la transformada de Laplace.

Otra cuestión que sería de interés estudiar es la evolución asintótica de las soluciones para distintas condiciones de frontera, así como para funciones de intensidad de muerte, o términos de crecimiento, que sean periódicos o tengan alguna característica relevante para las aplicaciones científicas. Esta perspectiva fue motivada por el análisis que presentan V. I. Arnold y B. A. Khesin en [2], cap. V, sección 3.C, acerca de la ecuación de Fokker-Planck. En ese sentido, sería interesante explorar cómo las condiciones de frontera y los términos adicionales de las ecuaciones de Feynman-Kac influyen en el comportamiento de las soluciones a tiempos largos.

Apéndice A

Código para la valuación de opciones asiáticas

A.1. Código para valorar opciones asiáticas con R

A continuación proporcionamos el código utilizado para reproducir los resultados de Roncoroni y Fusai y realizar el análisis computacional que describimos en el capítulo de Aplicaciones.

El código se entrega también en el archivo `codigo/opciones_asiaticas.R`, dentro del repositorio que acompaña a la tesis: <https://github.com/SymmetricSymplectic/Feynman-Kac-tesis-2024>. La copia local permite consultar y ejecutar el programa sin extraerlo del PDF.

```
#### Reproducir Roncoroni-Fusai ####
set.seed(2281)

# Función para calcular la transformada de Laplace en el modelo de raíz cuadrada
ltsr <- function(spot, expiry, sg, rf, gamma) {
  lambda <- sqrt(rf^2 + 2*gamma*sg*sg)
  numerator <- 2*gamma*(exp(expiry*lambda) - 1)
  denominator <- lambda + rf + (lambda - rf)*exp(expiry*lambda)
  lt <- exp(-spot*numerator/denominator)/(gamma^2)
  return(lt)
}

# Función para realizar la inversión numérica de la transformada de Laplace
# usando el algoritmo de Abate-Whitt con la aceleración de Euler
AWSR <- function(spot, strike, expiry, sg, rf, aa = 18.4, terms = 20, extraterms = 10) {
  X <- strike*expiry

  # Calcular la transformada en gamma = aa/(2*strike)
  lt <- ltss(spot, expiry, sg, rf, aa/(2*X))
}
```

```

sum <- lt*exp(aa/2)/(2*X)

# Aplicar el algoritmo de Euler
k <- 1:(terms + extraterms)
arg_real <- aa/(2*X)
arg_imag <- pi*k/X

term <- numeric(length(k))
for(i in 1:length(k)) {
  arg <- complex(real = arg_real, imaginary = arg_imag[i])
  term[i] <- ((-1)^k[i]) * ltsr(spot, expiry, sg, rf, arg) * exp(aa/2)/X
}

csum <- sum + cumsum(term)
sumr <- Re(csum[terms:(terms+extraterms)])

# Calcular coeficientes binomiales para la extrapolación
j <- 0:extraterms
bincoeff <- factorial(extraterms)/(factorial(j)*factorial(extraterms-j))

# Resultado extrapolado
euler <- sum(bincoeff*sumr) * (2^(-extraterms))

# Aplicar la fórmula final
optprice <- exp(-rf*expiry) * (euler + spot*(exp(rf*expiry)-1)/rf - X)/expiry

return(optprice)
}

# Función para generar la tabla de precios de opciones asiáticas
generate_asian_option_table <- function() {
  # Parámetros
  spot <- 1 # El spot parece ser 1 en los casos
  expiry <- 1 # Asumimos vencimiento de 1 año
  rf <- 0.05 # Tasa libre de riesgo (r en el texto)

  # Valores de volatilidad (sigma) y strikes a evaluar
  sigmas <- c(0.1, 0.3, 0.5)
  strikes <- c(0.9, 0.95, 1.0, 1.05, 1.1)

  # Crear tabla para almacenar resultados
  results <- matrix(0, nrow = length(strikes), ncol = length(sigmas) + 1)
  colnames(results) <- c("K", paste("sigma =", sigmas))
  results[,1] <- strikes

  # Calcular precios de opciones para cada combinación
  for (i in 1:length(strikes)) {

```

```

    for (j in 1:length(sigmas)) {
      results[i, j+1] <- AWSR(spot, strikes[i], expiry, sigmas[j], rf)
    }
  }

  # Convertir a data frame y formatear
  results_df <- as.data.frame(results)

  # Imprimir tabla de resultados
  print(results_df, digits = 5)

  return(results_df)
}

# Ejecutar la función para generar la tabla
asian_option_prices <- generate_asian_option_table()

# Crear una función para comparar los resultados con los valores de referencia
compare_asian_option_prices <- function() {
  # Parámetros
  spot <- 1
  expiry <- 1
  rf <- 0.05

  # Valores de volatilidad (sigma) y strikes a evaluar
  sigmas <- c(0.1, 0.3, 0.5)
  strikes <- c(0.9, 0.95, 1.0, 1.05, 1.1)

  # Crear matriz para los resultados calculados
  calculated_results <- matrix(0, nrow = length(strikes), ncol = length(sigmas) + 1)
  colnames(calculated_results) <- c("K", paste("sigma =", sigmas))
  calculated_results[,1] <- strikes

  # Valores de referencia de la tabla LaTeX proporcionada
  reference_values <- matrix(c(
    0.9, 0.13745, 0.15384, 0.18691,
    0.95, 0.09294, 0.12001, 0.15821,
    1.0, 0.05258, 0.09075, 0.13253,
    1.05, 0.02268, 0.06640, 0.10987,
    1.1, 0.00687, 0.04696, 0.09016
  ), nrow = 5, byrow = TRUE)

  reference_results <- as.data.frame(reference_values)
  colnames(reference_results) <- c("K", paste("sigma =", sigmas))

  # Calcular precios con nuestra implementación

```

```

for (i in 1:length(strikes)) {
  for (j in 1:length(sigmas)) {
    calculated_results[i, j+1] <- AWSR(spot, strikes[i], expiry, sigmas[j], rf)
  }
}

calculated_df <- as.data.frame(calculated_results)

# Calcular diferencias absolutas y porcentuales
diff_abs <- calculated_results
diff_pct <- calculated_results

for (i in 1:length(strikes)) {
  for (j in 1:length(sigmas)) {
    diff_abs[i, j+1] <- calculated_results[i, j+1] - reference_values[i, j+1]
    diff_pct[i, j+1] <- (calculated_results[i, j+1] / reference_values[i, j+1] - 1) *
      100
  }
}

diff_abs_df <- as.data.frame(diff_abs)
diff_pct_df <- as.data.frame(diff_pct)

# Nombrar adecuadamente las tablas de diferencias
colnames(diff_abs_df) <- c("K", paste("sigma =", sigmas))
colnames(diff_pct_df) <- c("K", paste("sigma =", sigmas))

# Crear tabla final con todos los resultados
cat("Precios calculados con el método de Laplace:\n")
print(calculated_df, digits = 5)

cat("\nValores de referencia de los autores:\n")
print(reference_results, digits = 5)

cat("\nDiferencias absolutas (Calculado - Referencia):\n")
print(diff_abs_df, digits = 5)

cat("\nDiferencias porcentuales (%):\n")
print(diff_pct_df, digits = 3)

# Crear una tabla formateada para presentación
comparison_table <- data.frame(
  Strike = strikes,
  Calc_Sigma_01 = calculated_results[, 2],
  Ref_Sigma_01 = reference_values[, 2],
  Diff_Sigma_01 = diff_pct[, 2],
  Calc_Sigma_03 = calculated_results[, 3],

```

```

Ref_Sigma_03 = reference_values[, 3],
Diff_Sigma_03 = diff_pct[, 3],
Calc_Sigma_05 = calculated_results[, 4],
Ref_Sigma_05 = reference_values[, 4],
Diff_Sigma_05 = diff_pct[, 4]
)

# Crear gráfico de comparación
if (requireNamespace("ggplot2", quietly = TRUE)) {
  library(ggplot2)
  library(reshape2)

  # Preparar datos para graficar
  plot_data <- data.frame(
    Strike = rep(strikes, 2 * length(sigmas)),
    Sigma = rep(rep(sigmas, each = length(strikes)), 2),
    Value = c(as.vector(as.matrix(calculated_df[, -1])),
              as.vector(as.matrix(reference_results[, -1]))),
    Type = rep(c("Calculado", "Referencia"), each = length(strikes) * length(sigmas))
  )

  # Crear gráfico
  p <- ggplot(plot_data, aes(x = Strike, y = Value, color = Type, shape = as.factor(
    Sigma))) +
    geom_point(size = 3) +
    geom_line(aes(linetype = Type)) +
    scale_color_manual(values = c("blue", "red")) +
    labs(title = "Comparación de precios de opciones asiáticas",
         subtitle = "Método de Laplace vs. Valores de referencia",
         x = "Strike (K)",
         y = "Precio de la opción",
         color = "Fuente",
         shape = "Volatilidad (sigma)",
         linetype = "Fuente") +
    theme_minimal() +
    theme(legend.position = "bottom")

  print(p)
} else {
  cat("\nPara generar gráficos, instale el paquete 'ggplot2':\n install.packages('
  ggplot2')\n")
}

return(list(
  calculated = calculated_df,
  reference = reference_results,
  diff_abs = diff_abs_df,

```

```

    diff_pct = diff_pct_df,
    comparison = comparison_table
  ))
}

# Ejecutar la comparación
results <- compare_asian_option_prices()

#### Comparacion con Euler-Maruyama ####

# Método de Euler-Maruyama para simular el proceso de raíz cuadrada
#  $dX_t = rX_t dt + \sigma \sqrt{X_t} dW_t$ 

# Función para simular el proceso de raíz cuadrada usando Euler-Maruyama
simulate_square_root_process <- function(X0, r, sigma, T, n_steps, n_paths) {
  dt <- T/n_steps
  sqrt_dt <- sqrt(dt)

  # Matriz para almacenar todas las trayectorias
  X <- matrix(0, nrow = n_steps + 1, ncol = n_paths)
  X[1, ] <- X0 # Valor inicial

  # Simular cada trayectoria
  for (i in 1:n_paths) {
    for (j in 1:n_steps) {
      # Generar incremento browniano
      dW <- rnorm(1, mean = 0, sd = sqrt_dt)

      # Aplicar Euler-Maruyama
      # Para evitar valores negativos, usamos max(X[j, i], 0)
      X[j+1, i] <- X[j, i] + r * X[j, i] * dt + sigma * sqrt(max(X[j, i], 0)) * dW

      # Asegurar que el proceso no tome valores negativos
      X[j+1, i] <- max(X[j+1, i], 0)
    }
  }

  return(X)
}

# Función para calcular el precio de una opción asiática usando Monte Carlo
# Función para calcular el precio de una opción asiática usando Monte Carlo
price_asian_option_mc <- function(spot, strike, T, r, sigma, n_steps = 1000, n_paths =
  10000, control_variate = FALSE) {
  # Simular el proceso
  X <- simulate_square_root_process(spot, r, sigma, T, n_steps, n_paths)

```

```

# Calcular la media aritmética para cada trayectoria
# Para una integración más precisa, usamos la regla del trapecio
avg_values <- numeric(n_paths)
dt <- T/n_steps

for (i in 1:n_paths) {
  # Aproximación de la integral usando la regla del trapecio
  # Corregimos los índices y aseguramos que todas las operaciones sean numéricas
  avg_values[i] <- (X[1, i]/2 + sum(X[2:n_steps, i]) + X[n_steps+1, i]/2) * dt / T
}

# El resto de la función sigue igual...
# Calcular payoff de la opción asiática
payoffs <- pmax(avg_values - strike, 0)

# Aplicar descuento
option_price <- exp(-r * T) * mean(payoffs)

# Calcular error estándar Monte Carlo
se <- sd(payoffs) / sqrt(n_paths)

# Si se solicita, implementar control variate para reducir varianza
if (control_variate) {
  # Usamos el valor esperado analítico del subyacente como variable de control
  #  $E[X_t] = X_0 * \exp(rt)$ 
  expected_avg <- spot * (exp(r * T) - 1) / (r * T)

  # Calcular media aritmética teórica
  MC_avg <- mean(avg_values)

  # Ajustar el precio usando la técnica de control variate
  beta <- -1 # Coeficiente óptimo simplificado
  option_price_cv <- option_price + beta * (MC_avg - expected_avg)

  return(list(price = option_price_cv, se = se))
}

return(list(price = option_price, se = se))
}

# Función para generar tabla comparativa
compare_pricing_methods <- function(laplace_fn, monte_carlo_fn) {
  # Parámetros
  spot <- 1
  T <- 1
  r <- 0.05

```

```

# Valores de volatilidad y strikes
sigmas <- c(0.1, 0.3, 0.5)
strikes <- c(0.9, 0.95, 1.0, 1.05, 1.1)

# Crear tabla para almacenar resultados
results <- data.frame(
  K = strikes,
  sigma_0.1_laplace = 0,
  sigma_0.1_mc = 0,
  sigma_0.1_diff = 0,
  sigma_0.3_laplace = 0,
  sigma_0.3_mc = 0,
  sigma_0.3_diff = 0,
  sigma_0.5_laplace = 0,
  sigma_0.5_mc = 0,
  sigma_0.5_diff = 0
)

# Calcular precios con ambos métodos
for (i in 1:length(strikes)) {
  for (j in 1:length(sigmas)) {
    # Calcular precio con transformada de Laplace
    laplace_price <- laplace_fn(spot, strikes[i], T, sigmas[j], r)

    # Calcular precio con Monte Carlo (con control variate)
    mc_result <- monte_carlo_fn(spot, strikes[i], T, r, sigmas[j],
                                control_variate = TRUE,
                                n_steps = 100,
                                n_paths = 5000)
    mc_price <- mc_result$price

    # Calcular diferencia relativa
    diff_pct <- 100 * (mc_price - laplace_price) / laplace_price

    # Guardar resultados
    col_idx <- 3 * (j - 1) + 2
    results[i, col_idx] <- laplace_price
    results[i, col_idx + 1] <- mc_price
    results[i, col_idx + 2] <- diff_pct
  }
}

return(results)
}

# caso de uso
compare_results <- compare_pricing_methods(AWSR, price_asian_option_mc)

```

[illegible]

```

                                control_variate = TRUE)

    results$price[i] <- mc_result$price
    results$sse[i] <- mc_result$sse
  }

  # Añadir error relativo
  results$rel_error <- abs(results$price - reference_price) / reference_price * 100

  return(results)
}

# caso: analizar convergencia para K=1.0 y sigma=0.3
convergence_data <- analyze_mc_convergence(1, 1.0, 1, 0.05, 0.3)

#### Comparación de los tres métodos ####
# Función para comparar los tres métodos: Valores de referencia, Laplace y Monte Carlo
compare_three_methods <- function() {
  # Parámetros
  spot <- 1
  expiry <- 1
  rf <- 0.05

  # Valores de volatilidad (sigma) y strikes a evaluar
  sigmas <- c(0.1, 0.3, 0.5)
  strikes <- c(0.9, 0.95, 1.0, 1.05, 1.1)

  # Valores de referencia de la tabla LaTeX proporcionada
  reference_values <- matrix(c(
    0.9, 0.13745, 0.15384, 0.18691,
    0.95, 0.09294, 0.12001, 0.15821,
    1.0, 0.05258, 0.09075, 0.13253,
    1.05, 0.02268, 0.06640, 0.10987,
    1.1, 0.00687, 0.04696, 0.09016
  ), nrow = 5, byrow = TRUE)

  reference_df <- as.data.frame(reference_values)
  colnames(reference_df) <- c("K", paste("Sigma =", sigmas))

  # Crear dataframe para resultados
  results <- data.frame(
    Strike = strikes,
    matrix(0, nrow = length(strikes), ncol = 9) # 3 métodos x 3 volatilidades
  )

  colnames(results) <- c(
    "Strike",

```

```

"Ref_Sigma=0.1", "Laplace_Sigma=0.1", "MC_Sigma=0.1",
"Ref_Sigma=0.3", "Laplace_Sigma=0.3", "MC_Sigma=0.3",
"Ref_Sigma=0.5", "Laplace_Sigma=0.5", "MC_Sigma=0.5"
)

# Calcular precios con todos los métodos
for (i in 1:length(strikes)) {
  # Valores de referencia
  for (j in 1:length(sigmas)) {
    # Índice de columna para cada volatilidad en el dataframe de resultados
    col_idx_ref <- 3*j - 1 # 2, 5, 8
    col_idx_lap <- 3*j     # 3, 6, 9
    col_idx_mc <- 3*j + 1  # 4, 7, 10

    # Valor de referencia
    results[i, col_idx_ref] <- reference_values[i, j+1]

    # Calcular precio con transformada de Laplace
    results[i, col_idx_lap] <- AWSR(spot, strikes[i], expiry, sigmas[j], rf)

    # Calcular precio con Monte Carlo
    mc_result <- price_asian_option_mc(
      spot, strikes[i], expiry, rf, sigmas[j],
      n_steps = 100,
      n_paths = 5000,
      control_variate = TRUE
    )
    results[i, col_idx_mc] <- mc_result$price
  }
}

# Calcular diferencias porcentuales
diff_results <- data.frame(
  Strike = strikes,
  matrix(0, nrow = length(strikes), ncol = 6) # 2 comparaciones x 3 volatilidades
)

colnames(diff_results) <- c(
  "Strike",
  "Laplace_vs_Ref_Sigma=0.1", "MC_vs_Ref_Sigma=0.1",
  "Laplace_vs_Ref_Sigma=0.3", "MC_vs_Ref_Sigma=0.3",
  "Laplace_vs_Ref_Sigma=0.5", "MC_vs_Ref_Sigma=0.5"
)

for (i in 1:length(strikes)) {
  for (j in 1:length(sigmas)) {
    col_idx_ref <- 3*j - 1 # 2, 5, 8 en results

```

```

col_idx_lap <- 3*j      # 3, 6, 9 en results
col_idx_mc <- 3*j + 1  # 4, 7, 10 en results

diff_col_lap <- 2*j     # 2, 4, 6 en diff_results
diff_col_mc <- 2*j + 1  # 3, 5, 7 en diff_results

# Diferencia porcentual: (método - referencia) / referencia * 100
ref_value <- results[i, col_idx_ref]
lap_value <- results[i, col_idx_lap]
mc_value <- results[i, col_idx_mc]

diff_results[i, diff_col_lap] <- (lap_value - ref_value) / ref_value * 100
diff_results[i, diff_col_mc] <- (mc_value - ref_value) / ref_value * 100
}
}

# Formatear resultados para mejor visualización
formatted_results <- results
formatted_diff <- diff_results

# Formatear valores de precios con 5 decimales
for (j in 2:ncol(formatted_results)) {
  formatted_results[, j] <- sprintf("%.5f", results[, j])
}

# Formatear valores de diferencias con 2 decimales y símbolo de porcentaje
for (j in 2:ncol(formatted_diff)) {
  formatted_diff[, j] <- sprintf("%.2f%%", diff_results[, j])
}

# Crear gráficos comparativos si está disponible ggplot2
if (requireNamespace("ggplot2", quietly = TRUE)) {
  library(ggplot2)
  library(reshape2)

  # Preparar datos para graficar precios
  plot_data <- data.frame(
    Strike = rep(strikes, 9),
    Method = rep(c(rep("Referencia", length(strikes)),
                    rep("Laplace", length(strikes)),
                    rep("Monte Carlo", length(strikes)))), 3),
    Sigma = c(rep("0.1", 3*length(strikes)),
               rep("0.3", 3*length(strikes)),
               rep("0.5", 3*length(strikes))),
    Price = c(
      results[, 2], results[, 3], results[, 4], # Sigma=0.1
      results[, 5], results[, 6], results[, 7], # Sigma=0.3

```

```

      results[, 8], results[, 9], results[, 10] # Sigma=0.5
    )
  )

# Gráfico de precios
p1 <- ggplot(plot_data, aes(x = Strike, y = Price, color = Method, shape = Method)) +
  geom_point(size = 3) +
  geom_line() +
  facet_wrap(~Sigma, scales = "free_y", ncol = 3,
             labeller = labeller(Sigma = function(x) paste("Sigma =", x))) +
  scale_color_manual(values = c("red", "blue", "green4")) +
  labs(title = "Comparación de precios de opciones asiáticas",
       subtitle = "Todos los métodos por nivel de volatilidad",
       x = "Strike (K)",
       y = "Precio de la opción") +
  theme_minimal()

# Preparar datos para graficar diferencias porcentuales
diff_plot_data <- data.frame(
  Strike = rep(strikes, 6),
  Method = rep(c(rep("Laplace vs Ref", length(strikes)),
                 rep("Monte Carlo vs Ref", length(strikes))), 3),
  Sigma = c(rep("0.1", 2*length(strikes)),
            rep("0.3", 2*length(strikes)),
            rep("0.5", 2*length(strikes))),
  Diff = c(
    diff_results[, 2], diff_results[, 3], # Sigma=0.1
    diff_results[, 4], diff_results[, 5], # Sigma=0.3
    diff_results[, 6], diff_results[, 7]  # Sigma=0.5
  )
)

# Gráfico de diferencias
p2 <- ggplot(diff_plot_data, aes(x = Strike, y = Diff, color = Method, shape = Method)) +
  geom_point(size = 3) +
  geom_line() +
  geom_hline(yintercept = 0, linetype = "dashed", color = "darkgrey") +
  facet_wrap(~Sigma, scales = "free_y", ncol = 3,
             labeller = labeller(Sigma = function(x) paste("Sigma =", x))) +
  scale_color_manual(values = c("blue", "green4")) +
  labs(title = "Diferencias porcentuales respecto a valores de referencia",
       subtitle = "Por nivel de volatilidad",
       x = "Strike (K)",
       y = "Diferencia (%)") +
  theme_minimal()

```

```

# Imprimir gráficos
print(p1)
print(p2)
} else {
  cat("\nPara generar gráficos, instale el paquete 'ggplot2':\n install.packages('
  ggplot2')\n")
}

# Mostrar tablas
cat("\nComparación de precios de opciones asiáticas:\n")
print(formatted_results, row.names = FALSE)

cat("\nDiferencias porcentuales respecto a los valores de referencia:\n")
print(formatted_diff, row.names = FALSE)

# Calcular estadísticas de error
error_stats <- data.frame(
  Method = c("Laplace", "Monte Carlo"),
  RMSE_01 = c(
    sqrt(mean((results[, 3] - results[, 2])^2)),
    sqrt(mean((results[, 4] - results[, 2])^2))
  ),
  RMSE_03 = c(
    sqrt(mean((results[, 6] - results[, 5])^2)),
    sqrt(mean((results[, 7] - results[, 5])^2))
  ),
  RMSE_05 = c(
    sqrt(mean((results[, 9] - results[, 8])^2)),
    sqrt(mean((results[, 10] - results[, 8])^2))
  ),
  MAE_01 = c(
    mean(abs(results[, 3] - results[, 2])),
    mean(abs(results[, 4] - results[, 2]))
  ),
  MAE_03 = c(
    mean(abs(results[, 6] - results[, 5])),
    mean(abs(results[, 7] - results[, 5]))
  ),
  MAE_05 = c(
    mean(abs(results[, 9] - results[, 8])),
    mean(abs(results[, 10] - results[, 8]))
  ),
  MAPE_01 = c(
    mean(abs(diff_results[, 2])),
    mean(abs(diff_results[, 3]))
  ),
  MAPE_03 = c(

```

```

    mean(abs(diff_results[, 4])),
    mean(abs(diff_results[, 5]))
  ),
  MAPE_05 = c(
    mean(abs(diff_results[, 6])),
    mean(abs(diff_results[, 7]))
  )
)

# Formatear estadísticas de error
formatted_stats <- error_stats
for (j in 2:ncol(formatted_stats)) {
  if (j <= 7) {
    # RMSE y MAE con 5 decimales
    formatted_stats[, j] <- sprintf("%.5f", error_stats[, j])
  } else {
    # MAPE con 2 decimales y símbolo de porcentaje
    formatted_stats[, j] <- sprintf("%.2f%%", error_stats[, j])
  }
}

cat("\nEstadísticas de error por método y volatilidad:\n")
print(formatted_stats, row.names = FALSE)

# Retornar todos los resultados
return(list(
  prices = results,
  differences = diff_results,
  error_stats = error_stats,
  formatted_prices = formatted_results,
  formatted_differences = formatted_diff,
  formatted_stats = formatted_stats
))
}

# caso de uso
comparison_results <- compare_three_methods()

#### Comparación del desempeño computacional de ambos métodos ####
# Función para medir el rendimiento de ambos métodos
compare_performance <- function() {
  # Parámetros comunes para ambos métodos
  spot <- 1
  strike <- 1.0
  T <- 1
  r <- 0.05

```

```

sigma <- 0.3

# Parámetros para escalabilidad (probaremos diferentes configuraciones)
mc_paths_list <- c(100, 500, 1000, 5000)
mc_steps_list <- c(100, 500, 1000)

laplace_terms_list <- c(10, 20, 50)
laplace_extraterms_list <- c(5, 10, 15)

# Tabla para resultados
results <- data.frame(
  Method = character(),
  Config = character(),
  Time_ms = numeric(),
  Memory_MB = numeric(),
  Price = numeric()
)

# Benchmark para Monte Carlo
for (paths in mc_paths_list) {
  for (steps in mc_steps_list) {
    # Limpiar memoria antes de cada prueba
    gc()

    # Inicio de medición
    config <- paste0("paths=", paths, ", steps=", steps)
    start_time <- Sys.time()
    mem_start <- gc(reset = TRUE)

    # Ejecutar Monte Carlo
    result <- price_asian_option_mc(
      spot = spot,
      strike = strike,
      T = T,
      r = r,
      sigma = sigma,
      n_steps = steps,
      n_paths = paths,
      control_variate = TRUE
    )

    # Fin de medición
    end_time <- Sys.time()
    mem_end <- gc(reset = FALSE)

    # Calcular métricas
    time_ms <- as.numeric(difftime(end_time, start_time, units = "secs")) * 1000
  }
}

```

```

mem_used <- sum(mem_end[,6] - mem_start[,6]) # Medir MB

# Guardar resultados
results <- rbind(results, data.frame(
  Method = "Monte Carlo",
  Config = config,
  Time_ms = time_ms,
  Memory_MB = mem_used,
  Price = result$price
))
}
}

# Benchmark para Laplace
for (terms in laplace_terms_list) {
  for (extraterms in laplace_extraterms_list) {
    # Limpiar memoria antes de cada prueba
    gc()

    # Inicio de medición
    config <- paste0("terms=", terms, ", extraterms=", extraterms)
    start_time <- Sys.time()
    mem_start <- gc(reset = TRUE)

    # Ejecutar Laplace
    result <- AWSR(
      spot = spot,
      strike = strike,
      expiry = T,
      sg = sigma,
      rf = r,
      aa = 18.4,
      terms = terms,
      extraterms = extraterms
    )

    # Fin de medición
    end_time <- Sys.time()
    mem_end <- gc(reset = FALSE)

    # Calcular métricas
    time_ms <- as.numeric(difftime(end_time, start_time, units = "secs")) * 1000
    mem_used <- sum(mem_end[,6] - mem_start[,6]) # / 1024^2 # Convertir a MB

    # Guardar resultados
    results <- rbind(results, data.frame(
      Method = "Laplace",

```

```

        Config = config,
        Time_ms = time_ms,
        Memory_MB = mem_used,
        Price = result
    ))
}
}

return(results)
}

# Función para visualizar los resultados de rendimiento
plot_performance <- function(perf_results) {
  # Convertir Method a factor para ordenar en gráficos
  perf_results$Method <- factor(perf_results$Method,
                                levels = c("Laplace", "Monte Carlo"))

  # Crear resumen por método
  method_summary <- aggregate(
    cbind(Time_ms, Memory_MB) ~ Method,
    data = perf_results,
    FUN = function(x) c(mean = mean(x),
                        median = median(x),
                        min = min(x),
                        max = max(x))
  )

  # Formato para mostrar resumen
  method_summary_formatted <- data.frame(
    Method = method_summary$Method,
    Mean_Time_ms = method_summary$Time_ms[, "mean"],
    Median_Time_ms = method_summary$Time_ms[, "median"],
    Min_Time_ms = method_summary$Time_ms[, "min"],
    Max_Time_ms = method_summary$Time_ms[, "max"],
    Mean_Memory_MB = method_summary$Memory_MB[, "mean"],
    Median_Memory_MB = method_summary$Memory_MB[, "median"]
  )

  # Si está disponible el paquete ggplot2, crear visualizaciones
  if (requireNamespace("ggplot2", quietly = TRUE)) {
    library(ggplot2)

    # Gráfico de tiempo de ejecución
    p1 <- ggplot(perf_results, aes(x = Method, y = Time_ms, fill = Method)) +
      geom_boxplot() +
      scale_y_log10() +
      labs(title = "Comparación de Tiempo de Ejecución",

```

```

    x = "Método",
    y = "Tiempo (ms, escala log)" +
    theme_minimal()

# Gráfico de uso de memoria
p2 <- ggplot(perf_results, aes(x = Method, y = Memory_MB, fill = Method)) +
  geom_boxplot() +
  labs(title = "Comparación de Uso de Memoria",
        x = "Método",
        y = "Memoria (MB)") +
  theme_minimal()

# Imprimir gráficos
print(p1)
print(p2)
}

# Devolver el resumen
return(method_summary_formatted)
}

# Función para medir el tiempo de convergencia
compare_convergence_speed <- function() {
  # Parámetros fijos
  spot <- 1
  strike <- 1.0
  T <- 1
  r <- 0.05
  sigma <- 0.3

  # Valor de referencia (considerar Laplace con términos altos como "exacto")
  reference_price <- AWSR(spot, strike, T, sigma, r, aa = 18.4, terms = 50, extraterms =
    20)

  # Error objetivo
  target_error <- 0.001 # 0.1%

  # Para Monte Carlo - aumentar gradualmente número de simulaciones
  mc_paths_seq <- seq(100, 1000, by = 100)
  mc_results <- data.frame(
    paths = integer(),
    time_ms = numeric(),
    price = numeric(),
    rel_error = numeric()
  )

  for (paths in mc_paths_seq) {

```

```

gc()
start_time <- Sys.time()

result <- price_asian_option_mc(
  spot = spot,
  strike = strike,
  T = T,
  r = r,
  sigma = sigma,
  n_steps = 500, # fijo para este test
  n_paths = paths,
  control_variate = TRUE
)

end_time <- Sys.time()
time_ms <- as.numeric(difftime(end_time, start_time, units = "secs")) * 1000

rel_error <- abs(result$price - reference_price) / reference_price

mc_results <- rbind(mc_results, data.frame(
  paths = paths,
  time_ms = time_ms,
  price = result$price,
  rel_error = rel_error
))

# Terminar si alcanzamos el error objetivo
if (rel_error <= target_error) {
  break
}
}

# Para Laplace - aumentar gradualmente número de términos
lap_terms_seq <- seq(5, 50, by = 5)
lap_results <- data.frame(
  terms = integer(),
  time_ms = numeric(),
  price = numeric(),
  rel_error = numeric()
)

for (terms in lap_terms_seq) {
  gc()
  start_time <- Sys.time()

  result <- AWSR(
    spot = spot,

```

```

    strike = strike,
    expiry = T,
    sg = sigma,
    rf = r,
    aa = 18.4,
    terms = terms,
    extraterms = round(terms/2) # proporcional a terms
  )

  end_time <- Sys.time()
  time_ms <- as.numeric(difftime(end_time, start_time, units = "secs")) * 1000

  rel_error <- abs(result - reference_price) / reference_price

  lap_results <- rbind(lap_results, data.frame(
    terms = terms,
    time_ms = time_ms,
    price = result,
    rel_error = rel_error
  ))

  # Terminar si alcanzamos el error objetivo
  if (rel_error <= target_error) {
    break
  }
}

# Resumen
mc_conv_time <- mc_results[mc_results$rel_error <= target_error, "time_ms"][1]
if (is.na(mc_conv_time)) mc_conv_time <- max(mc_results$time_ms)

lap_conv_time <- lap_results[lap_results$rel_error <= target_error, "time_ms"][1]
if (is.na(lap_conv_time)) lap_conv_time <- max(lap_results$time_ms)

summary <- data.frame(
  Method = c("Monte Carlo", "Laplace"),
  Convergence_Time_ms = c(mc_conv_time, lap_conv_time),
  Final_Error = c(min(mc_results$rel_error), min(lap_results$rel_error))
)

return(list(
  summary = summary,
  mc_results = mc_results,
  lap_results = lap_results
))
}

```

```
# Ejecutar pruebas de rendimiento
perf_results <- compare_performance()
print(perf_results)

# Visualizar resultados
summary <- plot_performance(perf_results)
print(summary)

# Análisis de convergencia
conv_results <- compare_convergence_speed()
print(conv_results$summary)
```

Referencias

- [1] R. Fürth Albert Einstein Mileva Maric. *Investigations on the Theory of the Brownian Movement*. Dover Publications Inc., 1956.
- [2] Vladimir I. Arnold y Boris A. Khesin. *Topological Methods in Hydrodynamics*. Vol. 125. Applied Mathematical Sciences. Springer, 1998.
- [3] Esthelle Asmodelle. “The collaboration of Mileva Marić and Albert Einstein”. En: *Asian Journal of Physics* 24.4 (2015).
- [4] Richard F. Bass. *Stochastic Processes*. Cambridge, 2011.
- [5] Andrei N. Borodin. *Stochastic Processes*. Birkhäuser, 2013.
- [6] Gerónimo Uribe Bravo. “La Ley Arcoseno en Caminatas Aleatorias, Movimiento Browniano y en el Proceso Poisson Compuesto”. Tesis de Licenciatura. UNAM, 2005.
- [7] Maria Emilia Caballero et al. *Cadenas de Markov: Un enfoque elemental*. Sociedad Matemática Mexicana, 2004.
- [8] Robert Horton Cameron. “A Family of Integrals Serving to Connect the Wiener and Feynman Integrals”. En: *Journal of Math. & Phys.* 39 (1960), págs. 126-140.
- [9] Ulises Pérez Cendejas. “Ecuaciones Diferenciales Estocásticas, Soluciones Fuertes y Proceso de Bessel”. Tesis de Licenciatura. UNAM, 2019.
- [10] Kai-Lai Chung y John B. Walsh. *Markov Processes, Brownian Motion, and Time Symmetry*. Springer, 2005.
- [11] Erhan Cinlar. *Probability and Stochastics*. Springer, 2011.
- [12] Rick Durrett. *Brownian Motion and Martingales in Analysis*. Wadsworth Pub Co, 1984.
- [13] Lawrence C. Evans. *Partial Differential Equations*. Springer, 2010.
- [14] Wendell H. Fleming y H.M. Soner. *Controlled Markov Processes and Viscosity Solutions*. Springer, 2006.
- [15] Gianluca Fusai y Andrea Roncoroni. *Implementing Models in Quantitative Finance: Methods and Cases*. Springer, 2008.

- [16] Jean Francois Le Gall. *Brownian Motion, Martingales, and Stochastic Calculus*. Springer, 2016.
- [17] Israel Moiseievich Gelfand y Akiva Moiseievich Yaglom. “Integration in Function Spaces and its Applications in Quantum Physics”. En: *Uspekhi Mat. Nauk* 2 (1956), págs. 77-114.
- [18] Paul Glasserman. *Monte Carlo Methods in Financial Engineering*. Springer, 2003.
- [19] Stefano M. Iacus. *Simulation and Inference for Stochastic Differential Equations with R Examples*. Springer, 2008.
- [20] Monique Jeanblanc y Rose-Anne Dana. *Financial Markets in Continuous Time*. Springer, 2004.
- [21] Monique Jeanblanc y Marc Yor. *Mathematical Methods for Financial Markets*. Springer, 2009.
- [22] Jr. y Stephen A. Ross John C. Cox Jonathan E. Ingersoll. “A Theory of the Term Structure of Interest Rates”. En: *Econometrica* 53.2 (1986), págs. 385-407.
- [23] Ioannis Karatzas y Steven Shreve. *Brownian Motion and Stochastic Calculus*. Springer, 1998.
- [24] Leonid Borisovich Korolov y Yakov Grigorievich Sinai. *Theory of Probability and Random Processes*. Springer, 2007.
- [25] Vadim Linetsky. “Step Options”. En: *Mathematical Finance, Vol. 9, No. 1 (Enero, 1999), 55-96* (1999).
- [26] Lucrecio. *De rerum natura (Sobre la naturaleza de las cosas)*. Bibliotheca Scriptorum Graecorum et Romanorum Mexicana, 1984.
- [27] Pierre Del Moral. *Feynman-Kac Formulae*. Springer, 2004.
- [28] Pierre Del Moral y Spiridon Penev. *Stochastic Processes From Applications to Theory*. Springer, 2017.
- [29] Bernt Oksendal. *Stochastic Differential Equations: An Introduction With Applications*. Springer, 2007.
- [30] Alejandro Rosales Ortiz. “H-transformadas de Doob e inversiones de difusiones”. Tesis de Maestría. UNAM, 2018.
- [31] Alejandro Rosales Ortiz. “Procesos de Lévy, Procesos de Markov y Convergencia Débil en Espacios de Skorokhod”. Tesis de Maestría. UNAM, 2019.
- [32] Yuval Peres y Peter Mörters. *Brownian Motion*. Cambridge University Press, 2010.
- [33] Luis Rincón. *Introducción a los procesos estocásticos*. Facultad de Ciencias, UNAM, 2012.

- [34] Paul Samuelson. “Rational Theory of Warrant Pricing”. En: *Industrial Management Review* (1965).
- [35] Georgii Evgenevich Shilov. *Elementary Functional Analysis*. Dover Publications Inc, 1996.
- [36] Albert Shiryaev. *Essentials of Stochastic Finance: Facts, Models, Theory*. World Scientific, 1999.
- [37] Barry Simon. *Functional Integration and Quantum Physics*. Princeton University Press, 1979.
- [38] J. Michael Steele. *Stochastic Calculus and Financial Applications*. Springer, 2000.
- [39] Daniel W. Stroock. *An Introduction to Markov Processes*. Springer, 2014.
- [40] Kazuaki Taira. *Semigroups, Boundary Value Problems and Markov Processes*. Springer, 2014.
- [41] Constantin Tudor. *Procesos Estocásticos*. Instituto de Matemáticas de la UNAM, 2022.
- [42] Hadley Wickham. *Advanced R*. Chapman & Hall, 2019.

Índice alfabético

- Cadena de Markov, 58
- Difusión de Itô, 31
- Ecuación de Chapman-Kolmogorov, 17
- Ecuación de difusión modificada, 42
- Ecuación de Feynman-Kac, 40
- Ecuación del calor, 22
- Ecuación diferencial estocástica, 27
- Ecuaciones de Kolmogorov, 33
- Filtración, 11
- Fórmula de Itô, 27
- Función armónica, 60
- Generador infinitesimal, 19, 32, 63
- h-transformada de Doob, 59, 63
- Instrumentos Financieros Derivados, 74
- Integral estocástica, 26
- Ley del Arcoseno, 70
- Martingala, 14
- Martingala local, 15
- Modelo CIR, 79
- Modelo de Black-Scholes, 76
- Movimiento Browniano Geométrico, 29
- Opción asiática, 77
- Opción europea, 76
- Problema de Cauchy, 49
- Problema de Dirichlet-Poisson, 47
- Proceso de difusión matado, 37
- Proceso de Feynman-Kac, 37
- Proceso de Itô, 27
- Proceso de Markov, 16
- Proceso estocástico real, 10
- Propiedad de Markov, 16, 18, 33, 59
- R, 81
- Sucesión localizadora, 15, 26, 53
- Teorema de Girsanov, 34, 66
- Tiempo de paro, 11